

Návrh a testování běhových prostředí pro autonomní coding agenty v softwarovém vývoji

Vedoucí práce: Ing. Jiří Korčák

Vysoká škola ekonomická v Praze

Téma a struktura prezentace

Motivace

Agenti píšou kód rychleji,
než kontrolujeme, jak ho píšou.

Téma

Jak měřit chování agenta
a podle dat ladit jeho instrukce.

Struktura prezentace

1. Cíle a metodika
2. Stav poznání
3. Sada metrik (cíl 1)
4. Iterativní ladění (cíl 2)
5. Ablace složek (cíl 3)
6. Závěr a přínos

**Měříme agenta, ladíme
instrukce.**

Cíle a metodika práce

Cíle

1. Navrhnout sadu metrik pokrývajících proces, produkt a zdroje.
2. Ověřit proveditelnost iterativního ladění instrukcí podle těchto metrik.
3. Ablacemi prozkoumat, které složky instrukcí přispívají a které jsou redundantní.

Metodika

Rámec: Případová studie (Yin), systém upomínek faktur

Postup: 5 pilotních iterací r1-r5 (cíl 2)
+ 2 ablační varianty × 2 běhy (cíl 3)

Měření: sada metrik napříč procesem, produktem a zdroji

Co se zatím měřilo a co chybí

Existující výzkum

Tři studie shodně dokládají, že binární průchod testů nestačí: polovina prošlých změn by neprošla code review (METR 2026, Li 2026, Ehsani 2026).

Funkční benchmarky (SWE-bench, Terminal-bench, HumanEval) měří binární průchod; novější vlna rozšiřuje na proces a tokeny (Yin et al. 2025), strukturální kvalita kódu zůstává mimo.

Studie souborů s instrukcemi měří soubor jako celek (Lulla 2026: –28 % runtime; Gloaguen 2026: marginální přínos).

Mezera

Holistický pohled napříč procesem, produktem a zdroji současně.

Izolace složek instrukcí, ne soubor jako blackbox.

Sada metrik: proces, produkt, zdroje

Cíl 1: sada metrik

Tři dimenze pokrývají, co binární průchod testů zakrývá.

Proces (P1-P8)

jak agent pracoval

issues před kódem
větev per issue
test-first commity
popisy PR a commitů

Produkt (Q1-Q8)

co vyrobil

funkční korektnost
kvalita testů
lint, typy, složitost
design (LLM soudce)

Zdroje (E1-E3)

kolik to stálo

tokeny
čas běhu
kompakce kontextu

Rámec: Fenton a Bieman (proces / produkt / zdroje), ISO/IEC 25010.

Měření: deterministické nástroje + LLM-as-judge (GLM-5) u tří kvalitativních metrik.

Verifikace drží kvalitu. Konvence drží design.

Cíl 3: ablace složek

Ablace A

verifikační kroky odebrány.



Kvalita kódu klesla.

***Předvídatelné:** tyto verifikace byly do instrukcí přidány v pilotech právě proto, že bez nich metriky selhávaly.*

Ablace B

kódové konvence odebrány.



Deterministika beze změny. Klesla jen designová kvalita.

***Překvapivé:** konvence drží z tréninku modelu, ne z instrukcí. Změnu zachytil jen LLM judge. Deterministické nástroje ji nevidí.*

** Závěry jsou indikativní: variabilita mezi běhy byla srovnatelná s efektem ablace samotné.*

Závěr

Přínos

Sada metrik napříč procesem, produktem a zdroji.

Iterativní postup po operacionalizačním oblouku.

Přenositelný je postup, ne AGENTS.md.

Limity

Případová studie: jeden model, jeden projekt.

Indikativní zjištění, ne statistický důkaz.

Nedeterminismus modelu silný.

** Demonstrace proveditelnosti na MiniMax-M2.5 a TypeScript projektu. Aplikace na jiné modely a jazyky zůstává otevřená.*

Otázky

Otázky vedoucího

Ing. Jiří Korčák

1. Role ablační studie — proč nestačily pilotní iterace?
2. Rozdíl procesních, produktových a zdrojových metrik — konkrétní příklad?
3. Jak odlišit vlastní přínos od přínosu AI asistenta?
4. Pravidlo → příkaz → verifikační krok — konkrétní příklad?

Otázky oponenta

Ing. Richard Antonín Novák, Ph.D.

1. Termín "Ablace" — hlubší vysvětlení pojmu a jeho role v práci?