

Vysoká škola ekonomická v Praze
Fakulta informatiky a statistiky



Návrh a testování prostředí pro AI agenty v softwarovém vývoji

BAKALÁŘSKÁ PRÁCE

Studijní program: Aplikovaná informatika

Autor: Thanh An Nguyen

Vedoucí práce: Ing. Jiří Korčák

Praha, květen 2026

Prohlášení

Prohlašuji, že jsem bakalářskou práci zpracoval samostatně a že jsem uvedl všechny použité prameny a literaturu, ze kterých jsem čerpal.

Potvrzuji, že při přípravě předložené práce **byly použity** nástroje umělé inteligence. Konkrétně byly použity těmito způsoby:

- úprava a rozšíření textových částí,
- vyhledávání a shrnutí literatury,
- generování částí zdrojových kódů.

Každé použití je dokumentováno v příloze D.

Potvrzuji, že:

- má práce je originální a byla zpracována v souladu s etickými standardy, zejména s Etickým kodexem Vysoké školy ekonomické v Praze; že jsou v práci citovány všechny použité informační zdroje a že generovaný obsah byl mnou ověřen;
- přijímám plnou odpovědnost za celý obsah závěrečné práce.

V Praze dne 24. dubna 2026

Thanh An Nguyen

Poděkování

Poděkování.

Abstrakt

AI coding agenti dokáží generovat funkční kód, ale bez vhodných instrukcí nedodržují softwarově-inženýrské praktiky. Existující benchmarky měří pouze výsledek (vyřešil agent úkol?), nikoli kvalitu procesu ani kódu. Formalizovaný postup pro návrh a vyhodnocování instrukcí dosud chybí. Práce si klade tři cíle: (1) navrhnout sadu metrik měřících proces, kvalitu a efektivitu práce agenta; (2) demonstrovat iterativní postup návrhu instrukcí řízený těmito metrikami; (3) ablacemi prozkoumat, které složky instrukční sady přispívají k měřenému chování agenta a které jsou redundantní. Sadu metrik a postup ověřujeme na případové studii systému upomínek faktur. Agent (model MiniMax-M2.5 prostřednictvím nástroje OpenCode) prošel pěti pilotními iteracemi a čtyřmi ablačními běhy. Chování bylo měřeno 19 metrikami ve třech kategoriích: procesní (P), produktové (Q) a efektivita (E). Metriky zachytily, že iterativní úpravy instrukcí zlepšily dodržování pracovního postupu, ale ne monotónně. Nejlepší pilotní běh dosáhl plného splnění procesních metrik P1–P5 a zvýšil počet projitých referenčních testů z 39/42 na 41/42. Analýza odhalila vzorec vývoje instrukcí: obecné pravidlo → konkrétní příkaz → verifikační krok. Ablace ukázaly, že verifikační kroky nejsou redundantní; jejich odebrání zhoršilo funkční korektnost i automatizované metriky kvality kódu. Sekce kódových konvencí byla pro automatizované metriky převážně redundantní, ale ovlivňovala designovou kvalitu hodnocenou LLM-as-judge. Výsledky současně ukázaly, že procesní compliance je výrazně citlivá na nedeterminismus modelu. Přenositelným přínosem jsou sada metrik a iterativní postup; konkrétní naměřené hodnoty jsou vázány na podmínky případové studie.

Klíčová slova

AI coding agent, AGENTS.md, metriky kvality software, iterativní návrh, ablační studie

Abstract

AI coding agents can generate functional code, but without proper instructions they fail to follow software engineering practices. Existing benchmarks measure only the outcome (did the agent solve the task?), not process quality or code quality. A formalized process for designing and evaluating instructions is still lacking. This thesis pursues three goals: (1) design a metric suite measuring agent process, quality, and efficiency; (2) demonstrate an iterative instruction design process driven by these metrics; (3) use ablation to explore which instruction components contribute to the observed behavior and which are redundant. The metric suite and

process are evaluated on a single case study of a dunning system. The agent (MiniMax-M2.5 model via the OpenCode tool) underwent five pilot iterations and four ablation runs. Behavior was measured using 19 metrics in three categories: process (P), product (Q), and efficiency (E). The metrics showed that iterative instruction changes improved workflow adherence, but not monotonically. The best pilot run achieved full compliance on process metrics P1–P5 and increased reference-test performance from 39/42 to 41/42. Analysis revealed an instruction evolution pattern: general rule → specific command → verification step. Ablation showed that verification steps are not redundant: removing them degraded both functional correctness and automated code-quality metrics. The code-convention section proved largely redundant for automated metrics, but it still affected design quality as assessed by an LLM-as-judge. The results also showed that process compliance is highly sensitive to model non-determinism. The transferable contributions are the metric suite and the iterative process; the specific measured values are bound to the case study conditions.

Keywords

AI coding agent, AGENTS.md, software quality metrics, iterative design, ablation study

Obsah

Úvod	11
1 Vymezení problému a cílů práce	12
1.1 Motivace	12
1.2 Cíle práce	13
1.3 Rozsah práce	13
2 Teoretická východiska	14
2.1 Kvalita software a její měření	14
2.1.1 Měření kvality v softwarovém inženýrství	14
2.1.2 Dimenze měření kvality	15
2.1.3 Praktiky zajišťování kvality	16
2.2 AI coding agenti	18
2.2.1 Základní pojmy a typy	18
2.2.2 Jak agenti mění softwarové inženýrství	18
2.2.3 Instrukce jako nezávislá proměnná	19
2.2.4 Hodnocení schopností agentů	20
3 Metodika	23
3.1 Výzkumný přístup	23
3.2 Sada metrik	24
3.2.1 Procesní metriky (P1–P8)	24
3.2.2 Produktové metriky (Q1–Q8)	25
3.2.3 Metriky efektivity (E1–E3)	27
3.2.4 Aplikace LLM-as-judge	27
3.3 Experimentální design	28
3.3.1 Výběr projektu	28
3.3.2 Fixní proměnné	28
3.3.3 Iterativní cyklus	29
3.3.4 Pilotní fáze	31
3.3.5 Komparativní variace	31
3.4 Přehledová tabulka	31
3.5 Omezení a validita	32
4 Praktická část	34
4.1 Příprava experimentu	34
4.1.1 Konstrukce specifikace	34
4.1.2 Referenční implementace	35
4.1.3 Konstrukce baseline instrukcí	35
4.2 Pilotní fáze	37

4.2.1	Pilot-r1: baseline	37
4.2.2	Pilot-r2	39
4.2.3	Pilot-r3	40
4.2.4	Pilot-r4	42
4.2.5	Pilot-r5: verifikace kontraktu	43
4.3	Komparativní variace	47
4.3.1	Výběr složek pro ablaci	47
4.3.2	Ablace A: bez verifikačních kroků	48
4.3.3	Ablace B: bez Package Quality	50
4.3.4	Závěr komparativní fáze	51
4.4	Souhrnné výsledky	51
5	Vyhodnocení a diskuse	54
5.1	Interpretace výsledků	54
5.1.1	Cíl 1: Sada metrik	54
5.1.2	Cíl 2: Iterativní postup	58
5.1.3	Cíl 3: Ablace	60
5.2	Porovnání s literaturou	61
5.2.1	Srovnání metrického rámce	61
5.2.2	Vliv instrukcí na chování agenta	61
5.3	Omezení a jejich dopad	62
5.4	Doporučení pro praxi	64
5.5	Náměty pro další výzkum	65
	Závěr	68
	Bibliography	69
	A Formulář v plném znění	76
	B Zdrojové kódy výpočetních procedur	77
	C Baseline AGENTS.md	78
	D Využití nástrojů umělé inteligence	79

Seznam obrázků

4.1	Baseline AGENTS.md (pilot-r1): kompletní znění instrukcí použitých jako výchozí bod pilotních iterací.	36
4.2	Vizuální diff změn AGENTS.md mezi pilot-r1 a pilot-r2	39
4.3	Vizuální diff změn AGENTS.md mezi pilot-r2 a pilot-r3	40
4.4	Vizuální diff změn AGENTS.md mezi pilot-r3 a pilot-r4	42
4.5	Vizuální diff změn AGENTS.md mezi pilot-r3 a pilot-r5	43
4.6	Souhrnná evoluce AGENTS.md : pilot-r1 → pilot-r3. Zelené řádky = přidáno, červené = odebráno.	46
4.7	Změny AGENTS.md pro ablaci A	47
4.8	Změny AGENTS.md pro ablaci B: odebrána celá sekce Package Quality (konvence, strict TypeScript, JSDoc, čisté API).	48
5.1	Míra splnění exit kritérií procesní metriky (P1–P8) napříč devíti běhy. P2 a P5 byly splněny nejméně často (3/9), P6 a P7 ve všech bžích. Deterministické položky (P1–P5) vykazují vyšší variabilitu než kvalitativní (P6–P8).	55
5.2	Míra splnění exit kritérií produktové metriky (Q1–Q8) napříč devíti běhy. Q1 a Q6 byly splněny ve všech bžích; Q3 a Q5 nejméně často. Q3 počítáno ze 7 běhů (2 bez dat). Metriky efektivity (E1–E3) nemají exit kritérium a nejsou zahrnuty.	57
5.3	Cena běhu vs. počet splněných deterministických kritérií	58
5.4	Spektrum operacionalizace instrukcí. Tři nezávislá selhání (P2, P3, Q8) prošla stejnými fázemi: pravidlo (agent ignoruje) → příkaz (agent obchází) → verifikační krok (agent dodržuje).	59

Seznam tabulek

3.1	Sada metrik: kód, měřená vlastnost, nástroj, exit kritérium a typ	32
4.1	Mapování sekcí baseline AGENTS.md na metriky	37
4.2	Pilot-r1: naměřené metriky	38
4.3	Pilot-r2: metriky s změnou oproti r1	39
4.4	Pilot-r3: metriky s změnou oproti r2	41
4.5	Pilot-r4: metriky s změnou oproti r3	42
4.6	Pilot-r5: metriky s změnou oproti r3	44
4.7	Ablace A: srovnání s r3 (bez verifikačních kroků)	49
4.8	Ablace B: srovnání s r3 (bez sekce Package Quality)	50
4.9	Souhrnné výsledky všech běhů (pilot + ablance)	52

Seznam použitých zkratek

E1 vstup/výstup/cache tokeny

E2 trvání

E3 stabilita session

P1 issues before code

P2 branch per issue

P3 test-first commits

P4 PRs linked to issues

P5 no existing test modifications

P6 commit message quality

P7 issue description quality

P8 PR description quality

Q1 API contract match

Q2 referenční test pass rate

Q3 mutation score

Q4 AC coverage

Q5 lint warnings

Q6 typecheck errors

Q7 složitost kódu

Q8 design quality

Úvod

AI coding agenti dokáží autonomně implementovat funkcionalitu, psát testy, spravovat verzovací historii a komunikovat prostřednictvím issues a pull requestů. S rostoucí autonomií těchto nástrojů roste i potřeba systematicky hodnotit kvalitu jejich práce. Současné benchmarky hodnotí izolované aspekty práce agenta, především funkční korektnost. Holistický pohled, který by zachytil proces, kvalitu kódu a efektivitu společně, však chybí. Přitom i funkčně správné řešení může být v praxi odmítnuto kvůli nedostatkům v procesu nebo udržitelnosti. Praktik, který vidí jen pass/fail výsledek, tak může přecenit řešení, které by ve skutečném vývoji neprošlo code review nebo by se obtížně rozvíjelo.

Kvalitu práce agenta výrazně ovlivňují instrukce, které dostane. V praxi se etablují instrukční soubory jako `AGENTS.md` nebo `CLAUDE.md`, které definují pracovní postup, konvence a omezení projektu. Tyto soubory se stávají standardním rozhraním mezi člověkem a agentem nejen v softwarovém vývoji, ale i v univerzálních agentních nástrojích. Jak instrukce systematicky navrhovat a jak měřit, zda agent dodržuje požadované praktiky, zůstává otevřenou otázkou.

Tato práce navrhuje sadu metrik pokrývajících proces, kvalitu kódu a efektivitu práce agenta. Na případové studii necháváme agenta opakovaně implementovat systém upomínek faktur ze specifikace, výsledky měříme navrženými metrikami a na jejich základě upravujeme instrukce mezi iteracemi. Ablacemi dále zkoumáme, které složky instrukcí přispívají k měřenému chování a které jsou redundantní.

Práce nejprve vymezuje problém a cíle, poté shrnuje teoretická východiska z oblasti softwarového inženýrství, AI agentů a měření kvality. Na jejich základě navrhuje metodiku, kterou ověřuje na případové studii. Kapitola Vyhodnocení a diskuse interpretuje výsledky ve vztahu k cílům a porovnává je s existujícím výzkumem.

1. Vymezení problému a cílů práce

1.1 Motivace

AI coding agenti, tedy autonomní systémy schopné samostatně psát kód, spravovat verzovací historii a interagovat s vývojovým prostředím, se v posledních letech staly rozšířeným nástrojem každodenního vývoje softwaru. Slibují výrazné zrychlení práce: implementace, která vývojáři zabere hodiny, je teoreticky proveditelná v řádu minut. Empirická data ale ukazují, že tento příslib se nenaplnuje automaticky. Randomizovaná studie METR (METR, 2025) na 246 úlohách doložila, že vývojáři s AI nástroji byli ve skutečnosti o 19 % pomalejší.

Současné benchmarky jako SWE-bench (Jimenez et al., 2024) hodnotí izolované aspekty práce agenta, především funkční korektnost. Tři empirické studie ale shodně ukazují, že samotný pass/fail výsledek pro praktickou použitelnost nestačí. METR (METR, 2026)¹ doložila, že polovina patchů projitých automatickými testy by nebyla přijata při code review. Li et al. (B. Li et al., 2026) na 1 210 sloučených pull requestech zjistili kvalitativní nedostatky i v přijatém kódu. Ehsani et al. (Ehsani et al., 2026) pak z 33 tisíc agentních pull requestů identifikovali, že vedle funkčních chyb tvoří významný podíl odmítnutí i procesní selhání. Každá studie pojmenovává jinou stranu téhož problému: pass/fail neměří, zda by řešení obstálo v code review, zda je kód udržovatelný a zda vznikl auditovatelným postupem. Holistický pohled, který by tyto dimenze zachytil společně, dosud chybí.

Výsledky agenta nejsou dány jen schopnostmi modelu samotného; lze je ovlivnit dvěma způsoby: trénováním modelu nebo instrukcemi v kontextovém okně. S rostoucí velikostí kontextových oken a zkracujícími se cykly mezi generacemi modelů se instrukce stávají praktičtější alternativou: jsou dostupné komukoliv, iterativně upravitelné a přenositelné mezi modely. Fine-tuning naproti tomu vyžaduje trénovací data, výpočetní kapacitu a investici vázanou na konkrétní verzi modelu. Shin et al. (Shin et al., 2025) ukazují, že iterativní zpřesňování instrukcí dosahuje srovnatelných výsledků s fine-tuned modely na úlohách s kódem.

Empirie o účinnosti instrukcí je ale smíšená. Lulla et al. (Lulla et al., 2026) zjistili, že přítomnost instrukčního souboru je spojena se zkrácením doby běhu o 28,6 %, zatímco Gloaguen et al. (Gloaguen et al., 2025) upozorňují, že generické instrukce přinášejí marginální zlepšení při vyšších nákladech. Které složky instrukcí k měřenému chování skutečně přispívají a které jen zabírají kontextové okno, dosud nebylo izolováno. Jak instrukce systematicky navrhovat a jak měřit, zda agent dodržuje požadované praktiky, zůstává proto otevřenou otázkou.

¹Jiná studie téže organizace než (METR, 2025); zde analýza SWE-bench pull requestů, ne randomizovaný experiment.

1.2 Cíle práce

1. Na základě analýzy existujících standardů kvality softwaru a současných benchmarků pro AI agenty navrhnout sadu metrik pokrývající proces, kvalitu kódu a efektivitu, a tím zachytit dimenze, které stávající benchmarky neměří.
2. Na případové studii demonstrovat iterativní postup návrhu instrukcí řízený těmito metrikami a vyhodnotit, zda a jak vede k měřitelným změnám v dodržování vývojových praktik.
3. Z instrukcí vytvořených v cíli 2 prozkoumat ablacemi, které složky přispívají k měřenému chování agenta a které jsou redundantní.

1.3 Rozsah práce

Cíle ověřujeme na případové studii systému upomínek faktur. Existující studie hodnotí agenty na velkém počtu krátkých úloh; naše práce volí opačný přístup: jeden projekt do hloubky, s opakovanými běhy a podrobnou analýzou každého z nich.

Práce se nezabývá trénováním modelů, protože cílem je zkoumat vliv instrukcí, ne schopnosti konkrétního modelu. Nesrovnává různé modely ani programovací jazyky, protože experimentální design se snaží držet ostatní podmínky co nejstabilnější a měnit především instrukce. Neporovnává agenta s lidským vývojářem, protože měří zlepšení mezi iteracemi, ne absolutní výkon. Navržená sada metrik a iterativní postup jsou koncipovány jako přenositelný rámec; konkrétní instrukce a naměřené hodnoty platí pro tuto případovou studii a slouží jako feasibility demonstrace, nikoli jako obecně platný výsledek pro všechny modely a projekty. Zdůvodnění volby projektu a podrobnosti experimentálního designu popisuje kapitola 3.

2. Teoretická východiska

Tato kapitola poskytuje teoretický základ pro metrický rámec a experimentální postup práce. První sekce se věnuje kvalitě software z pohledu softwarového inženýrství: proč je její zajištění obtížné, jaké dimenze má, jakými praktikami se zajišťuje a jak se měří. Druhá sekce zavádí AI coding agenty: co jsou, jak se řídí instrukcemi a jak se jejich výstupy hodnotí.

2.1 Kvalita software a její měření

Softwarové inženýrství je disciplína, která přistupuje k vývoji software systematicky: od specifikace přes implementaci po údržbu (IEEE Computer Society, 2024). Na rozdíl od programování, které se soustředí na algoritmy a implementaci, softwarové inženýrství řeší mimo jiné i to, jak zajistit kvalitu výsledku (Sommerville, 2016). To zahrnuje řízení požadavků, návrh architektury, správu konfigurací, zajištění kvality i řízení projektu. Kvalita se přitom v této disciplíně posuzuje na více entitách: nejen podle vlastností výsledného software produktu, ale i podle procesů, jimiž tento produkt vzniká, a podle zdrojů, které k tomu byly spotřebovány. Tato sekce proto nejprve zavádí tři entity měření podle Fentona a Biemana a shrnuje, jak je literatura pokrývá (sekce 2.1.1). Poté popisuje dimenze kvality produktu, procesu a zdrojů podrobněji (sekce 2.1.2) a nakonec shrnuje praktiky, kterými se kvalita v tradičním vývoji zajišťuje (sekce 2.1.3).

2.1.1 Měření kvality v softwarovém inženýrství

Měření kvality v softwarovém inženýrství se neomezuje na vlastnosti výsledného artefaktu. Fenton a Bieman (Fenton & Bieman, 2014) rozlišují tři kategorie entit, na kterých lze kvalitu měřit: *produkt*, tedy výstupy vývoje (implementace, testy, dokumentace); *proces*, tedy aktivity a postupy, kterými produkt vzniká; a *zdroje*, tedy vstupy nutné k jeho vzniku (čas, úsilí, lidé, výpočetní prostředky). Každá entita nese jiný typ evidence o kvalitě a celkové hodnocení je obvykle skládá dohromady.

Literatura pokrývá tyto tři entity asymetricky. Produktová stránka je nejzralejší. Standardizovaný rámec ISO/IEC 25010 (ISO/IEC, 2023) rozkládá kvalitu produktu do osmi charakteristik a navazuje na dřívější modely, například na McCallův (McCall et al., 1977); detailněji se jim věnuje sekce 2.1.2. Procesní stránka má zavedené rámce v podobě modelů procesní zralosti: CMM/CMMI (Paulk et al., 1993) a rodina norem ISO/IEC 330xx (ISO/IEC, 2019) popisují, jak hodnotit capability organizačního procesu. Tyto rámce ale pracují v horizontu auditu zralosti napříč projekty a roky, nikoli v horizontu pozorování jednoho experimentálního běhu. Procesní metriky pro konkrétní experiment se proto obvykle definují ad hoc. Zdrojová stránka bývá zachycena zejména přes proxy nákladů, úsilí a času (Fenton & Bieman, 2014).

Tato asymetrie se v kapitole 3 stává motivací pro operacionalizaci jednotlivých dimenzí v kontextu coding agentů: pro produkt lze navázat na zavedené charakteristiky, pro proces a zdroje je třeba zvolit konkrétnější podobu než jakou nabízejí obecné rámce.

2.1.2 Dimenze měření kvality

Na každé ze tří entit zavedených v předchozí sekci se kvalita projevuje jiným typem evidence. Tato sekce popisuje, jaké charakteristiky literatura sleduje na produktu, na procesu a na zdrojích.

Produktová kvalita má dnes podobu standardizovaného rozkladu do osmi charakteristik. ISO/IEC 25010 (ISO/IEC, 2023) je navazuje na starší modely, například McCallův z roku 1977 (McCall et al., 1977), a dělí kvalitu produktu na funkční vhodnost, výkonnostní efektivitu, kompatibilitu, použitelnost, spolehlivost, bezpečnost, udržitelnost a přenositelnost. Dvě z nich stojí v literatuře o generování kódu do popředí. *Funkční vhodnost* vyjadřuje, do jaké míry software poskytuje funkce naplňující stanovené potřeby (ISO/IEC, 2023), a typicky se projevuje v chování programu za běhu vůči specifikaci. *Udržitelnost* vyjadřuje, s jakou účinností a efektivitou lze software upravovat při opravách, zlepšeních nebo přizpůsobování změnám (ISO/IEC, 2023), a projevuje se ve vlastnostech zdrojového kódu, nikoli až za běhu. Obě dimenze proto vyžadují odlišné typy evidence. Přehled a srovnání produktových modelů kvality podává Miguel et al. (Miguel et al., 2014).

Procesní kvalita má v softwarovém inženýrství vlastní rodinu rámců. CMM/CMMI (Paulk et al., 1993) a ISO/IEC 330xx (ISO/IEC, 2019) popisují pětistupňovou škálu zralosti organizačního procesu a slouží k auditu a certifikaci. Jejich horizont je dlouhodobý a agregovaný: hodnotí, jak organizace své procesy definuje, řídí a zlepšuje napříč mnoha projekty. Pro pozorování jednoho experimentálního běhu (například běhu coding agenta nad jednou sadou úloh) tyto rámce neposkytují přímo použitelné metriky, a procesní charakteristiky se proto v empirických studiích obvykle definují ad hoc pomocí artefaktů vývoje, jako jsou commity, pull requesty nebo záznamy z CI.

Zdrojová stránka zachycuje náklady, za které výsledek vzniká. Fenton a Bieman (Fenton & Bieman, 2014) mezi zdrojové atributy řadí zejména čas, lidské úsilí a použití výpočetních prostředků. U LLM-based systémů se k tradičním proxy přidávají specifitější veličiny, zejména spotřebované tokeny a čas běhu na úlohu.

Uvnitř produktové dimenze se jednotlivé charakteristiky liší typem evidence, ze kterého je lze získat, a nástroji, které se v praxi používají. Funkční vhodnost se zjišťuje testováním; test porovnává pozorovatelné chování programu s očekávaným chováním odvozeným ze specifikace nebo akceptačních kritérií. Samotný průchod testů ale vypovídá primárně o testované implementaci, nikoli o síle testů samotných. *Mutation testing* strukturální coverage doplňuje o pohled na sílu testovací sady: do programu systematicky zavádí drobné změny (mutanty) a sleduje, kolik z nich testy odhalí (Papadakis et al., 2019). Udržitelnost se naopak projevuje ve vlastnostech zdrojového kódu a část z ní lze hodnotit statickou analýzou bez spuštění

programu. Cyklomatická složitost (McCabe, 1976) vyjadřuje počet lineárně nezávislých cest grafem řízení toku; v praxi se často používá práh 10 na funkci (McConnell, 2004). Linting a typová kontrola podobně zachycují porušení konvencí a nekonzistence v rozhraních. Statická analýza je však jen proxy pro vybrané atributy udržitelnosti: vhodnost dekompozice, pojmenování nebo přiměřenost návrhových rozhodnutí přesahují možnosti čistě deterministických nástrojů.

2.1.3 Praktiky zajišťování kvality

Předchozí sekce vymezila, jaké charakteristiky se sledují u produktu, procesu a zdrojů. Samotné vymezení těchto charakteristik však ještě neříká, jak jich při vývoji dosáhnout. Praktiky zajišťování kvality přitom v softwarovém inženýrství tvoří širší spektrum činností od práce s požadavky a specifikací přes organizaci změn a jejich ověřování až po průběžnou péči o strukturu kódu. Tato sekce se z tohoto širšího rámce soustředí na tři skupiny praktik, které se přímo promítají do hodnocení agentních běhů a výsledného kódu: organizaci práce se změnami, testování a postupy podporující udržitelnost kódu.

Procesní praktiky.

Procesní praktiky určují, jak změny vznikají, kontrolují se a začleňují do projektu. Jejich význam spočívá v tom, že zvyšují auditovatelnost a spolehlivost vývoje.

Základem těchto praktik je správa verzí, protože umožňuje sledovat historii změn a bezpečně se vrátit k předchozím stavům kódu. Pro kvalitu vývoje však není rozhodující jen samotný nástroj, ale způsob, jakým se používá. Práce v oddělených větvích (*branches*) izoluje rozpracované změny od stabilního kódu; Shihab et al. (Shihab et al., 2012) empiricky ukázali, že nesoulad mezi strukturou větví a organizační strukturou je spojen s vyšší mírou defektů po vydání. Granulární commity, kde každá změna odpovídá jednomu logickému kroku, usnadňují zpětnou analýzu chyb a code review (Humble & Farley, 2010). Průběžná integrace (*continuous integration*) tyto praktiky doplňuje automatickým ověřováním, že sloučení změn nenarušilo funkčnost (Humble & Farley, 2010).

Další procesní praktikou je code review, tedy kontrola kódu jiným vývojářem před jeho začleněním. Historicky probíhala formou strukturovaných inspekcí, dnes převládá méně formální podoba integrovaná do pull requestů, označovaná jako *modern code review*. Jde o průběžné posuzování menších změn jako běžné součásti integrace, nikoli o samostatnou formální inspekci celé implementace. Bacchelli a Bird (Bacchelli & Bird, 2013) empiricky zjistili, že moderní code review přispívá nejen k odhalování defektů, ale především ke zlepšování kvality kódu, sdílení znalostí a nalézání alternativních řešení. McIntosh et al. (McIntosh et al., 2016) dále prokázali, že kód, který neprošel review, vykazuje měřitelně vyšší míru defektů po vydání.

Vedle správy verzí a code review je pro kvalitu vývoje důležitá také *traceability*, tedy schopnost

dohledat vazby mezi požadavkem a artefakty, které s ním souvisejí (Gotel & Finkelstein, 1994). Nejde jen o uchování historie kódu, ale o propojení zadání změny, její implementace, review a ověření. V praxi to znamená vazby mezi issue, commity a větvemi, pull requestem a testy. Díky nim lze zpětně pochopit, proč byla změna provedena, co přesně měnila a jak bylo ověřeno, že odpovídá zadání.

Testování.

Testování ověřuje, zda software skutečně plní požadavky, které na něj klademe. Jeho význam spočívá v tom, že poskytuje systematickou kontrolu chování výsledného řešení a zachycuje chyby dříve, než se projeví v provozu.

Testování se provádí na různých úrovních: *unit testy* ověřují jednotlivé funkce nebo moduly izolovaně, *integrační testy* ověřují spolupráci komponent a *akceptační testy* ověřují splnění požadavků z pohledu zadavatele. Každá úroveň zachycuje jiný typ chyb.

Z hlediska pořadí lze testování organizovat různými způsoby. Nejběžnější je *test-after* přístup, kdy vývojář napíše implementaci a následně k ní vytvoří testy. Přístup *test-driven development* (TDD) pořadí obrací: nejprve se napíše test definující očekávané chování, teprve pak implementace, která test splní (Beck, 2000). Tím se test stává specifikací požadavku, nikoli zpětnou kontrolou již napsaného kódu. Meta-analýza 27 studií Rafiqua a Mišiće (Rafique & Mišić, 2013) ukazuje, že TDD má pozitivní efekt na kvalitu kódu měřenou hustotou defektů. Efekt je výraznější v průmyslových projektech než v akademických experimentech, což naznačuje, že přínos roste se složitostí řešeného problému.

Praktiky podporující udržovatelnost.

Praktiky podporující udržovatelnost mají zajistit, aby kód zůstal srozumitelný a bezpečně modifikovatelný i při dalších změnách. Jejich význam spočívá v tom, že omezují růst složitosti a snižují riziko, že každá další úprava bude dražší a náchylnější k chybám.

V praxi se udržovatelnost opírá o vlastnosti jako čitelnost, srozumitelné pojmenování, oddělení zodpovědností, omezení složitosti nebo dodržování konvencí jazyka (McConnell, 2004). Proto ji podporují průběžný refaktoring, důsledná práce s rozhraními a odpovědnostmi modulů i automatizované kontroly kódu. SWEBOOK zároveň zdůrazňuje, že její úroveň neposilují jen vlastnosti samotného kódu, ale i systematické vývojové procesy, techniky a nástroje (IEEE Computer Society, 2024). Některé z těchto vlastností lze ověřovat deterministicky, jiné však vyžadují i expertní posouzení; právě k těmto způsobům hodnocení se vrací následující sekce.

2.2 AI coding agenti

Předchozí sekce popsala, jak se kvalita software zajišťuje a měří v tradičním vývoji. AI coding agenti tento kontext mění: kód již nepíše pouze člověk, ale autonomní systém řízený instrukcemi. Požadavky na kvalitu zůstávají stejné, mění se však to, kdo je plní, jak vzniká pracovní stopa a jakými proxy se zachycují náklady. Tato sekce nejprve zavádí základní pojmy (sekce 2.2.1), poté shrnuje, jak agenti mění softwarové inženýrství napříč dimenzemi produktu, procesu a zdrojů (sekce 2.2.2). Navazuje popisem toho, jak se chování agentů řídí instrukcemi jako nezávislou proměnnou (sekce 2.2.3), a končí přehledem přístupů k hodnocení jejich schopností (sekce 2.2.4).

2.2.1 Základní pojmy a typy

Velký jazykový model (*large language model*, LLM) je neuronová síť trénovaná na rozsáhlých textových korpusech (Vaswani et al., 2017). Na základě předchozího kontextu predikuje pravděpodobný následující token, a tím generuje koherentní text, včetně zdrojového kódu. Samotný LLM je však pasivní: odpovídá na dotazy, ale nemůže samostatně číst soubory, spouštět příkazy ani měnit stav projektu.

LLM-based agent model rozšiřuje o schopnost interagovat s prostředím (Liu et al., 2024): plánuje kroky, volá nástroje (*tool use* (Schick et al., 2023)) a na základě pozorovaného výsledku rozhoduje o dalším kroku v cyklu Thought → Action → Observation (Yao et al., 2023). V kontextu softwarového vývoje to znamená, že agent může číst a zapisovat soubory, spouštět testy, používat verzovací systém nebo volat API. Právě tyto schopnosti určují, jak agent zpracuje instrukce a jaké měřitelné stopy po sobě zanechá.

Předmětem této práce jsou *autonomní coding agenti*, tedy systémy, které na základě specifikace a instrukcí samostatně implementují softwarový projekt (např. Claude Code, OpenHands) (Guo et al., 2025). Na rozdíl od asistenčních nástrojů (GitHub Copilot) agent provádí celý vývojový proces, nikoli jen jednotlivé kroky. Jeho výstupy proto lze posuzovat stejnými požadavky na kvalitu procesu i produktu, jaké popisuje sekce 2.1.

2.2.2 Jak agenti mění softwarové inženýrství

Přechod od lidského vývojáře k autonomnímu agentovi posouvá softwarové inženýrství ve všech třech dimenzích zavedených v sekci 2.1.1. Jin et al. (Jin et al., 2024) v přehledu 124 studií ukazují, že agenti pronikají do šesti oblastí SE: požadavků, generování kódu, autonomního rozhodování, návrhu, generování testů a údržby. Důsledky pro každou dimenzi měření kvality se však liší.

Procesní stránka se mění v tom, kdo provádí jednotlivé kroky, a v tom, jakou stopu po sobě zanechávají. Agenti fungují jako sekvence cyklu Thought–Action–Observation (Yao et al., 2023)

nad sandboxovaným prostředím: čtou a upravují repozitář, spouští testy a skripty, komitují a otevírají pull requesty. Open-source implementace jako SWE-agent (Yang et al., 2024) ukazují, že i drobné úpravy rozhraní mezi agentem a prostředím (agent-computer interface) posouvají úspěšnost na reálných úlohách o jednotky procentních bodů. V produkčním nasazení tak vzniká procesní stopa v podobě commitů, větví a CI výstupů, kterou lze zpětně analyzovat; empirická pozorování ale ukazují, že agent-generované pull requesty se od těch lidských liší mírou nadbytečnosti, konzistencí commit zpráv a ochotou reviewera je přijmout (Ehsani et al., 2026; Watanabe et al., 2025).

Produktová stránka zůstává vymezena stejnými charakteristikami (viz sekce 2.1.2), ale typické vzorce agent-generovaného kódu jsou jiné než u lidského vývojáře. Li et al. (B. Li et al., 2026) na 1210 merged agent-PR z reálných repozitářů zjistili, že i přijaté patche nesou vyšší výskyt code smells, duplikací a strukturálních problémů, které merge samotný neodhalí. Zhodnocení výstupu proto v literatuře kombinuje automatizované benchmarky (sekce 2.2.4) s post-hoc statickou analýzou a s hodnocením od LLM-judgů či lidských reviewerů.

Zdrojová stránka dostává u agentů nové proxy. Na místě člověko-hodin stojí spotřebované tokeny a čas běhu na úlohu; kontextové okno a rate limit vystupují jako vzácné zdroje, které ovlivňují, kolik úloh a jak dlouhých agent zvládne. Empirické práce v této oblasti ukazují, že řízení kontextu samo o sobě významně mění ekonomiku běhu: například Lindenbauer et al. (Lindenbauer et al., 2025) pozorují, že jednoduché maskování pozorování dosáhne srovnatelné úspěšnosti jako LLM-sumarizace za polovinu nákladů.

Protože běžné benchmarky hodnotí izolované úlohy a zavedené rámce (ISO 25010 pro produkt, CMMI/ISO 33020 pro proces) nepokrývají všechny tři dimenze v režimu jednoho experimentálního běhu, je pro vyhodnocení coding agenta v rámci jedné case study třeba operacionalizovat všechny tři dimenze cíleně. Tento krok řeší kapitola 3.

2.2.3 Instrukce jako nezávislá proměnná

Autonomní agent nemá *tacit knowledge*, tedy implicitní znalosti, které lidský vývojář získává zkušeností: jaké konvence tým dodržuje, proč je kód strukturovaný určitým způsobem nebo jaké chyby se v projektu opakují. Nonaka a Takeuchi (Nonaka & Takeuchi, 1995) popisují převod tacit knowledge na explicitní jako klíčový proces v organizacích. Pro agenty je tento převod nutný v plném rozsahu: veškerý kontext, který agent potřebuje, musí být zapsán explicitně. Hassan et al. (Hassan et al., 2025) tuto dualitu formalizují v rámci SASE (*Software Engineering for Agents*): zatímco lidský vývojář (SE4H) čerpá z meetingů, code review a zkušenosti, agent (SE4A) pracuje výhradně s tím, co dostane jako vstup.

Scaffolding označuje strukturované artefakty v prostředí agenta, které jeho chování řídí. V praxi jde nejčastěji o instrukční soubory umístěné v repozitáři (např. `AGENTS.md`, `CLAUDE.md`), které definují roli agenta, pracovní postup, konvence a omezení. Na rozdíl od jednorázových promptů jsou tyto soubory verzované a iterativně upravované, což z nich činí “living documents,” jejichž vývoj lze zpětně sledovat.

Mao et al. (Mao et al., 2025) analyzovali 2 163 produkčních prompt šablon a identifikovali sedm typů komponent: Role, Directive, Context, Workflow, Output, Constraints a Examples. Zjistili, že Role a Directive se nejčastěji objevují na začátku dokumentu a že Workflow (procedurální kroky) je nejúčinnější komponentou pro složité úkoly. Toto zjištění potvrzují Li et al. (X. Li et al., 2025), kteří ukazují, že procedurální instrukce (“jak pracovat”) jsou efektivnější než popisná dokumentace (“jak vypadá codebase”).

Empirická evidence o účinnosti instrukčních souborů je smíšená a ukazuje, že samotná přítomnost instrukcí nestačí: rozhodující je jejich obsah, struktura a relevance pro konkrétní úlohu. Přítomnost souboru `AGENTS.md` je sice spojena s nižší mediánovou dobou běhu agenta (−28,6 %) (Lulla et al., 2026), ale dopad závisí na původu obsahu: LLM-generované instrukční soubory úspěšnost agenta snižují a i soubory napsané vývojáři přinášejí jen marginální zlepšení (Gloaguen et al., 2025). V benchmarku SkillsBench zlepšují kurátorované moduly výsledky o 16,2 procentních bodů, zatímco automaticky generované nemají žádný efekt (X. Li et al., 2025). Účinnost jednotlivých typů obsahu přitom dosud nebyla izolována.

Chování agenta je navíc citlivé na formulaci instrukcí. Breunig et al. (Breunig, 2025) ukazují, že přestrukturování instrukce je účinnější než její opakování: když agent pravidlo ignoruje, nepomůže ho zopakovat; je třeba ho přeformulovat tak, aby se stalo součástí pracovního postupu. Razavi a Fard (Razavi & Fard, 2025) dokládají, že drobné změny formulace promptu mohou dramaticky změnit chování modelu, což motivuje cílené úpravy místo přidávání dalších pravidel.

Na chování agenta působí také *specifita* instrukce. Kim et al. (Kim, 2025) v benchmarku DETAIL a Zi et al. (Zi et al., 2025) na úlohách s kódem shodně ukazují, že konkrétnější formulace zvyšují úspěšnost agenta, ale přílišný detail může omezit jeho reasoning. Instrukce se tak pohybují po ose od volné nápovědy po explicitní příkaz, přičemž optimální bod závisí na úloze i modelu.

Výzkum promptingu navíc naznačuje, že instrukce nepůsobí na chování modelu jedním mechanismem. Wei et al. (Wei et al., 2022) ukazují, že i krátká nápověda (“think step by step”) aktivuje reasoning, který se bez ní neprojeví, a Min et al. (Min et al., 2022) dokládají, že demonstrace v in-context learning působí spíš jako strukturální vodítka než jako přímé příkazy. Chování modelu lze tedy ovlivnit přímým *vynucením* i *aktivací* latentních znalostí; která z cest je v konkrétním případě účinnější, nelze rozhodnout předem.

Otevřenou otázkou proto není jen to, zda instrukce obecně pomáhají, ale jak jejich obsah systematicky navrhovat a jak poznat, které složky skutečně mění chování agenta.

2.2.4 Hodnocení schopností agentů

De facto standardem pro hodnocení coding agentů je SWE-bench (Jimenez et al., 2024): benchmark obsahující 2 294 úloh z reálných GitHub repozitářů, kde agent dostane popis problému (GitHub issue) a má vytvořit patch, který projde testy. Hodnocení je binární: patch

projde nebo neprojde. Obdobně HumanEval (M. Chen et al., 2021) měří schopnost modelu generovat funkčně správný kód na izolovaných programovacích úlohách.

Tyto benchmarky měří *funkční korektnost*: zda výsledek dělá to, co má. Neměří však, jak agent pracoval (dodržoval proces?), jakou strukturální kvalitu má výsledný kód (je udržitelný?) ani za jakou cenu výsledku dosáhl (kolik tokenů spotřeboval?). Kapitola 1 tuto mezeru dokládá na třech nezávislých empirických studiích (METR (METR, 2026), Li et al. (B. Li et al., 2026) a Ehsani et al. (Ehsani et al., 2026)), které na různých velkých vzorcích a z různých úhlů ukazují, že pass/fail výsledek samotný neodpovídá praktické použitelnosti patche: nezachycuje code review, udržitelnost ani procesní integritu. Každá studie pojmenovává jinou stranu téhož problému.

Existují benchmarky, které hodnocení rozšiřují nad rámec pass/fail. SWE-bench Pro (Scale AI, 2025) přidává strukturované požadavky, ACE-Bench („ACE-Bench: End-to-End Feature Development Benchmark“, 2025) testuje end-to-end vývoj a FeatureBench („FeatureBench: Benchmarking Agentic Coding for Complex Feature Development“, 2026) hodnotí implementaci celých funkcí. Žádný z nich však systematicky neměří kvalitu procesu (jak agent organizoval práci), kvalitu kódu nad rámec funkční korektnosti (udržovatelnost, čistota) a efektivitu (spotřeba zdrojů) současně. Tato mezera naznačuje potřebu metrického rámce, který by dimenze procesu, kvality kódu a efektivitu pokrýval současně. Návrh takového rámce a jeho operacionalizaci v kontextu této práce popisuje kapitola 3.

LLM-as-judge.

Některé dimenze kvality, jako srozumitelnost commit zpráv, kvalita dokumentace nebo vhodnost návrhových vzorů, nelze spolehlivě hodnotit deterministickými nástroji. Jedním z přístupů je využití LLM jako hodnotitele (*LLM-as-judge*). Zheng et al. (Zheng et al., 2023) ukázali, že LLM dokáže hodnotit kvalitu výstupů na úrovni srovnatelné s lidskými hodnotiteli, ale identifikovali tři systematické biasy: *position bias* (preferuje odpověď na určité pozici), *verbosity bias* (preferuje delší odpovědi) a *self-enhancement bias* (preferuje vlastní výstupy). Panickssery et al. (Panickssery et al., 2024) prokázali korelaci mezi schopností modelu rozpoznat vlastní výstupy a mírou, do jaké je preferuje, což naznačuje kauzální vztah mezi self-recognition a self-preference. Verga et al. (Verga et al., 2024) navrhli mitigaci formou panelu diverzních modelů (PoLL), který dosahuje lepší shody s lidským hodnocením než jednotlivý model. Praktickou implikací je volba hodnotícího modelu z odlišné modelové rodiny, než ve které pracuje hodnocený agent.

Test oracle problem.

S testováním souvisí *test oracle problem*: kdo definuje správný výsledek? Mathews et al. (Mathews & Nagappan, 2024) zjistili, že nástroje pro automatické generování testů systematicky filtrují selhávající testy; až 68,1 % výsledných testovacích sad validuje chybné

chování místo jeho odhalení. Chen et al. (J. Chen et al., 2025) na 500 úlohách benchmarku SWE-bench Verified potvrdili, že agent-generované testy slouží primárně jako observační zpětná vazba, nikoli jako validační nástroj. Obranou proti tomuto problému je odvozování očekávaných hodnot ze specifikace, nikoli z pozorování kódu.

Benchmarky i doplňkové mechanismy z této sekce hodnotí převážně izolované úlohy a jednotlivé aspekty výstupu. Pro vyhodnocení agenta v kontextu jedné case study je třeba metrik pokrývajících dimenze produktu, procesu i zdrojů současně; jejich návrh je obsahem kapitoly 3.

3. Metodika

Před definicí konkrétních metrik a experimentálního designu je třeba oddělit tři roviny, na nichž tato práce pracuje, protože se snadno zaměňují. *Systém upomínek faktur* slouží jako testovací prostředí, na kterém agenta pozorujeme; není předmětem zkoumání. *Chování agenta*, tedy jak implementuje, jak strukturuje práci a jaký kód vytváří, je to, co měříme. *Instrukce* v souboru `AGENTS.md` jsou nezávislou proměnnou, kterou mezi běhy měníme. Následující metodika definuje, jak tyto roviny měřit odděleně a jak výsledky mezi běhy porovnávat.

3.1 Výzkumný přístup

Kapitola 1 vymezila problém, že pass/fail benchmarky nepostačují pro posouzení praktické použitelnosti AI coding agenta, a kapitola 2 ukázala, proč je vedle funkční korektnosti nutné sledovat i proces, kvalitu kódu a efektivitu a proč jsou instrukce smysluplnou nezávislou proměnnou. Tato kapitola tato východiska převádí do konkrétní metodiky: definuje sadu metrik, experimentální design a způsob, jak jsou výsledky mezi běhy porovnávány.

Navrhujeme sadu metrik a iterativní postup pro hodnocení AI coding agentů. Ověřujeme je na případové studii systému upomínek faktur: opakovaně pouštíme agenta s různými variantami instrukcí a měříme, jak se mění jeho proces, výstup a náklady. Tento přístup odpovídá iterativnímu cyklu návrhu a vyhodnocení (Hevner et al., 2004; Peffers et al., 2008), ale v našem kontextu neslouží k silné statistické izolaci kauzality. Jeho cílem je ukázat, zda je navržený metrický rámec a postup použitelný a jaké typy změn v chování agenta dokáže odhalit.

V této práci realizujeme cyklus čtyřmi kroky: Spuštění, Měření, Diagnóza a Úprava. Podrobný popis kroků uvádí sekce 3.3.4. Postup má dvě fáze: pilotní fázi, v níž cyklus opakujeme dokud nedosáhneme stabilního zlepšení a jednoho úspěšného běhu podle zvolených kritérií, a komparativní variace, v níž z fungující verze instrukcí systematicky odebíráme jednotlivé části a měříme dopad na chování agenta (sekce 3.3.5).

Pro ověření jsme zvolili případovou studii na jednom projektu. Řízený experiment s větším počtem běhů by byl vzhledem k ceně jedné iterace (tisíce tokenů, desítky minut) nepraktický. Případová studie naopak umožňuje opakované běhy s různými instrukcemi a podrobnou analýzu každého z nich. Z jednoho projektu nelze statisticky generalizovat. Yin (R. K. Yin, 2018) pro tento typ výzkumu používá pojem analytická generalizace: na jednom případě ukazujeme princip, který lze dále ověřovat na dalších projektech. Jde o embedded single-case design: zkoumáme jeden projekt, ale v rámci něj více běhů agenta, z nichž každý má vlastní verzi instrukcí, git historii a sadu naměřených metrik.

3.2 Sada metrik

Každý experimentální běh probíhá tak, že agent dostane prázdné GitHub repo, specifikaci v Issue #1 a instrukce v `AGENTS.md`, a autonomně implementuje zadaný projekt. Výstup jednoho běhu (kód, testy, git historie) měříme sadou 19 metrik. Postup běhu a experimentální design popisuje sekce 3.3.

Sada metrik pokrývá tři otázky: jak agent pracoval, co vyrobil a za jakou cenu. Fenton a Bieman (Fenton & Bieman, 2014) klasifikují měřitelné entity v softwarovém inženýrství do tří kategorií: proces, produkt a zdroj. V kontextu AI agentů dospívají k obdobnému rozdělení Yin et al. (2025) (Z. Yin et al., 2025), kteří hodnotí agentní frameworky ve třech dimenzích: effectiveness (výsledek), efficiency (průběh práce) a overhead (spotřebované zdroje). Naše sada metrik sleduje stejnou strukturu a obsahuje 19 metrik ve třech kategoriích:

- P – proces (P1–P8)** Dodržel agent předepsaný postup? Měříme dodržování workflow pravidel z instrukcí (P1 (issues before code)–P5) a kvalitu procesních výstupů jako commit messages, issue a PR descriptions (P6 (commit message quality)–P8).
- Q – kvalita produktu (Q1–Q8)** Je kód kvalitní? Měříme funkční korektnost (Q1 (API contract match)–Q2), kvalitu testů (Q3 (mutation score)–Q4) a udržitelnost kódu (Q5 (lint warnings)–Q8).
- E – efektivita (E1–E3)** Za jakou cenu? Zaznamenáváme tokeny z exportu (E1 (vstup/výstup/cache tokeny): špička promptu na krok, součet výstupů a součet `cache.read+cache.write` přes kroky; vše v tisících vedle sebe), čas (E2 (trvání)) a stabilitu session (E3 (stabilita session)).

Výběr konkrétních metrik vychází z potřeb případové studie a dostupných nástrojů. Z osmi charakteristik ISO/IEC 25010 (sekce 2.1.2) operacionalizujeme v produktových metrikách dvě: *funkční vhodnost* (Q1–Q4: agent vytváří správné řešení) a *udržitelnost* (Q5–Q8: agent vytváří kód vhodný k dalšímu pochopení a rozvoji). Ostatní charakteristiky (bezpečnost, výkonnostní efektivita, kompatibilita, použitelnost, spolehlivost, přenositelnost) by se na rozsahu jedné malé případové studie systému upomínek smysluplně měřit nedaly. Sada si neklade nárok na úplnost. Teoretické základy jednotlivých metrik (proč jsou validní, jaká je evidence) popisuje sekce 2.1.2. Tato sekce se soustředí na jejich operacionalizaci: jaký nástroj používáme, jaká data jsou vstupem a co přesně je výsledkem měření. Interpretace přínosu jednotlivých metrik patří až do kapitoly 5.

3.2.1 Procesní metriky (P1–P8)

Procesní metriky (Fenton & Bieman, 2014) měří *jak* agent pracuje. Instrukce v `AGENTS.md` definují strukturovaný vývojový postup: agent má odvozovat práci ze specifikace, organizovat ji přes issues a branches, psát testy před implementací a dokumentovat rozhodnutí v commit messages a PR descriptions.

P1–P5: compliance (binární)

P1 (issues before code) ověřuje, zda agent vytvořil issues s timestampem před prvním kódovým commitem. Měříme porovnáním `created_at` nejstaršího agentova issue (GitHub API) s časem prvního commitu obsahujícího soubory v `src/` nebo `tests/`.

P2 (branch per issue) ověřuje, zda agent vytvořil pro každé issue vlastní větev. Měříme počet remote branches (bez `main`) vůči počtu issues: podmínka $branches \geq issues$ je splněna tehdy, nenastalo-li slučování více issues do jedné větve.

P3 (test-first commits) ověřuje, zda agent psal testy před implementací. Primární indikátor: existuje alespoň jeden commit s prefixem `test:` a zároveň alespoň jeden `feat:`. Přesnější měření poskytuje behavioral trace (sekce 3.3.3): počet větví, kde první zápis do `src/` předcházela prvnímu zápisu do `tests/` (`tddOrderViolations`).

P4 (PRs linked to issues) ověřuje, zda každý PR obsahuje odkaz na issue. GitHub API vrací tělo PR. Podmínka: všechna PR těla obsahují regex `Closes #N`.

P5 (no existing test modifications) ověřuje, že agent nepřepisoval již existující testové soubory. Metrika zachycuje `modified` změny (`--diff-filter=M`) na testovacích souborech, tedy situaci kdy agent dříve vytvořený test později upraví místo toho, aby opravil implementaci. Nově přidané testy se do P5 nezapočítávají.

P6–P8: kvalita procesních artefaktů (LLM-as-judge)

P6 (commit message quality) hodnotí popisnost commit messages: atomicitu, konvenční prefix a srozumitelnost co a proč bylo změněno. Hodnocení provádí LLM-as-judge na škále 1–3 (sekce 3.2.4).

P7 (issue description quality) hodnotí popisnost issue descriptions: jasnost scope, přítomnost acceptance criteria, dostatečnost pro implementaci. Hodnocení provádí LLM-as-judge na škále 1–3.

P8 (PR description quality) hodnotí popisnost PR descriptions: přítomnost odkazu na issue, popis co a proč, dostatečnost pro code review. Hodnocení provádí LLM-as-judge na škále 1–3.

3.2.2 Produktové metriky (Q1–Q8)

Produktové metriky (Fenton & Bieman, 2014) měří *co* agent vyrobil. Pokrývají tři oblasti: funguje implementace správně (Q1–Q2), detekují agentovy testy skutečné chyby (Q3–Q4) a je kód udržitelný (Q5–Q8).

Funkční korektnost (Q1–Q2)

Q1 (API contract match) ověřuje, zda agentův kód dodržuje definované rozhraní. Referenční typy se importují a zkompilují proti agentovu kódu (`tsc`). Výsledek je binární: typy sedí, nebo ne. Q1 je vstupní podmínkou pro Q2: pokud agentův kód neimplementuje správné API, referenční testy nelze ani zkompilovat, a výsledek Q2 by byl nesmyslný.

Q2 (referenční test pass rate) měří kolik z referenčních testů projde na agentově implementaci. Vitest spustí 42 testů proti agentovu kódu. Výsledek je počet passing testů z 42. Testy ověřují chování přes veřejné API (black-box, sekce 2.1.2), takže je lze spustit na libovolném běhu nezávisle na interní struktuře. Konstrukce referenční test suite popisuje sekce 4.1.2.

Kvalita testů (Q3–Q4)

Q3 (mutation score) měří, jestli agentovy testy skutečně detekují chyby (sekce 2.1.2). Stryker s konfigurací `--mutate 'src/**/*.ts'` a mutátory pro TypeScript (conditional, arithmetic, string, logical operators) systematicky zavádí drobné změny do zdrojového kódu. Vstup: agentovy testy + zdrojový kód. Výstup: procento zabitých mutantů z celkového počtu.

Q4 (AC coverage) měří, kolik akceptačních kritérií ze specifikace má odpovídající test v agentově test suite. Na rozdíl od Q2 (funguje implementace?) se Q4 ptá, jestli agent *testoval všechno co měl*. Specifikace obsahuje 25 acceptance criteria. Historicky uložené judge běhy byly exportovány ve 24bodovém formátu. Při finalizaci práce byl chybějící bod AC25 (*custom holiday calendar*) dopočítán manuálně. V textu proto Q4 uvádíme na škále N/25. Hodnocení provádí LLM-as-judge (sekce 3.2.4) doplněné o toto manuální ověření.

Kvalita kódu (Q5–Q8)

Q5 (lint warnings) počítá varování a chyby z ESLint s fixní konfigurací (pravidla: recommended + strict TypeScript rules). Konfigurace je součástí experimentální infrastruktury, ne agentova repo. Agent ji nemůže měnit. Výstup: celkový počet warnings + errors.

Q6 (typecheck errors) počítá chyby z `tsc --noEmit` ve strict mode. Doplnuje počet explicitních `any` ve zdrojových souborech (grep v `src/**/*.ts`) jako proxy pro obcházení typového systému.

Q7 (složitost kódu) měří cyklomatickou složitost per funkce. ESLint `complexity` rule reportuje funkce překračující nastavený práh. Výstup: maximální složitost across all functions. Prah ≤ 10 per funkce vychází z McCabe (sekce 2.1.2).

Q8 (design quality) hodnotí aspekty které automatizované nástroje nezachytí: pojmenování, oddělení zodpovědností, idiomatický TypeScript, kvalita dokumentace a zbytečná komplexita. Hodnocení provádí LLM-as-judge (sekce 3.2.4). Celkové skóre Q8 je *minimum* pěti dimenzí,

nikoliv průměr. Volba minima je záměrná: jeden slabý rozměr má stáhnout celkový výsledek dolů, aby slabiny nebyly maskované silnými dimenzemi.

3.2.3 Metriky efektivity (E1–E3)

Metriky efektivity měří zdroje spotřebované při vývoji. Nemají exit kritérium a slouží k porovnání nákladů mezi iteracemi.

E1 (vstup/výstup/cache tokeny) zaznamenává tři komplementární hodnoty z exportu `transcript.json`: maximální vstup na jednom kroku včetně cache, součet výstupních tokenů a součet cache tokenů přes kroky. Všechny tři složky uvádíme v tisících. Toto rozdělení umožňuje odlišit šířku promptu, objem generování a cenu opakovaného čtení kontextu. Sledování objemu tokenů motivuje zjištění Gloaguen et al. (Gloaguen et al., 2025), že context files zvyšují inference cost o více než 20 %.

E2 (trvání) měří wall-clock time v minutách od spuštění agenta po poslední commit.

E3 (stabilita session) sleduje stabilitu session ve třech signálech: zda běh dokončil, kolik kompakcí kontextu nastalo a kolikrát auto-continue plugin session restartoval. Počet kompakcí odvozujeme heuristicky z exportu a počet restartů z `metrics.csv`. Na této úloze jde o pomocnou záznamovou metriku, která má zachytit zjevné kolapsy kontinuity práce mezi kroky.

Se dvěma běhy per variaci jsou tyto hodnoty deskriptivní, ne inferenční.

3.2.4 Aplikace LLM-as-judge

Pět metrik (P6, P7, P8, Q4, Q8) hodnotí vlastnosti které nelze extrahovat automatizovaným nástrojem. Pro jejich hodnocení používáme metodu LLM-as-judge (sekce 2.2.4).

Volba modelu. Jako judge používáme GLM-5 (Zhipu AI). Agentní běhy provádí model MiniMax-M2.5; judge je tedy z jiné modelové rodiny. Důvod: model má tendenci hodnotit výstupy svého vlastního druhu lépe, i když jsou objektivně slabší (self-preference bias (Pannickssery et al., 2024)). Volba judge z jiné modelové rodiny než agent tento bias snižuje (Verga et al., 2024).

Škála. Hodnocení probíhá na škále 1–3 per dimenze: 1 = nevyhovující, 2 = přijatelné, 3 = dobré. Jemnější škály (1–5, 1–10) produkují při malém počtu hodnocených artefaktů nižší shodu mezi hodnotiteli (Zheng et al., 2023); třístupňová škála je pro tento rozsah spolehlivější.

Rubrika. Judge dostane artefakty agentova běhu (zdrojový kód, commit messages, issue a PR descriptions) spolu s rubrikou obsahující popis každého stupně. Dimenze per metriku jsou popsány při definici metrik (P6–P8 v sekci 3.2.1, Q4 a Q8 v sekci 3.2.2). Kompletní

formulace rubrik a promptu je v příloze. Prompt je fixní napříč všemi běhy, aby hodnocení bylo srovnatelné mezi iteracemi.

Interpretace výsledků. LLM-as-judge zde neslouží jako plně objektivní měření, ale jako strukturované posouzení vlastností, které nelze spolehlivě vyhodnotit deterministickým skriptem. Výsledky těchto metrik proto interpretujeme jako podpůrné kvalitativní indikátory a ne jako hlavní důkazní osu případové studie.

3.3 Experimentální design

3.3.1 Výběr projektu

Případová studie potřebuje projekt, na kterém lze opakovaně spouštět agenta s různými instrukcemi a objektivně měřit výsledky. Projekt musí mít deterministickou logiku (stejný vstup vždy dá stejný výstup), aby bylo možné ověřit korektnost automatizovanými testy a mutation testingem. Zároveň musí být dostatečně malý pro více experimentálních běhů, ale obsahovat reálné nuance (hraniční případy, doménová pravidla), aby měl agent co řešit.

Zvolili jsme systém upomínek faktur: systém pro automatické odesílání připomínek k nezaplaceným fakturám. Obsahuje stavový automat (nová, po splatnosti, upomínaná, eskalovaná), časové výpočty (pracovní dny, ochranné lhůty) a pravidla pro eskalaci. Specifikace definuje 25 acceptance criteria, API kontrakt (TypeScript typy a signatury) a doménový slovník. Systém zde neplní roli hlavního výsledku práce, ale testovacího prostředí, na němž lze měřit chování agenta. Tato kombinace deterministické logiky a hraničních případů (víkendy, svátky, grace periods) umožňuje objektivně testovat jak funkční korektnost (Q1, Q2), tak kvalitu testů (Q3, Q4).

Současně jde o úlohu, která je dostatečně bohatá na netriviální rozhodování, ale stále zvládnutelná pro opakované běhy. Agent musí správně kombinovat stavové přechody, časové výpočty a testování hraničních případů, takže metriky zachycují více než jen průchod jednoduchou CRUD implementací.

3.3.2 Fixní proměnné

Aby bylo možné měřit vliv instrukcí, musí být všechno ostatní co nejstabilnější. Hlavní měněnou proměnnou mezi běhy je obsah souboru `AGENTS.md`, tedy procedurálních instrukcí, které definují pracovní postup, omezení a quality gates. Tento design negarantuje dokonalou izolaci všech vlivů; jeho cílem je omezit zjevné vedlejší vstupy a udělat jejich případný vliv auditovatelný. Na rozdíl od generických context files, které typicky popisují adresářovou strukturu a build příkazy (Gloaguen et al., 2025), jde o fokusované instrukce s konkrétními procedurami (X. Li et al., 2025).

Fixní proměnné jsou:

Prázdné GitHub repo obsahuje pouze `AGENTS.md`, konfiguraci agenta a `auto-continue` plugin. Žádný existující kód, testy ani `package.json`. Agent musí inicializovat projekt a zvolit strukturu sám.

Specifikace v GitHub Issue #1 obsahuje 25 acceptance criteria, API kontrakt (TypeScript typy a signatury), doménový slovník a out of scope. Je to hlavní věcný vstup, který agent dostane kromě instrukcí.

Auto-continue plugin je hook který detekuje kdy se agent zastaví a automaticky ho restartuje. Počítadlo restartů a kontrola otevřených issues zajišťují běh bez manuálního zásahu. Metrika E3 z toho čerpá.


Model MiniMax-M2.5 byl zvolen jako model schopný autonomně dokončit zadaný úkol. Cílem práce je vyhodnotit sadu metrik a iterativní postup, ne srovnávat výkon modelů — volba konkrétního modelu je v tomto ohledu sekundární. MiniMax-M2.5 je zároveň z jiné modelové rodiny než judge (GLM-5, Zhipu AI), čímž se eliminuje self-preference bias (sekce 2.2.4). Teplota modelu nebyla mezi běhy explicitně nastavena. Agent běžel s výchozí konfigurací poskytovatele. Dopad této volby na variabilitu výsledků diskutuje sekce 5.3.

Běhové prostředí (Docker container) zajišťuje, že agent nemá přístup ke globální konfiguraci nástroje, MCP serverům ani rozšířením nainstalovaným na hostitelském systému. Izolace tím významně omezuje vliv vedlejších vstupů z prostředí, ale nevyklučuje všechny zdroje variability. Sdílený autentizační svazek zajišťuje konzistentní přístup k API napříč běhy.

System prompt agenta (`build.md`) nahrazuje výchozí system prompt nástroje OpenCode, jehož instrukce o verzování konfliktovaly s procesními požadavky případové studie. Vlastní system prompt obsahuje pouze obecné kódové konvence (styl, bezpečnost, zákaz komentářů) a odkaz na `AGENTS.md`. Veškeré procesní instrukce jsou výhradně v `AGENTS.md`, aby bylo možné změny procesního chování přisuzovat této vrstvě obhajitelněji než při jejich rozptýlení mezi více vstupů.

3.3.3 Iterativní cyklus

Pilotní fáze postupuje opakováním čtyřkrokového cyklu, dokud agent nesplní exit kritéria. Každý průchod cyklem je jedna experimentální iterace — vstupem je aktuální verze `AGENTS.md`, výstupem upravená verze pro příští běh.



Spuštění. Skript `new-run.ts` připraví izolované prostředí: vytvoří prázdné GitHub repo,

zkopíruje aktuální `AGENTS.md`, vytvoří Issue #1 se specifikací a spustí agenta v Docker kontejneru. Agent dostane výhradně prázdné repo, instrukce a specifikaci — žádný existující kód ani závislosti. Po dokončení se exportuje session transcript (`transcript.json`).

Měření. Skript `analyze-run.ts` extrahuje deterministické metriky automaticky: git log a GitHub API (P1), výstup Vitest a Stryker (Q2, Q3), statická analýza (Q5–Q7), session metadata (E1–E3). Kvalitativní metriky (P6, P7, P8, Q4, Q8) hodnotí LLM-as-judge GLM-5 podle fixní rubriky (sekce 3.2.4). Výstupem je `FINDINGS.md` s tabulkou metrik a faktickým popisem chování agenta.

Diagnóza. Z naměřených hodnot a behaviorálního popisu se identifikuje kde a proč agent nedodržel očekávané chování. Analýza postupuje podle čtyř rámců:

- Mao et al. (Mao et al., 2025) — která složka instrukcí selhala a proč
- Hassan et al. (Hassan et al., 2025) — zda obsah vyvažuje proceduru, kontext a omezení
- Lulla et al. (Lulla et al., 2026) — zda každý řádek přidává hodnotu
- Razavi, Breunig (Breunig, 2025; Razavi & Fard, 2025) — proč agent instrukci opakovaně ignoruje

Diagnóza probíhá ve třech navazujících krocích. Nejprve se z tabulky metrik vyberou nesplněné nebo hraniční hodnoty. Poté se pro každou z nich dohledají faktické projevy ve `FINDINGS.md` a v odpovídajících artefaktech (git log, issues, PR, transcript, výstupy nástrojů), aby bylo možné odlišit jednorázové selhání běhu od opakujícího se problému instrukcí. Nakonec se příčina klasifikuje jako chybějící instrukce, příliš obecná instrukce, konflikt mezi instrukcemi nebo instrukce ignorovaná bez verifikačního kroku. Z této klasifikace plyne typ opravy (doplnění, zpřesnění, přestrukturování nebo přidání verifikačního kroku). Pořadí aplikace rámců se řídí právě touto klasifikací: chybějící nebo obecná složka vede k analýze komponent podle Mao et al., konflikt mezi typy obsahu k posouzení balance podle Hassan et al., opakovaně ignorovaná instrukce k Razavi a Breunig (proč nepůsobí a jak přestrukturovat). Audit redundance podle Lulla et al. slouží napříč jako kontrola, zda každý řádek instrukcí nese hodnotu.

V tomto kroku byl průběžně využíván nástroj Claude (Anthropic) jako analytický asistent: výzkumník formuloval hypotézy o příčinách selhání a AI asistent navrhoval literaturou podložené interpretace a varianty úprav. Finální rozhodnutí o každé změně `AGENTS.md` však vždy činil výzkumník.

Výstupem je `DIAGNOSIS.md` s identifikovanými příčinami a návrhem změn.

Úprava. Na základě diagnózy se upraví `AGENTS.md`. Každá změna odpovídá jednomu identifikovanému problému, je podložena citací a zaznamenána v changelogu — aby bylo zpětně dohledatelné proč daná úprava vznikla a co měla opravit. Přestrukturování instrukcí je preferováno před jejich rozšiřováním: redundantní obsah zvyšuje inference cost bez přínosu k úspěšnosti (Gloaguen et al., 2025) a fokusované instrukce překonávají vyčerpávající dokumentaci (X. Li et al., 2025).

3.3.4 Pilotní fáze

Pilotní fáze běží dokud agent nesplní exit kritéria ze sloupce *Exit kritérium* v tabulce 3.1. Kritéria dělíme do tří skupin. Tvrdá deterministická kritéria (P1–P5, Q1, Q2, Q5, Q6) mají přirozenou hranici splněno/nesplněno. Prahové deterministické metriky (Q3, Q7) používají minimum odvozené z literatury a praxe. Judge-based metriky (P6–P8, Q4, Q8) slouží jako podpůrné kvalitativní indikátory. E1–E3 jsou záznamové metriky bez exit kritéria a slouží k porovnání efektivity mezi běhy.

S ohledem na scope práce (jeden projekt, jeden model) definujeme úspěšný běh jako dokončení bez manuálního zásahu, při kterém agent splnil všechna tvrdá deterministická kritéria (P1–P5, Q1, Q2, Q5, Q6) a překročil prahy prahových metrik ($Q3 \geq 70\%$, $Q7 \leq 10$ na funkci). Judge-based metriky u tohoto běhu nesmí současně klesnout pod baseline. Pilotní fáze končí, jakmile takový běh nastane a vykáže prokazatelné zlepšení oproti baseline. Tím se ukazuje proveditelnost postupu na jednom případě; neimplikuje to, že zvolené prahy obecně platí pro všechny agenty a projekty. Každá iterace produkuje aktualizovaný `AGENTS.md`, záznam změn se zdůvodněním a kompletní P/Q/E metriky.

3.3.5 Komparativní variace

Z fungující sady instrukcí (výstup pilotní fáze) systematicky odebíráme jednotlivé složky a měříme dopad na chování agenta. Tento postup, ablace, odpovídá na otázku: potřebuje agent danou část instrukcí, nebo je redundantní?

Konkrétní variace nelze specifikovat předem. Pilotní fáze *generuje* hypotézy o tom, které složky instrukcí jsou pro chování agenta podstatné, a komparativní fáze je testuje. Výběr variací vychází z diagnostiky pilotních běhů (sekce 3.3.4): pokud se v pilotu ukáže, že agent konzistentně nedodržuje určité pravidlo, ablace může testovat, zda jeho odebrání změní i ostatní metriky. Podobně pokud určitá sekce instrukcí koreluje s vysokou kvalitou výstupu, ablace ověří, zda je tento vztah kauzální.

Každá ablace se provádí ve dvou nezávislých bězích se stejným nastavením, aby bylo možné odlišit systematický efekt změny od přirozené variability nedeterministického modelu. I se dvěma běhy nelze dosáhnout statistické průkaznosti (sekce 3.5). Výsledky komparativní fáze proto interpretujeme jako indikativní, nikoliv kauzální.

3.4 Přehledová tabulka

Tabulka 3.1 shrnuje všechny metriky na jednom místě. Sloupec *typ* rozlišuje deterministická exit kritéria (automatizované měření), judge-based metriky (rubrikové hodnocení LLM-as-judge) a záznamové metriky (bez kritéria, slouží k porovnání mezi běhy). Prahové požadavky

jsou uvedeny ve sloupci *Exit kritérium*. Způsob sběru odpovídá rozlišení deterministické metriky, kvalitativní metriky a záznamové metriky zavedenému v kapitole 2.

Tabulka 3.1: Sada metrik: kód, měřená vlastnost, nástroj, exit kritérium a typ

Kód	Metrika	Nástroj	Exit kritérium	Typ
<i>Procesní (P): jak agent pracuje</i>				
P1	Issues before code	git, GitHub API	pass	deter.
P2	Branch per issue	git, GitHub API	pass	deter.
P3	Test-first commits	git log	pass	deter.
P4	PRs linked to issues	GitHub API	pass	deter.
P5	No existing test modifications	git diff	pass	deter.
P6	Commit message quality	LLM-as-judge (GLM-5)	$\geq 2/3$	judge
P7	Issue description quality	LLM-as-judge (GLM-5)	$\geq 2/3$	judge
P8	PR description quality	LLM-as-judge (GLM-5)	$\geq 2/3$	judge
<i>Produktové (Q): co agent vyrobil</i>				
Q1	API contract match	tsc (import + typecheck)	match	deter.
Q2	Referenční test pass rate	Vitest (42 testů)	42/42	deter.
Q3	Mutation score	Stryker	$\geq 70\%$	min.
Q4	AC coverage agentových testů (25 krit.)	LLM-as-judge (GLM-5)	25/25	judge
Q5	Lint warnings	ESLint	0	deter.
Q6	Typecheck errors	tsc --noEmit	0	deter.
Q7	Cykломatická složitost	ESLint (complexity)	$\leq 10/\text{fn}$	min.
Q8	Design quality	LLM-as-judge (GLM-5)	$\geq 2/3$	judge
<i>Efektivita (E): za jakou cenu</i>				
E1	Vstup / výstup / Σ cache (tis.) z exportu	OpenCode export	—	záznam
E2	Trvání (minuty)	session timestamps	—	záznam
E3	Stabilita session (kompakce + dokončení + restarty)	transcript + metrics.csv	—	záznam

3.5 Omezení a validita

Každý výzkumný design má omezení. Následující analýza vychází z kategorizace Runeson a Höst (Runeson & Höst, 2009).

Tato sekce deklaruje hrozby validity, které jsou dané designem studie a známe je předem. Jak se tyto hrozby skutečně projeví v naměřených datech, diskutuje sekce 5.3.

Konstruktová validita (měříme to, co chceme měřit?). Jednotlivé metriky vychází z existující teorie: mutation testing (Papadakis et al., 2019), cykломatická složitost (McCabe, 1976), taxonomie procesních a produktových metrik (Fenton & Bieman, 2014). Konkrétní kombinace metrik do sady a volba exit kritérií jsou autorské a představují návrh, ne ověřený standard. Pět metrik (P6, P7, P8, Q4, Q8) obsahuje subjektivní složku (LLM-as-judge). Tyto metriky proto slouží jako podpůrné kvalitativní indikátory, zatímco hlavní opora vyhodnocení stojí na deterministických metrikách a auditovatelných artefaktech. Spolehlivost LLM-as-judge nebyla validována proti lidskému hodnocení (např. Cohenovým κ) z důvodu časových omezení.

Případová studie rozlišuje dva druhy testů: referenční testy (měřené metrikou Q2, spouštěné po běhu skriptem, agentovi neviditelné) a agentovy vlastní testy (psané agentem během běhu, viditelné a spustitelné agentem). Metrika P5 se vztahuje výhradně k agentovým vlastním testům. Referenční testy jsou odvozeny ze specifikace metodou TDD (Mathews & Nagappan, 2024), čímž se snižuje riziko test oracle problému. Správnost skriptu `analyze-run.ts` pro metriky P1–P5 byla ověřena manuálním srovnáním výstupů s raw daty z git logu a GitHub API pro běhy r4 a r5. Žádná diskrepance nebyla identifikována.

Interní validita (jsou závěry podložené daty?). Hlavní hrozba je nedeterminismus LLM: stejné instrukce mohou při různých bžích dát různé výsledky (Razavi & Fard, 2025). Dva běhy per variaci jsou mitigací, ale neposkytují statistickou sílu. Další hrozbou je confirmation bias: autor navrhuje instrukce i evaluuje výsledky. Tuto hrozbu oslabují automatizované metriky (P1, Q1–Q3, Q5–Q7), které nepodléhají subjektivnímu posouzení, a volba judge modelu z jiné rodiny. Mitigací je také auditovatelný řetězec rozhodnutí (changelog per iterace, korekční poznámky v `FINDINGS.md`) a oddělení měřicí infrastruktury od agentova prostředí.

Externí validita (lze zobecnit?). Případová studie na jednom projektu, jednom modelu a jednom agentním nástroji neumožňuje statistickou generalizaci. Yin (R. K. Yin, 2018) pro tento typ výzkumu rozlišuje analytickou generalizaci: z jednoho případu lze ukázat principy, ne statistické zákonitosti. Systém upomínek má deterministickou logiku a výsledky nemusí platit pro projekty s uživatelským rozhraním, strojovým učením nebo nedeterministickými výstupy. Přenositelné jsou metriky a postup (kdokoliv je může použít na svém projektu), konkrétní naměřené hodnoty a instrukce platí pro tuto studii.

Výzkum nezahrnuje lidské účastníky. Veškerá data (git log, metriky, session transcripts) jsou generována experimentální infrastrukturou. Zdrojový kód a experimentální data jsou veřejně dostupná.

Pro transparentnost je třeba doplnit, že při přípravě textu, vyhledávání literatury a podpůrné diagnostické analýze byl průběžně využíván nástroj Claude (Anthropic). Výzkumný design, volba metrik, experimentální rozhodnutí i interpretace výsledků jsou autorovy vlastní. Generovaný obsah byl vždy autorem posouzen a upraven. Podrobný popis využití AI uvádí příloha D.

4. Praktická část

Tato kapitola popisuje provedení případové studie. Struktura sleduje chronologii experimentu: nejprve příprava tří výchozích podkladů (specifikace, referenční implementace, instrukce), pak pilotní fázi kde se instrukce opakovaně upravují na základě naměřených metrik, a nakonec komparativní variace kde z fungující sady systematicky odebíráme jednotlivé části a měříme dopad. Kapitola tím přímo navazuje na metodiku z kapitoly 3: neobhazuje znovu volbu metrik ani design studie, ale ukazuje, jak se navržený postup projevil v konkrétních bězích a jaká data při tom vznikla.

4.1 Příprava experimentu

Před spuštěním pilotních běhů bylo nutné připravit tři výchozí podklady každého experimentálního běhu: specifikaci projektu (co má agent implementovat), referenční implementaci (měřicí nástroj pro Q2 – referenční test pass rate) a baseline instrukce (jak má agent pracovat).

4.1.1 Konstrukce specifikace

Specifikace definuje fixní zadání, které agent dostává v Issue #1. Navazuje na metodické vymezení fixních vstupů v sekci 3.3: kromě instrukcí v souboru `AGENTS.md` agent pracuje právě s touto specifikací a žádný další architektonický návrh nedostává. Issue má dvě části: **Requirements** (co business potřebuje) a **API Contract** (co musí implementace exportovat). API kontrakt je současně jediným technickým omezením implementace a vstupem pro metriku Q1 (API contract match).

Specifikace obsahuje:

- **25 acceptance criteria** ve formátu Given/When/Then s konkrétními hodnotami: eskalační flow (8 stavových přechodů), platby, terminální stavy, pause/resume, manuální advance, konfigurovatelné timeouty, výpočet pracovních dní
- **API kontrakt** v TypeScriptu: veřejná funkce `process(state, event, now)` vracející nový stav a action descriptory; typy pro 12 stavů, 6 událostí, 3 typy akcí; konfigurační interface pro timeouty a svátky
- **Doménový slovník**: 9 pojmů definujících business doménu (dunning, grace period, business days, action descriptor aj.)
- **Out of scope**: 6 explicitně vyloučených oblastí (payment retry, late fees, partial payments, email sending, scheduling, persistence)

Specifikace je záměrně stručná a strukturovaná, aby omezovala interpretační volnost agenta a současně zůstala přímo měřitelná. Formát Given/When/Then usnadňuje převod požadavků do referenčních testů (Q2 (referenční test pass rate)) i mapování acceptance criteria na agentem

vytvořené testy (Q4 (AC coverage)). Systém je definován jako pure function `process(state, event, now)`, takže stejné deterministické rozhraní lze použít napříč všemi běhy pro referenční testy Q2 i mutation testing Q3. Explicitní sekce out of scope navíc omezuje riziko, že agent rozšíří řešení nad rámec sledovaného zadání.

4.1.2 Referenční implementace

Referenční implementace slouží jako měřicí nástroj: definuje strop kvality proti kterému se porovnávají agentovy běhy. Její role v metrikách popisuje sekce 3.2.2.

Testy byly napsány metodou *spec-first TDD* (sekce 2.1.2): expected values pochází ze specifikace, ne z pozorování kódu.

Výsledná implementace obsahuje 42 behavioral testů pokrývajících všech 25 acceptance criteria (některá kritéria vyžadují více testových případů pro hraniční situace), dosahuje mutation score 91,9 %. Kód kompiluje bez typecheck errors, neobsahuje žádné `any` a má 3 lint warnings (kosmetické, bez vlivu na funkční korektnost). Metrika Q8 (design quality) ohodnotila design quality na 3/3 ve všech dimenzích. Tyto výsledky validují, že specifikace je implementovatelná a že exit kritéria (sekce 3.3.4) jsou dosažitelná lidským vývojářem.

4.1.3 Konstrukce baseline instrukcí

Baseline verze `AGENTS.md` byla konstruována čistě z literatury. Cílem bylo vytvořit výchozí bod jehož každá komponenta má opodstatnění v empirických zjištěních. Literatura společně naznačuje, že výchozí instrukční soubor musí spojit tři vrstvy: jasné vymezení úkolu, stručný procedurální pracovní postup a explicitní kontrolní kroky kvality. Mao et al. (Mao et al., 2025) poskytují kostru komponent, Li et al. (X. Li et al., 2025) ukazují vyšší účinnost procedurálních instrukcí než popisné dokumentace, Breunig et al. (Breunig, 2025) motivují převod obecných pravidel na konkrétní akce a Lulla et al. (Lulla et al., 2026) varují před přidáváním obsahu bez jasné hodnoty. Baseline proto nevznikla jako vyčerpávající manuál, ale jako kompaktní soubor instrukcí, jehož sekce se mapují na konkrétní měřené dimenze.

Konstrukce proběhla ve třech krocích: odstranění předchozí ad-hoc verze, návrh struktury podle pořadí komponent popsanych Mao et al. (Mao et al., 2025) a mapování tří dimenzí chování (sekce 3.2) na konkrétní instrukce. Výsledné sekce (Role, Goal, Specification, Environment, Process, Package Quality, Constraints) jsou adaptací tohoto rámce na doménu případové studie.

Procesní sekce obsahuje stručné instrukce pro spec-first TDD (Mathews & Nagappan, 2024), dekompozici do sub-issues, branch-per-issue a conventional commits. Sekce Package Quality vymezuje očekávání na modularitu, striktní typování, dokumentaci a čisté veřejné API. Tyto požadavky přímo míří na metriky kvality kódu (Q5 (lint warnings)–Q8 (design quality)). Sekce byla přidána proto, že udržitelnost a design nejsou ve specifikaci projektu explicitně

vynutitelné, ale v naší sadě metrik je chceme sledovat. Nejde tedy o tvrzení, že “architektura + konvence” jsou obecně neúčinnější obsah instrukcí, ale o operacionalizaci požadavků na kvalitu do podoby, kterou lze v této případové studii měřit. Sekce Constraints pak obsahuje explicitní zákazy typu nekombinovat issues, nemodifikovat existující testy a nepřepisovat git historii. Výsledný dokument má 53 řádků a ~350 slov.

Tabulka 4.1 ukazuje mapování jednotlivých sekcí na metriky a obrázek 4.1 uvádí kompletní znění.

```
Baseline AGENTS.md

# AGENTS.md --- Dunning System

## Role

You are a senior TypeScript developer building a production-grade npm package. You prioritize clean architecture,
spec compliance, and test quality.

## Goal

Implement the dunning system (billing reminder state machine) specified in GitHub Issue #1. Deliver a modular,
documented, publishable TypeScript package.

## Specification

Read Issue #1 completely before writing any code. It contains:
- **Acceptance Criteria** --- every one must be satisfied and tested
- **API Contract** --- exact TypeScript signatures to export
- **Domain Glossary** --- use these terms in code and documentation
- **Out of Scope** --- do not implement

All design decisions must trace back to the spec. Do not invent requirements.

## Environment

- Runtime: Node.js, TypeScript (strict mode, ESM)
- Test runner: Vitest
- Build: tsc
- Tools: GitHub CLI (`gh`), Git

## Process

Decompose the spec into focused GitHub issues before writing code. Work through them sequentially:

1. Create issues --- one concern per issue, starting with project setup
2. For each issue: branch from main, write tests first, implement, PR with "Closes #N", merge
3. Use conventional commits: `test:` for tests, `feat:` for implementation, `docs:` for documentation
4. Run `tsc --noEmit` before every PR --- no type errors allowed

## Package Quality

Structure the code as a production-grade npm package:

- **Modular architecture** --- separate files for types, business logic, utilities, and public API re-exports. No
single-file implementations.
- **Strict TypeScript** --- no `any`, explicit return types on public API, `readonly` where applicable.
- **Documentation** --- JSDoc on all exported functions and types. Inline comments for non-obvious domain logic
(e.g., business day calculations, escalation thresholds).
- **Clean API surface** --- `src/index.ts` re-exports only the public API. Internal modules are not exposed.

## Constraints

- Never combine multiple issues into one branch.
- Never implement without a failing test first.
- Never modify a test to match your implementation. Tests encode the spec --- fix the code, not the test.
- Never rewrite git history (no amend, squash, rebase, force-push).
- Do not add dependencies beyond the dev toolchain (vitest, typescript).
```

Obrázek 4.1: Baseline AGENTS.md (pilot-r1): kompletní znění instrukcí použitých jako výchozí bod pilotních iterací.

Tabulka 4.1: Mapování sekcí baseline `AGENTS.md` na metriky

Cíl	Sekce <code>AGENTS.md</code>	Metriky
Spec-first	Specification, Process krok 2	P1
Strukturovaný workflow	Process kroky 1–4	P2, P3, P4
TDD	Process krok 2, Constraints	P3, P5
Modulární kód	Package Quality	Q5, Q7, Q8
API kompatibilita	Specification (API Contract)	Q1
Funkční korektnost	Specification (AC)	Q2, Q4

Specifikace, referenční implementace a baseline instrukce tvoří výchozí bod experimentu. Následující sekce popisuje průběh pilotních iterací cyklem Spuštění/Měření/Diagnóza/Úprava (sekce 3.3.4).

4.2 Pilotní fáze

Každá iterace sleduje cyklus Spuštění/Měření/Diagnóza/Úprava (sekce 3.3.4). U prvního běhu (baseline) uvádíme kompletní tabulku metrik a podrobnou diagnostiku. U dalších běhů popisujeme pouze změny oproti předchozí iteraci. Souhrnný přehled všech běhů obsahuje sekce 4.4.

4.2.1 Pilot-r1: baseline

První běh s baseline instrukcemi (příloha C), agent MiniMax-M2.5 přes OpenCode, proběhl v jedné session bez restartů. Tabulka 4.2 shrnuje naměřené metriky.

Ze 10 deterministických metrik splnil agent 4 (P1, P4, Q1, Q6).

Chování agenta.

Agent vytvořil 11 GitHub issues a rozložil implementaci do 4 pull requestů, každý s vlastní branch. Zvolil modulární strukturu (4 soubory: `types.ts`, `businessDays.ts`, `dunning.ts`, `index.ts`), což odpovídá požadavkům sekce Package Quality v instrukcích. Napsal 59 vlastních testů, všechny procházejí.

Diagnostika.

Tři procesní metriky z pěti nebyly splněny: agent sloučil 11 issues do 4 branches (P2), nepoužil oddělené commity pro testy a kód (P3) a upravil vlastní test aby seděl na implementaci (P5).

Tabulka 4.2: Pilot-r1: naměřené metriky

Kód	Metrika	Hodnota	Kritérium	Splněno?
P1	Issues before code	✓	splněno	✓
P2	Branch per issue	×	branches $\geq$ issues	×
P3	Test-first commits	×	test: před feat:	×
P4	PRs linked to issues	✓	všechny PR	✓
P5	Existující testy nezměněny	×	0 změn	×
P6	Commit msg quality	n/a	$\geq 2/3$	n/a
P7	Issue quality	3/3	$\geq 2/3$	✓
P8	PR quality	2/3	$\geq 2/3$	✓
Q1	API contract match	match	match	✓
Q2	Ref. test pass rate	39/42	42/42	×
Q3	Mutation score	84 %	≥ 70 %	✓
Q4	AC coverage (agentovy testy)	23/25	25/25	×
Q5	Lint warnings	2	0	×
Q6	Typecheck errors	0	0	✓
Q7	Složitost kódu	2 viol.	0 viol.	×
Q8	Design quality	1/3	$\geq 2/3$	×
E1	Vstup / výstup / Σ cache (tis.)	115 / 60 / 11528	—	záznam
E2	Trvání	32,7 min	—	záznam
E3	Stabilita session	dokončeno	—	záznam

Ve všech třech případech agent vybral rychlejší cestu místo té předepsané.

Z referenčních testů selhaly 3 z 42 (Q2), převážně v pause/resume logice a výpočtu pracovních dní. Q8 = 1/3 kvůli chybějící JSDoc dokumentaci na veřejném API. Ostatní dimenze dosáhly 3/3.

Změna instrukcí pro r2.

Čtyři selhání sdílela stejný vzorec: instrukce říkala *co* má platit, ale neukazovala *jak* to provést. Každé selhání proto dostalo konkrétní opravu v pracovním postupu:

- P2: na začátek každého cyklu přidán příkaz `git checkout -b issue-N`
- P3: testy a kód se nově odevzdávají odděleně, nejdřív `git add tests/`, pak `git add src/`
- P5: doplněno pravidlo, že selhávající test po implementaci se opravuje v kódu, ne přepisem testu
- Q7: přidána kontrola `npx eslint src/ --max-warnings 0` před otevřením pull requestu

Výřez `git diff` mezi verzemi `AGENTS.md` pro běhy r1 a r2 ukazuje rozsah těchto změn.

AGENTS.md: pilot-r1 -> pilot-r2

```

1. Create issues – one concern per issue, starting with project setup
2. For each issue: branch from main, write tests first, implement, PR with "Closes #N", merge
2. For each issue, follow this exact sequence:
  a. `git checkout main && git pull && git checkout -b issue-N` (one branch per issue, no exceptions)
  b. Write tests: `git add tests/ && git commit -m "test: <description>"`
  c. Implement: `git add src/ && git commit -m "feat: <description>"`
  d. Open PR: `gh pr create --title "..." --body "Closes #N"`, merge, delete branch
3. Use conventional commits: `test:` for tests, `feat:` for implementation, `docs:` for documentation
4. Run `tsc --noEmit` before every PR – no type errors allowed
4. Before every PR, run these checks and fix all issues before opening:
  - `tsc --noEmit` – zero type errors
  - `npx eslint src/ --max-warnings 0` – zero lint warnings (includes complexity violations)

## Package Quality
- Never combine multiple issues into one branch.
- Never implement without a failing test first.
- Never modify a test to match your implementation. Tests encode the spec – fix the code, not the test.
- Never modify a test to match your implementation. If a test fails after implementation, fix the code – not the test. Tests encode the spec.
- Never rewrite git history (no amend, squash, rebase, force-push).
- Do not add dependencies beyond the dev toolchain (vitest, typescript).

```

Obrázek 4.2: Vizuální diff změn AGENTS.md mezi pilot-r1 a pilot-r2

4.2.2 Pilot-r2

Druhý běh ověřoval čtyři změny instrukcí. Tabulka 4.3 ukazuje metriky kde došlo ke změně.

Tabulka 4.3: Pilot-r2: metriky s změnou oproti r1

Kód	Metrika	r1	r2	Trend
P5	Existující testy nezměněny	×	✓	opraveno
Q2	Ref. test pass rate	39/42	32/42	horší
Q3	Mutation score	84 %	68 %	pod prahem
Q5	Lint warnings	2	1	zlepšení
Q7	Složitost kódu	2 viol.	0	opraveno
Q8	Design quality	1/3	1/3	beze změny
E1	Vstup / výstup / Σ cache (tis.)	115 / 60 / 11528	76 / 41 / 3196	záznam
E2	Trvání	32,7 min	37,2 min	záznam

Diagnostika.

P5 a Q7 byly opraveny, ale P2 a P3 přetrvaly v jiné podobě než v r1: agent tentokrát testy a kód sloučil do jednoho commitu s prefixem `test:`. Formálně tedy dodržel konvenci názvu commitu, ale nesplnil její záměr. Q8 = 1/3 zůstala beze změny, protože samotný textový požadavek na JSDoc dokumentaci agent nepřiměl k ověření výsledku.

Q2 a Q3 se zároveň zhoršily (32/42 resp. 68 %). Agent napsal víc testů než v r1, ale horší kvality, pravděpodobně proto, že je vytvořil hromadně ze specifikace místo postupného test-fix


cyklu. E1 klesla na promptové i výstupní straně, ale pro rozhodnutí o další úpravě byla podstatná hlavně regrese v testování a dokumentaci.

Změna instrukcí pro r3.

Z r2 přetrvaly tři slabiny. Každá dostala vlastní opravu:

- P2: pracovní postup nově začíná příkazem `gh issue list -state open`
- P3: mezi commit s testy a commit s kódem přibyl kontrolní příkaz `git log -oneline -3`
- Q8: požadavek na JSDoc byl přesunut do kontrolního kroku před pull requestem, aby ho agent musel ověřit

Výřez `git diff` mezi verzemi `AGENTS.md` pro běhy r2 a r3 ukazuje rozsah těchto změn.



Obrázek 4.3: Vizuální diff změn `AGENTS.md` mezi pilot-r2 a pilot-r3

4.2.3 Pilot-r3

Třetí běh ověřoval tři změny instrukcí z r2: kontrolní příkaz po commitu s testy, výběr issue přes `gh issue list` a přesun požadavku na JSDoc do kontrolního kroku před pull requestem. Tabulka 4.4 ukazuje metriky s výraznou změnou.

Tabulka 4.4: Pilot-r3: metriky s změnou oproti r2

Kód	Metrika	r2	r3	Trend
P2	Branch per issue	×	✓	opraveno
P3	Test-first commity	×	✓	opraveno
P6	Kvalita commit zpráv	2/3	3/3	zlepšení
P7	Kvalita issue popisů	2/3	3/3	zlepšení
Q2	Ref. test pass rate	32/42	41/42	zlepšení
Q3	Mutation score	68 %	71 %	nad prahem
Q8	Design quality	1/3	3/3	průlom
E1	Vstup / výstup / Σ cache (tis.)	76 / 41 / 3196	62 / 30 / 4770	záznam
E2	Trvání	37,2 min	24,8 min	záznam
E3	Stabilita session	dokončeno	1 kompakce	záznam

Diagnostika.

Všechny tři změny zabraly. Agent poprvé splnil celý procesní checklist P1–P5 = 5/5: vytvořil issues před kódem, každý issue dostal vlastní branch, test commit předcházely kódu, pull requesty obsahovaly `Closes #N` a žádný test nebyl dodatečně upraven. Současně Q8 = 3/3 ukazuje, že přesun požadavku na JSDoc do kontrolního kroku vedl i k doplnění dokumentace.


Q2 = 41/42: zbývá jedna chyba v implementaci. Specifikace definuje chování pause/resume jednoznačně: acceptance criteria vyžadují “elapsed time are preserved” při pauzování a “timeout resumes from where it left off” při obnovení. API kontrakt navíc poskytuje pole `pausedElapsed` s komentářem “business days elapsed before pause”. Agent přesto zvolil vlastní přístup (posunutí `stateEnteredAt` zpět v čase) místo použití pole z kontraktu. Agentův přístup fungoval pro jedno pozastavení, ale selhal při opakovaném pause/resume. Spec není nejednoznačná. Agent učinil implementační rozhodnutí navzdory explicitnímu poli v kontraktu.

Změna instrukcí pro r4.

Diagnostika r3 odhalila dva problémy, každý s vlastní opravou:

- Procesní hygiena: do pre-PR checklistu přidán příkaz `npx vitest run`, aby agent ověřil, že jeho vlastní testy procházejí ještě před otevřením pull requestu
- Agent nedodržel API kontrakt: spec definuje pole `pausedElapsed` v typu `DunningState`, ale agent ho nepoužil a vymyslel vlastní řešení. Do Constraints přidáno pravidlo: každé pole v API kontraktu musí být v implementaci použito (Breunig, 2025)

Výřez `git diff` mezi verzemi `AGENTS.md` pro běhy r3 a r4 ukazuje obě změny: nová položka v pre-PR checklistu a nové pravidlo v Constraints.



Obrázek 4.4: Vizuální diff změn AGENTS.md mezi pilot-r3 a pilot-r4

4.2.4 Pilot-r4

Čtvrtý běh ověřoval dvě úpravy: přidání `npx vitest run` do pre-PR checklistu a pravidlo o dodržení API kontraktu (každé pole v typech musí být použito v implementaci). Tabulka 4.5 ukazuje metriky s nejvýraznější změnou.

Tabulka 4.5: Pilot-r4: metriky s změnou oproti r3

Kód	Metrika	r3	r4	Trend
P2	Branch per issue	✓	×	regrese
P5	Testy nezměněny	✓	×	regrese
Q2	Ref. test pass rate	41/42	39/42	horší
Q3	Mutation score	71 %	n/a	n/a
Q8	Design quality	3/3	2/3	horší
E1	Vstup / výstup / Σ cache (tis.)	62 / 30 / 4770	81 / 36 / 5996	záznam
E2	Trvání	24,8 min	25,9 min	stabilní
E3	Stabilita session	dokončeno	dokončeno	záznam

Diagnostika.

R4 je regrese oproti r3. Současně ale platí, že mezi běhy r3 a r4 se nezměnily jen instrukce: od r4 byla upravena i konfigurace modelu v Docker prostředí (sekce 5.3). Regresi proto nelze připsat výhradně dvěma novým řádkům v **Constraints**. Agent vytvořil 7 issues ale zpracoval jen 5. Dva issues zůstaly bez branch (P2 = 4/6). Upravil dva vlastní testové soubory po implementaci (P5).

Q2 se zhoršilo z 41/42 na 39/42: k přetrvávajícímu elapsed time bugu přibýly dvě nové chyby (výpočet víkendů v eskalaci a boundary DUE_SOON přechodu). Pravidlo o dodržení API kontraktu nepomohlo. Agent pole `pausedElapsed` opět nepoužil. Agentův vlastní test navíc obsahoval timezone bug a přesto agent mergoval kód, přestože pre-PR checklist zahrnoval `npx vitest run`.

Regrese ukázala dvě věci důležité pro další iteraci: samotné deklarativní pravidlo v `Constraints` zde neprokázalo zlepšení a instrukce na této úloze zůstávají citlivé na variabilitu mezi běhy. Zbývající selhání současně nebyla důsledkem nejednoznačné specifikace, ale rozhodnutí agenta ignorovat pole `pausedElapsed` a nerozložit složitou funkci `processTick`.

Změna instrukcí pro r5.

Návrat k předchozí verzi instrukcí po neúspěšné iteraci je standardní postup; iterativní cyklus nepředpokládá monotónní zlepšování (Peffer et al., 2008). R5 proto vychází z r3 (ne z r4) a cílí na dvě zbývající selhání procedurální verifikací. Obě změny používají stejný vzorec jako předchozí úspěšné opravy: místo deklarativního pravidla přidáváme verifikační akci do pre-PR checklistu.

- Q2: do pre-PR checklistu přidán krok “verify that every field in the API Contract types is read and written in your implementation. If a field exists in the type but is unused, fix it before opening the PR.” Na rozdíl od r4, kde pravidlo bylo v `Constraints` (deklarativní), je verifikace v `Process` (procedurální) (Breunig, 2025)
- Q5/Q7: agent v r3 spustil eslint s vlastním configem, který neobsahoval pravidlo `complexity`, dostal nula warningů a kód považoval za hotový. Experiment měří Q5/Q7 s fixním configem kde `complexity` pravidlo je. Do instrukcí přidán explicitní požadavek: “your ESLint config must include `complexity`: `[warn, 10]`”

Výřez `git diff` mezi verzemi `AGENTS.md` pro běhy r3 a r5 ukazuje obě změny: rozšířený pre-PR checklist o API contract verifikaci a explicitní `complexity` pravidlo.

```
AGENTS.md: pilot-r3 -> pilot-r5

4. Before every PR, run these checks and fix all issues before opening:
  - `tsc --noEmit` – zero type errors
  - `npx eslint src/ --max-warnings 0` – zero lint warnings (includes complexity violations)
  - `npx eslint src/ --max-warnings 0` – zero lint warnings. Your ESLint config must include `"complexity": ["warn", 10]`.
  - Verify API contract compliance: every field in the API Contract types (e.g. `pausedElapsed`, `pausedFrom`) must be read and used in your implementation logic – not just written. If a field is defined but never read, fix it before opening the PR.

## Package Quality
```

Obrázek 4.5: Vizuální diff změn `AGENTS.md` mezi pilot-r3 a pilot-r5

4.2.5 Pilot-r5: verifikace kontraktu

Pátý běh ověřoval změny zavedené po r4. Agent přečetl `AGENTS.md` (v transcriptu potvrzeno), ale místo `gh issue create` použil interní plánovací nástroj (`todowrite`) a implementoval vše v jednom `feat`: commitu bez issues, branches a pull requestů.

Tabulka 4.6: Pilot-r5: metriky s změnou oproti r3

Kód	Metrika	r3	r5	Trend
P2	Branch per issue	✓	×	regrese
P3	Test-first commity	✓	×	regrese
P4	PRs linked	✓	×	regrese
Q2	Ref. test pass rate	41/42	38/42	horší
Q5	Lint warnings	1	0	opraveno
Q7	Složitost kódu	1 viol.	0	opraveno
E1	Vstup / výstup / Σ cache (tis.)	62 / 30 / 4770	65 / 23 / 3028	záznam
E2	Trvání	24,8 min	13,2 min	záznam
E3	Stabilita session	dokončeno	dokončeno	záznam

Diagnostika.

Instrukce r5 se lišily od r3 pouze ve dvou řádcích pre-PR checklistu (API contract verifikace a ESLint complexity config). Obě cílené opravy zabraly: $Q5 = 0$ a $Q7 = 0$. Agent konfiguroval ESLint s pravidlem `complexity` a rozložil funkci `processTick`. Opravu Q5/Q7 tak pravděpodobně přinesla jediná konkrétní instrukce: “your ESLint config must include `complexity`: [warn, 10]”.

Přesto agent ignoroval celý Process workflow: žádné issues, branches ani pull requesty. Analýza transcriptu ukazuje posloupnost: agent přečetl instrukce (zpráva 4: “I need to decompose the spec into focused GitHub issues”), v následujícím kroku však místo `gh issue create` použil interní plánovací nástroj (`todowrite`) a implementoval vše v jednom `feat`: commitu. Pre-PR checks (tsc, eslint) přitom dodržel. Agent tedy selektivně plnil instrukce: jednokrokové příkazy s okamžitým výstupem (“spust eslint”) ano, vícekrokový workflow (“vytvoř issue, pak branch, pak test, pak implementuj, pak PR”) ne.

Srovnání r3, r4 a r5 ukazuje, že tento vzorec není náhodný. R3 agent dodržel celý workflow ($P1-P5 = 5/5$). R4 dodržel částečně ($\sim 3/5$), vytvořil issues ale ne pro všechny branch. R5 workflow ignoroval zcela ($\sim 1/5$). Instrukce se přitom mezi r3 a r5 liší minimálně (2 řádky v pre-PR checklistu). Data tak naznačují, že nedeterminismus modelu je pro dodržování vícekrokových sekvencí silnějším faktorem než drobné lokální změny v pre-PR checklistu.

Závěr pilotních iterací.

Pět iterací (r1–r5) přineslo čtyři pozorování:

- Verifikační kroky fungují spolehlivě.** Jednokrokové příkazy s okamžitým výstupem agent dodržoval stabilněji než zbytek workflow.
- Vícekový workflow je nedeterministický.** Stejná instrukční sada vedla od plného dodržení (r3) přes částečné dodržení (r4) až po

kolaps workflow (r5).

3. **Deklarativní pravidla byla slabší než procedurální verifikace.** Pravidlo v Constraints nepomohlo, zatímco konkrétní kontrolní kroky opakovaně vedly ke zlepšení.
4. **Některá implementační rozhodnutí instrukce neopravila.** Problém s `pausedElapsed` přetrval i po dalších úpravách, přestože specifikace i API kontrakt byly jednoznačné.

Pilotní baseline pro komparativní variace zůstává r3, jediný běh kde agent workflow dodržel. Komparativní variace testují, které z těchto pozorování vydrží cílenou ablaci.

Obrázek 4.6 ukazuje souhrnnou evoluci instrukcí od baseline k nejlepší iteraci. Bílé řádky zůstaly z r1, zelené byly přidány během iterací.

AGENTS.md: pilot-r1 -> pilot-r3 (souhrnná evoluce)

```
# AGENTS.md – Dunning System

## Role

You are a senior TypeScript developer building a production-grade npm package. You prioritize clean architecture,
spec compliance, and test quality.

## Goal

Implement the dunning system (billing reminder state machine) specified in GitHub Issue #1. Deliver a modular,
documented, publishable TypeScript package.

## Specification

Read Issue #1 completely before writing any code. It contains:
- Acceptance Criteria – every one must be satisfied and tested
- API Contract – exact TypeScript signatures to export
- Domain Glossary – use these terms in code and documentation
- Out of Scope – do not implement

All design decisions must trace back to the spec. Do not invent requirements.

## Environment

- Runtime: Node.js, TypeScript (strict mode, ESM)
- Test runner: Vitest
- Build: tsc
- Tools: GitHub CLI (`gh`), Git

## Process

Decompose the spec into focused GitHub issues before writing code. Work through them sequentially:

1. Create issues – one concern per issue, starting with project setup
2. For each issue: branch from main, write tests first, implement, PR with "Closes #N", merge
2. For each issue, follow this exact sequence:
  a. Pick one open issue: `gh issue list --state open`, then `git checkout main && git pull && git checkout -b issue-N`
  b. Write tests: `git add tests/ && git commit -m "test: <description>"`
  c. Verify: run `git log --oneline -3` and confirm the test: commit exists before proceeding
  d. Implement: `git add src/ && git commit -m "feat: <description>"`
  e. Open PR: `gh pr create --title "..." --body "Closes #N"`, merge, delete branch
3. Use conventional commits: `test:` for tests, `feat:` for implementation, `docs:` for documentation
4. Run `tsc --noEmit` before every PR – no type errors allowed
4. Before every PR, run these checks and fix all issues before opening:
  - `tsc --noEmit` – zero type errors
  - `npx eslint src/ --max-warnings 0` – zero lint warnings (includes complexity violations)

## Package Quality

Structure the code as a production-grade npm package:

- Modular architecture – separate files for types, business logic, utilities, and public API re-exports. No single-file implementations.
- Strict TypeScript – no `any`, explicit return types on public API, `readonly` where applicable.
- Documentation – JSDoc on all exported functions and types. Inline comments for non-obvious domain logic (e.g., business day calculations, escalation thresholds).
- Documentation – JSDoc on all exported functions and types. Inline comments for non-obvious domain logic (e.g., business day calculations, escalation thresholds). This is enforced in Constraints.
- Clean API surface – `src/index.ts` re-exports only the public API. Internal modules are not exposed.

## Constraints

- Never combine multiple issues into one branch.
- Never implement without a failing test first.
- Never modify a test to match your implementation. Tests encode the spec – fix the code, not the test.
- Never modify a test to match your implementation. If a test fails after implementation, fix the code – not the test. Tests encode the spec.
- Before every PR, verify JSDoc on every exported function in `src/index.ts`. If any export lacks JSDoc, add it before opening the PR.
- Never rewrite git history (no amend, squash, rebase, force-push).
- Do not add dependencies beyond the dev toolchain (vitest, typescript).
```

Obrázek 4.6: Souhrnná evoluce AGENTS.md: pilot-r1 → pilot-r3. Zelené řádky = přidáno, červené = odebráno.

4.3 Komparativní variace

Pilotní iterace ukázaly, že část zlepšení souvisí s přidáním konkrétních kontrolních kroků. Zbývá proto otázka, které složky výsledných instrukcí jsou pro chování agenta nezbytné a které lze odebrat bez dopadu. Po pilotu zůstaly otevřené dvě konkrétní nejistoty: zda agent potřebuje explicitně předepsané verifikační kroky a zda sekce Package Quality nese samostatný přínos nad rámec workflow. Komparativní variace proto nejsou generickým odebíráním částí `AGENTS.md`. Každá ablance odpovídá na otázku, která po r1–r5 zůstala neuzavřená.

Existující studie měří efekt souboru `AGENTS.md` převážně jako celku. Účinek jednotlivých složek proto zůstává otevřenou otázkou (Gloaguen et al., 2025; Lulla et al., 2026). Naše ablance tuto mezeru částečně vyplňují na úrovni případové studie.

4.3.1 Výběr složek pro ablaci

Soubor `AGENTS.md` obsahuje sedm sekcí. Pro účely ablaci rozlišujeme sekce definující *co* implementovat (Role, Goal, Specification, Environment) a sekce definující *jak* pracovat a jakou kvalitu produkovat (Process, Package Quality, Constraints). Odebrání kontextových sekcí by testovalo jinou otázku než vliv instrukcí na proces a kvalitu. Constraints zde navíc neablujeme, protože jejich efekt se v pilotních bězích částečně překrýval s workflow v Process. Proto testujeme dvě složky, u nichž zůstala největší nejistota: verifikační kroky v Process a sekci Package Quality.

Ablance A: bez verifikačních kroků.

Odebíráme explicitní verifikační příkazy (`tsc --noEmit`, `npx eslint`, `git log --oneline -3`), ale ponecháváme workflow `issue → branch → test → implement → PR` (obrázek 4.7). Cílem je ověřit, zda agent tyto kontrolní kroky spouští i bez instrukce.

AGENTS.md: pilot-r3 → ablance-a (bez verifikačních kroků)

```

a. Pick one open issue: `gh issue list --state open`, then `git checkout main && git pull && git checkout -b issue-N`
b. Write tests: `git add tests/ && git commit -m "test: <description>"`
c. Verify: run `git log --oneline -3` and confirm the test: commit exists before proceeding
d. Implement: `git add src/ && git commit -m "feat: <description>"`
e. Open PR: `gh pr create --title "... " --body "Closes #N"` , merge, delete branch
c. Implement: `git add src/ && git commit -m "feat: <description>"`
d. Open PR: `gh pr create --title "... " --body "Closes #N"` , merge, delete branch
3. Use conventional commits: `test:` for tests, `feat:` for implementation, `docs:` for documentation
4. Before every PR, run these checks and fix all issues before opening:
  - `tsc --noEmit` – zero type errors
  - `npx eslint src/ --max-warnings 0` – zero lint warnings (includes complexity violations)


## Package Quality
```

Obrázek 4.7: Změny `AGENTS.md` pro ablaci A: odebrány verifikační kroky (`git log`, `tsc`, `eslint`) z Process.¹

Očekávání: pokud agent typecheck a lint spustí i bez instrukce, verifikační kroky jsou redundantní; pokud ne, jde o klíčový mechanismus jejich účinku.

Ablace B: bez sekce Package Quality.

Odebíráme celou sekci Package Quality (modulární architektura, strict TypeScript, JSDoc dokumentace, čisté veřejné API). Process a Constraints zůstanou beze změny (obrázek 4.8).



Obrázek 4.8: Změny AGENTS.md pro ablaci B: odebrána celá sekce Package Quality (konvence, strict TypeScript, JSDoc, čisté API).

Očekávání: pokud Q5, Q7 a Q8 zůstanou na úrovni r3, jsou konvenční instrukce převážně redundantní s tréninkem modelu; pokud se zhorší, explicitní konvence v instrukcích přispívají k celkovému efektu souboru.

4.3.2 Ablace A: bez verifikačních kroků

Tabulka 4.7 shrnuje výsledky dvou běhů (A-1, A-2) ve srovnání s r3.

¹Zelené řádky v diffu neobsahují nový text; vznikly přecíslováním kroků po odebrání kroku c (Verify).

Tabulka 4.7: Ablace A: srovnání s r3 (bez verifikačních kroků)

Kód	Metrika	r3	A-1	A-2
P1	Issues before code	✓	✓	✓
P2	Branch per issue	✓	✓	×
P3	Test-first commits	✓	✓	×
P4	PRs linked to issues	✓	✓	×
P5	Testy nezměněny	✓	×	✓
P6	Commit msg quality	3/3	2/3	2/3
P7	Issue quality	3/3	2/3	3/3
P8	PR quality	3/3	3/3	1/3
Q1	API contract match	match	match	match
Q2	Ref. test pass rate	41/42	35/42	37/42
Q3	Mutation score	71 %	62 %	— [†]
Q5	Lint warnings	1	4	3
Q6	Typecheck errors	0	0	0
Q7	Complexity violations	1	4	1
Q8	Design quality	3/3	2/3	2/3
E1	Vstup / výstup / Σ cache (tis.)	62 / 30 / 4770	n/a	n/a
E2	Trvání	25 min	39 min	24 min
E3	Stabilita session	dokončeno	dokončeno	dokončeno

[§] Sloupec r3: E1 z pilotního `transcript.json` (62 / 30 / 4770 tis.). U A-1 a A-2 chybí export v lokálním snapshotu. E1 pro tyto běhy nešlo dopočítat.

[†] Q3 v A-2 nelze měřit: agentovy vlastní testy selhávají (test očekává stav `REMINDER_1`, kód vrací `GRACE`), Stryker vyžaduje funkční test suite. Bez verifikačních kroků agent commitl kód s nefunkčními testy.

Interpretace.

E1 u ablace nelze dopočítat, protože v lokálním snapshotu chybí `transcript.json`. Tabulka 4.7 ukazuje pokles napříč metrikami kvality kódu (Q5, Q7) i funkční korektnosti (Q2, Q3). Bez explicitního příkazu `npx eslint` agent neprovedl kontrolu kvality před odevzdáním kódu, což naznačuje, že verifikační kroky nejsou redundantní. Agent je bez instrukce nespouští sám.

Procesní metriky vykazují vzorec známý z pilotních iterací: A-1 dodržel workflow kompletně, A-2 nikoliv. Instrukce se mezi běhy nelišily. Variabilita je důsledkem nedeterminismu modelu, ne ablace.

Agent bez verifikačních kroků spotřeboval přibližně dvakrát více testovacích cyklů (44 spuštění `vitest` oproti ~ 20 u ablace B). To naznačuje, že verifikační kroky plní kromě kontroly kvality

i druhou funkci: fungují jako checkpointy které strukturují práci agenta a zabráňují cyklickému debugování.

4.3.3 Ablace B: bez Package Quality

Tabulka 4.8 shrnuje výsledky dvou běhů (B-1, B-2) ve srovnání s r3.

Tabulka 4.8: Ablace B: srovnání s r3 (bez sekce Package Quality)

Kód	Metrika	r3	B-1	B-2
P1	Issues before code	✓	✓	✓
P2	Branch per issue	✓	✓	×
P3	Test-first commits	✓	✓	✓
P4	PRs linked to issues	✓	×	✓
P5	Testy nezměněny	✓	×	×
P6	Commit msg quality	3/3	3/3	3/3
P7	Issue quality	3/3	3/3	3/3
P8	PR quality	3/3	2/3	2/3
Q1	API contract match	match	match	match
Q2	Ref. test pass rate	41/42	37/42	11/42
Q3	Mutation score	71 %	67 %	72 %
Q5	Lint warnings	1	2	2
Q6	Typecheck errors	0	0	0
Q7	Complexity violations	1	1	2
Q8	Design quality	3/3	—*	2/3
E1	Vstup / výstup / Σ cache (tis.)	62 / 30 / 4770	n/a	n/a
E2	Trvání	25 min	28 min	21 min
E3	Stabilita session	dokončeno	dokončeno	dokončeno

* Q8 v B-1: judge nedokončil hodnocení (API timeout).

Interpretace.

Stejně jako u tabulky 4.7 chybí u ablace export `transcript.json`. Řádek E1 proto zůstává n/a.

Automatizované metriky kvality kódu (Q5, Q6, Q7) zůstaly na podobné úrovni jako v r3 (tabulka 4.8). Agent produkoval modulární kód, striktní TypeScript a v B-1 i JSDoc dokumentaci, přestože instrukce tyto požadavky neobsahovaly. Jediný pokles zaznamenalo Q8 (design quality): judge identifikoval chybějící modularitu (veškerý kód v jednom souboru) a neúplnou dokumentaci. Data naznačují, že základní kódové konvence jsou u tohoto modelu řízeny převážně znalostmi z tréninku. Strukturální rozhodnutí (modularita, dokumentace)

instrukce pravděpodobně ovlivňují. Tento závěr je ale založen na Q8, tedy na judge-based metrice bez validace proti lidskému hodnocení.

Funkční korektnost (Q2) vykazuje extrémní variabilitu: B-1 dosáhl 37/42 (srovnatelné s r3), zatímco B-2 pouze 11/42. Mutation score zůstal stabilní (67–72 %). Propad Q2 v B-2 není důsledkem ablace Package Quality, ta neobsahuje žádné instrukce o implementační logice. Jde o projev nedeterminismu modelu: agent v B-2 implementoval business day výpočty chybně, což způsobilo kaskádové selhání eskalačních přechodů. Stejný typ chyby se objevoval i v pilotních iteracích (r1, r4).

P5 (testy nezměněny) selhalo v obou bězích. Agent modifikoval vlastní testy po implementaci. Stejný problém se objevoval i v pilotních iteracích (r1, r4) se stejnými instrukcemi, jde tedy o projev nedeterminismu modelu, ne ablace.

4.3.4 Závěr komparativní fáze

Dvě ablace testovaly dvě složky instrukcí z r3: verifikační kroky v Process (ablace A) a sekci Package Quality (ablace B). Výsledky ukazují odlišný charakter obou složek.

Bez verifikačních kroků (`tsc`, `eslint`) klesly metriky kvality kódu i funkční korektnosti (tabulka 4.7). Agent bez kontrolních bodů navíc spotřeboval přibližně dvakrát více testovacích cyklů. Verifikační kroky tak v této studii fungují nejen jako kontrola kvality, ale i jako checkpointy strukturující práci agenta.

Bez sekce Package Quality zůstaly automatizované metriky kvality (Q5–Q7) na srovnatelné úrovni (tabulka 4.8), avšak Q8 (design quality) kleslo ve všech ablačních bězích. Judge identifikoval chybějící modularitu a neúplnou dokumentaci. Data jsou konzistentní s hypotézou, že základní kódové konvence jsou u tohoto modelu řízeny znalostmi z tréninku, zatímco strukturální rozhodnutí instrukce ovlivňují.

Procesní metriky (P1–P5) vykazovaly v obou ablacích variabilitu srovnatelnou s pilotními iteracemi (r3 vs. r4/r5). Tato variabilita není důsledkem ablace, ale nedeterminismu modelu: instrukce pro workflow zůstaly v obou ablacích beze změny.

4.4 Souhrnné výsledky

Tabulka 4.9 shrnuje deterministické metriky všech běhů: pět pilotních iterací a čtyři ablační běhy. Pilotní sloupce ukazují evoluci instrukcí, ablační sloupce ukazují dopad odebrání jednotlivých složek. Baseline pro srovnání je r3, jediný pilotní běh kde agent splnil celý procesní checklist. Sloupec E1 uvádí vstup (max. na kroku včetně `cache` v exportu), výstup a součet `cache` přes kroky, vše v tisících. Stejný přehled generuje skript `summary.ts` do `experiments/runs/SUMMARY.md`.

Tabulka 4.9: Souhrnné výsledky všech běhů (pilot + ablace)

Metrika	Pilotní iterace					Ablace A		Ablace B	
	r1	r2	r3	r4	r5	A-1	A-2	B-1	B-2
P1 issues before code	✓	✓	✓	✓	×	✓	✓	✓	✓
P2 branch per issue	×	×	✓	×	×	✓	×	✓	×
P3 test-first	×	×	✓	✓	×	✓	×	✓	✓
P4 PRs linked	✓	✓	✓	✓	×	✓	×	×	✓
P5 testy nezměněny	×	✓	✓	×	✓	×	✓	×	×
P6 commit msg	n/a	2/3	3/3	3/3	2/3	2/3	2/3	3/3	3/3
P7 issue quality	3/3	2/3	3/3	3/3	3/3 [‡]	2/3	3/3	3/3	3/3
P8 PR quality	2/3	3/3	3/3	3/3	1/3	3/3	1/3	2/3	2/3
Q1 API contract	match	match	match	match	match	match	match	match	match
Q2 ref. testy	39	32	41	39	38	35	37	37	11
Q3 mutation score	84 %	68 %	71 %	n/a	—	62 %	—*	67 %	72 %
Q4 AC coverage	23	25	25	25	24	25	25	25	23
Q5 lint warnings	2	1	1	1	0	4	3	2	2
Q6 typecheck errors	0	0	0	0	0	0	0	0	0
Q7 složitost	2	0	1	1	0	4	1	1	2
Q8 design quality	1/3	1/3	3/3	2/3	2/3	2/3	2/3	2/3	2/3
E1 in/out/cache (tis.)	115/60/11k	76/41/3k	62/30/5k	81/36/6k	65/23/3k	n/a	n/a	n/a	n/a
E2 trvání (min)	32,7	37,2	24,8	25,9	13,2	39	24	28	21
E3 stabilita session	ok	ok	1 komp.	ok	ok	ok	ok	ok	ok

[‡] P7 v r5: judge hodnotil specifikační issue, ne agentovu.

* Stryker v A-2 nedokončil analýzu (timeout).

Q4 v uložených judge artefaktech historicky používalo 24bodovou rubriku. Ve thesis jsou hodnoty převedeny na 25 AC po manuálním dopočítání AC25 (*custom holiday calendar*).

Tabulka shrnuje dva hlavní vzorce. V pilotní fázi se instrukce podařilo iterativně zlepšit: r1 splnila 4/10 tvrdých deterministických kritérií, r3 po dvou cyklech úprav 7/10. Ablace zároveň ukazuje, že ne všechny složky instrukcí přispívají stejně: odebrání verifikačních kroků zhoršilo Q2, Q3, Q5 a Q7, zatímco odebrání sekce Package Quality ponechalo automatizované metriky kvality na srovnatelné úrovni. Napříč všemi devíti běhy zůstaly stabilní zejména Q1 (API contract match) a Q6 (typecheck errors); nejvyšší variabilitu naopak vykazovaly procesní metriky P2–P5. Interpretaci těchto výsledků ve vztahu k cílům práce uvádí kapitola 5.

5. Vyhodnocení a diskuse

Předchozí kapitola popsala průběh případové studie a naměřená data. Tato kapitola výsledky interpretuje: nejprve ve vztahu ke třem cílům práce (sekce 5.1), poté v kontextu existujícího výzkumu (sekce 5.2) a nakonec diskutuje, jak se metodologická omezení identifikovaná v sekci 3.5 projevila v praxi (sekce 5.3).

5.1 Interpretace výsledků

Následující tři podsekcce hodnotí, do jaké míry případová studie naplnila cíle stanovené v kapitole 1. Vracíme se tím k hlavnímu problému práce: jak hodnotit a iterativně zlepšovat chování AI coding agenta v situaci, kdy samotný pass/fail výsledek nestačí pro praktické rozhodování o použitelnosti řešení.

5.1.1 Cíl 1: Sada metrik

Na základě analýzy existujících standardů kvality softwaru a současných benchmarků pro AI agenty navrhnout sadu metrik pokrývajících proces, kvalitu kódu a efektivitu (dimenze, které stávající benchmarky neměří).

Sada 19 metrik byla navržena (kapitola 3) a použita na devíti bězích (kapitola 4). Její přínos nespočívá v tom, že „ukázala nějaká čísla“, ale v tom, že rozšířila hodnocení agenta za hranici pass/fail výsledku. Právě to bylo potřeba pro problém vymezený v kapitole 1: odlišit řešení, které jen projde testy, od řešení, které je zároveň vytvořeno obhajitelným postupem a zanechává použitelný kód.


Procesní metriky (P1–P8).

procesní metriky (P1–P8) měří zda agent dodržoval vývojové praktiky (issues, branching, test-first, PR workflow), tedy dimenzi kterou stávající benchmarky pokrývají jen okrajově (sekce 2.2.4). Na devíti bězích se ukázaly jako nejcitlivější složka sady: byly jediné metriky které kolísaly i mezi běhy se stejnými instrukcemi. Možným vysvětlením je, že kvalita kódu je u tohoto modelu řízena převážně tréninkovými daty (Q metriky zůstaly stabilní), zatímco dodržování vícekrokového postupu (issue → branch → test → implement → PR) je inherentně náchylnější k selhání: agent musí udržet sekvenci kroků v kontextu a každý krok je příležitost k odchylce. P1–P5 ale říkají jen splněno/nesplněno, což přináší ztrátu nuancí. Například P3 (test-first commits) hlásila v prvních dvou bězích stejný výsledek “nesplněno”, ale z git historie a behaviorálního popisu bylo vidět, že se chování lišilo: v prvním běhu agent testy nepsal vůbec, v druhém je psal ale kombinoval s implementací do jednoho commitu. Odpověď ano/ne

řekne *co* nefunguje, ale ne *proč*. K diagnostice a návrhu opravy instrukcí bylo vždy nutné doplnit binární metriky o podrobnější analýzu chování agenta (git historie, `FINDINGS.md`).

Podobně P4 měří *zda* agent vytvořil PR linkovaný na issue, ale ne *jak kvalitní* ten PR je. P6 (commit message quality)–P8 (PR description quality) (kvalita commit zpráv, issue popisů a PR popisů, hodnocené na škále 1–3) tuto mezeru doplňují. V běhu r1 P4 hlásila “splněno” (agent skutečně vytvořil linkované PR), ale P8 = 2/3 zachytila, že část PR slučovala více issues do jednoho review artefaktu. Binární a kvalitativní metriky tedy měří odlišné aspekty téhož procesu a jejich kombinace se ukázala jako nutná.

Obrázek 5.1 shrnuje míru splnění exit kritérií procesních metrik napříč devíti běhy.



Obrázek 5.1: Míra splnění exit kritérií procesní metrik (P1–P8) napříč devíti běhy. P2 a P5 byly splněny nejméně často (3/9), P6 a P7 ve všech bězích. Deterministické položky (P1–P5) vykazují vyšší variabilitu než kvalitativní (P6–P8).

Kvalita kódu (Q1–Q8).

Na rozdíl od procesních metrik vykazují produktové metriky (Q1–Q8) celkově vyšší stabilitu: Q1 (API contract match) a Q6 (typecheck errors) byly splněny ve všech devíti bězích, a Q4 (AC coverage) dosáhla ve většině hodnocených běhů plného skóre 25/25. Data naznačují, že základní kvalita kódu je u tohoto modelu řízena převážně tréninkovými daty, zatímco procesní chování závisí na instrukcích výrazněji. Uvnitř skupiny se ale metriky chovají odlišně podle toho, co měří.

Korektnost (Q1, Q2). Q1 zůstala stabilní ve všech bězích: agent vždy vytvořil veřejné API odpovídající kontraktu, takže Q1 na této úloze nepřinesla rozlišení. Q2 (referenční test pass rate) je naopak nejvariabilnější produktová metrika (splněna v 6 z 9 běhů): opakovaně selhávaly testy pokrývající přechody pause/resume. Specifikace i API kontrakt jednoznačně vyžadují zachování elapsed time (pole `pausedElapsed`), ale agent toto pole opakovaně ignoroval. Kontrast mezi Q1 (binární, vždy splněna) a Q2 (poměr projitých testů, variabilní) ukazuje, že binární metrika nezachytí problémy které jemnější měření odhalí.

Testování (Q2–Q4). Tři metriky pokrývají testování z různých úhlů: Q2 (referenční test pass

rate) měří kolik referenčních testů projde (vyšší = lepší implementace), Q3 (mutation score) měří jaký podíl injektovaných chyb agentovy testy odhalí (vyšší = kvalitnější testy) a Q4 (AC coverage) měří kolik acceptance criteria má odpovídající test (vyšší = úplnější pokrytí).


Vztah mezi Q2 a Q3 se ukázal jako nejinformativnější. V ablačním běhu B-2 agent dosáhl $Q2 = 11/42$. Jeho implementace byla z velké části chybná. Přesto $Q3 = 72\%$, tedy testy které napsal by v korektní implementaci zachytily většinu injektovaných chyb. Agent tedy uměl psát kvalitní testy, ale neuměl správně implementovat logiku. Kdyby sada obsahovala jen jednu z těchto metrik, tento rozdíl by zůstal skrytý.

Q4 zůstala relativně stabilní: po manuálním doplnění AC25 dosáhla většina hodnocených běhů plného skóre 25/25. Tato metrika ale měří pouze *přítomnost* testu na dané AC, ne jeho správnost: agent mohl napsat test který judge vyhodnotí jako pokrytí, ale který ve skutečnosti chování neověřuje. Kvalitu testů měří až Q3. Společně tyto tři metriky tvoří hierarchii: Q4 říká *co* agent testuje, Q3 *jak dobře*, a Q2 zda implementace skutečně funguje.

Čistota a design (Q5–Q8). Q5 (lint warnings) a Q7 (složitost kódu) se ukázaly jako citlivé na instrukce: v ablacích bez sekce Package Quality vzrostl počet lint warnings o přibližně 150 % a počet violations cyklomatické složitosti obdobně. Q6 (typecheck errors) naproti tomu zůstala nulová ve všech bězích. Statické typování poskytuje modelu explicitní vodítka přímo v kódu: typy parametrů, návratové hodnoty a rozhraní jsou součástí trénovacích dat a model je při generování dodržuje. U dynamicky typovaných jazyků by Q6 pravděpodobně rozlišovala lépe.

Q8 (design quality) doplňuje automatizované metriky o strukturální pohled na kód. Hodnocení provádí LLM-as-judge na základě rubriky s pěti dimenzemi: naming, separation of concerns, idiomatický TypeScript, dokumentace a složitost. V pilotních bězích Q8 opakovaně identifikovala chybějící dokumentaci: r1 a r2 dostaly 1/3 (žádné JSDoc), r4 a r5 dostaly 2/3 (dokumentace jen na hlavním API, ne na utility funkcích). Teprve po přidání explicitního verifikačního kroku do instrukcí (r3) agent dokumentaci doplnil (3/3). V ablačních bězích klesla navíc dimenze separation of concerns: agent soustředil kód do jednoho souboru. Automatizované metriky Q5–Q7 přitom žádný z těchto problémů nehlásily. Kombinace deterministické metriky a kvalitativní metriky tak zachycuje víc než kterýkoliv typ sám.

Obrázek 5.2 shrnuje míru splnění exit kritérií produktových metrik napříč devíti běhy.




Obrázek 5.2: Míra splnění exit kritérií produktové metriky (Q1–Q8) napříč devíti běhy. Q1 a Q6 byly splněny ve všech bězích; Q3 a Q5 nejméně často. Q3 počítáno ze 7 běhů (2 bez dat). Metriky efektivity (E1–E3) nemají exit kritérium a nejsou zahrnuty.

Efektivita (E1–E3).

E1 (vstup/výstup/cache tokeny) ukázala užitečný vzorec: bez verifikačních kroků agent spotřeboval přibližně dvakrát více testovacích cyklů, což se projevilo na vyšší spotřebě tokenů. E2 (trvání) závisí převážně na rychlosti poskytovatele API (rate limity, latence), ne na kvalitě agentovy práce. Nejkratší běh (r5, 13 min) vznikl tím, že agent ignoroval celý pracovní postup. E2 je proto nutné číst společně s procesními metrikami.

E3 (stabilita session) na této úloze přinesla jen malé rozlišení: sessiony byly většinou dostatečně krátké na to, aby se vešly do kontextového okna. Pro rozsáhlejší projekty by E3 pravděpodobně rozlišovala lépe.

Při orientačním přepočtu na cenu (ceník poskytovatele Alibaba Cloud Model Studio) se ukázalo, že vyšší spotřeba tokenů nekoreluje s lepším výsledkem: nejlevnější běh (r3, přibližně \$0,17) dosáhl nejlepších metrik (Q2 = 41/42 a plné splnění P1–P5), zatímco nejdražší běh (r4, přibližně \$0,64) měl horší výsledky. Agent v r4 spotřeboval víc tokenů na cyklické debugování, ne na kvalitnější práci (obrázek 5.3).



Obrázek 5.3: Vztah mezi odhadovanou cenou běhu (E1) a počtem splněných deterministických kritérií (P1–P5, Q1, $Q2 \geq 41$, $Q5 \leq 1$, $Q6 = 0$, $Q7 \leq 1$). Běh r3 dosáhl maxima 10/10 při nejnižší ceně z pilotních iterací. Ablací běhy (trojúhelníky) se pohybují v rozmezí 5–6 splněných kritérií.

Shrnutí a reflexe.

Sada se ukázala jako proveditelná pro opakované měření: deterministické metriky se extrahují automatizovaně, kvalitativní metriky hodnotí LLM-as-judge s fixní rubrikou. Jedno kompletní měření trvá řádově minuty, což umožňuje zpětnou vazbu v rámci jedné iterace.

Kritický pohled na design sady odhaluje několik slabých míst. Tři metriky (Q1, Q6, E3) nepřinesly na této úloze žádné rozlišení. Jsou pojistkou pro jiné úlohy nebo jazyky, ale na devíti bězích zabíraly místo bez informačního přínosu. Procesní metriky přinesly nejvíc nových poznatků (nestabilita chování kterou produktové metriky nezachytily), ale jsou zároveň nejméně spolehlivé: kolísají i mezi běhy se stejnými instrukcemi, takže u jednoho běhu jim nelze plně věřit. Binární P1–P5 navíc ztrácí nuance: “nesplněno” neříká *proč* a k diagnostice bylo vždy nutné vrátit se k transcriptu agenta. Kvalitativní metriky (Q4, Q8) zachytily problémy které automatizované nevidí, ale bez validace Cohenovým κ zůstávají podpůrnými indikátory. Metriky efektivity byly na této úloze nejslabší skupinou: pouze E1 přinesla použitelný insight.

5.1.2 Cíl 2: Iterativní postup

Na případové studii demonstrovat iterativní postup návrhu instrukcí řízený těmito metrikami a vyhodnotit, zda a jak vede k měřitelným změnám v dodržování vývojových praktik.

Případová studie ukazuje, že tento postup lze na jednom projektu prakticky použít a že

tento problém nepodařilo adresovat. Jde o implementační rozhodnutí na úrovni kde instrukce typu pravidlo ani verifikační krok nestačí. Podobně nelze vyloučit, že některé regrese v r4 byly vedlejším efektem úprav cílených na jiné metriky. Nedeterminismus modelu a malý počet běhů neumožňují odlišit kauzální efekt úpravy od náhodného šumu.

Z hlediska praktické proveditelnosti: každá iterace trvala 25–40 minut (běh agenta) plus řádově desítky minut na diagnostiku a úpravu instrukcí. Diagnóza se opírala o tabulku metrik, behaviorální popis z `FINDINGS.md` a analýzu transcriptu agenta. Zjištěný vzorec na spektru operacionalizace (pravidlo → příkaz → verifikační krok) považujeme za jeden z hlavních poznatků práce, ale vychází z jedné případové studie s jedním modelem. Jeho platnost pro jiné modely a typy úloh vyžaduje další výzkum.

5.1.3 Cíl 3: Ablace

Z instrukcí vytvořených v cíli 2 prozkoumat ablacemi, které složky přispívají k měřenému chování agenta a které jsou redundantní.

Sekce 4.3.4 shrnuje výsledky obou ablací. Verifikační kroky (ablace A) přispívají: bez nich klesly metriky kvality i korektnosti. Sekce Package Quality (ablace B) je pro automatizované metriky převážně redundantní: Q5, Q6 a Q7 zůstaly na srovnatelné úrovni. Pouze Q8 zachytila pokles v modularitě a dokumentaci.

Co tyto výsledky znamenají pro cíl 3? Ablace rozlišily dva typy složek instrukcí. V této případové studii mají verifikační kroky zjevný instrumentální přínos: bez explicitní instrukce agent kontrolní příkazy nespouštěl spolehlivě. Kódové konvence agent dodržuje i bez instrukce, pravděpodobně ze znalostí z tréninku. Instrukce ale ovlivňují strukturální rozhodnutí (modularita, dokumentace) která automatizované metriky nezachytí. Dimenze efektivity byla v ablacích vyhodnocena jen částečně: E1 nešlo kvůli chybějícím exportům spočítat ani v jednom ablačním běhu, takže závěry ablační fáze stojí primárně na procesní metriky (P1–P8) a produktové metriky (Q1–Q8).

Variabilita procesních metrik byla v ablacích srovnatelná s pilotními iteracemi, přestože instrukce pro workflow zůstaly beze změny. Data naznačují, že procesní compliance je u tohoto modelu stochastická vlastnost, kterou instrukce ovlivňují jen částečně. Variabilita mezi B-1 (Q2 = 37/42) a B-2 (Q2 = 11/42) ukazuje, že nedeterminismus modelu může být silnějším faktorem než efekt ablace. Při dvou bězích per variaci nelze oba faktory spolehlivě odlišit.

Reflexe designu ablací.

Vzorec operacionalizace (pravidlo → příkaz → verifikační krok), identifikovaný v cíli 2, jsme pojmenovali až při analýze pilotních dat. Výběr ablací mu předcházela. Zpětně je zřejmé, že u ablace A byl pokles metrik do značné míry předvídatelný: `npx eslint` a `git log` jsme do instrukcí přidali v pilotních iteracích právě proto, že bez nich metriky selhávaly.

Novým poznatkem byla dvojí funkce verifikačních kroků: kromě kontroly kvality strukturují práci agenta a zabraňují cyklickému debugování (sekce 4.3.2). Informativnější by byla ablace Constraints nebo workflow struktury, kde výsledek z pilotů předvídatelný není. To zůstává námětem pro další výzkum.

5.2 Porovnání s literaturou

5.2.1 Srovnání metrického rámce

Literatura shrnutá v kapitole 2 ukazuje, že hodnocení AI coding agentů je stále silně orientováno na funkční výsledek. SWE-bench a jemu podobné benchmarky jsou postaveny především na pass/fail logice. Právě proti tomuto omezení vystupují novější empirické práce. METR (METR, 2026) ukazuje, že část patchů, které projdou testy, by nebyla přijata při code review. Li et al. (B. Li et al., 2026) dokládají, že ani sloučený pull request negarantuje udržitelný kód. Ehsani et al. (Ehsani et al., 2026) ukazují, že neúspěch agentních PR není jen otázkou chyb v implementaci, ale i procesních selhání.

Naše sada metrik je s těmito zjištěními konzistentní. Funkční korektnost zůstává nutnou složkou hodnocení, ale sama nestačí. V naší případové studii právě procesní metriky ukázaly informaci, kterou by výsledkové benchmarky samy nezachytily: běhy se stejnými nebo podobnými produktovými výsledky se lišily v tom, zda agent vytvořil auditovatelný pracovní postup. Produktové metriky naopak ukázaly, že ani kvalitní procesní artefakty samy nezaručují správnou implementaci. Přínos rámce P/Q/E tedy nespočívá jen v rozšíření počtu měřených veličin, ale v tom, že umožňuje sledovat různé druhy selhání odděleně a pak je znovu spojit při interpretaci.

Odlišnost vůči existujícím benchmarkům je i v tom, že metriky zde nejsou jen evaluačním výstupem, ale i řídicím nástrojem pro další iteraci. To je důležité pro hlavní problém práce: nestačí vědět, že agent selhal nebo uspěl, pokud z výsledku neplyne, jak instrukce upravit. V tomto smyslu je náš rámec bližší praktickému diagnostickému nástroji než klasickému benchmarku.

5.2.2 Vliv instrukcí na chování agenta

Studie o instrukčních souborech zatím většinou měří jejich přítomnost nebo absenci jako celek. Lulla et al. (Lulla et al., 2026) spojují AGENTS.md s nižším mediánovým runtime, zatímco Gloaguen et al. (Gloaguen et al., 2025) ukazují jen marginální přínos generických repository-level souborů a upozorňují na vyšší náklady. SkillsBench (X. Li et al., 2025) dále rozlišuje mezi kurátorovanou a automaticky generovanou instrukční podporou a ukazuje, že rozhodující je kvalita a relevance obsahu. Naše výsledky jsou s těmito zjištěními kompatibilní: ne všechny složky instrukčního souboru přispívají stejně.

Nejvýraznější efekt měly v naší studii verifikační kroky. Ablace A ukázala pokles jak ve funkční korektnosti, tak v automatizovaných metrikách kvality kódu, když byly explicitní kontroly odstraněny. To doplňuje pozorování Breuniga (Breunig, 2025), že opakování ignorované instrukce nepomáhá a účinnější je její přestrukturování do pracovního postupu. Pilotní iterace v našich datech ukázaly stejný vzorec: obecné pravidlo nestačilo, konkrétní příkaz pomohl jen částečně a stabilnější zlepšení přinesl až verifikační krok. Tento vývoj je konzistentní i s výzkumem specifity instrukcí, podle něhož vyšší konkrétnost pomáhá zejména u procedurálních úloh, ale přílišný detail může omezovat flexibilitu modelu (Kim, 2025; Zi et al., 2025).

Sekce Package Quality se chovala odlišně. Její odebrání nezhoršilo automatizované metriky stejným způsobem jako odebrání verifikačních kroků, ale projevilo se v designové kvalitě hodnocené LLM-as-judge. Data jsou proto konzistentní s tím, že část instrukcí nefunguje primárně jako přímé vynucení chování, ale jako rámec, který aktivuje latentní znalosti modelu. V tomto ohledu je užitečná analogie s promptingem: minimální nápověda může vyvolat žádoucí chování i bez detailního skriptu (Min et al., 2022; Wei et al., 2022). V naší studii tak vznikají dvě funkce instrukcí: verifikační kroky vynucují měřitelné požadavky, zatímco obecnější konvence podporují designová rozhodnutí.

Zároveň ale platí, že vliv instrukcí nelze od nedeterminismu modelu oddělit dokonale. Razavi a Fard (Razavi & Fard, 2025) upozorňují na vysokou citlivost modelů na drobné změny promptu a naše pilotní i ablační běhy tento problém potvrzují. Proto je třeba naše výsledky číst jako indikativní syntézu na úrovni případové studie: ukazují, které typy instrukcí se v tomto prostředí osvědčily, ale neprokazují univerzální kauzální zákon.

5.3 Omezení a jejich dopad

Sekce 3.5 identifikovala metodologická omezení designu studie předem. Zde ukazujeme, jak se tato omezení projevila v naměřených datech, a popisujeme omezení která se objevila až v průběhu experimentu. Omezení řadíme podle toho, co ohrožují: nejprve sílu závěrů, pak spolehlivost měření a nakonec rozsah platnosti výsledků.

Nedeterminismus a prompt sensitivity. Pět binárních procesních metrik P1–P5 (splněno/nesplněno) kolísalo od 5/5 (r3) přes $\sim 3/5$ (r4) po $\sim 1/5$ (r5), přestože procesní instrukce v těchto bězích zůstaly stejné. R4 přidalo dva řádky do Constraints a procesní compliance se zhoršila, přestože žádná změna přímo necílila na workflow. Razavi a Fard (Razavi & Fard, 2025) tento jev popisují jako prompt sensitivity. Alternativním vysvětlením je efekt kumulace instrukcí: s rostoucím počtem instrukcí klesá pravděpodobnost dodržení všech současně. Instrukce rostly z r1 (baseline) do r5. Část poklesu compliance může být tímto efektem, ne jen citlivostí na formulaci.

Dva běhy na ablační variaci tento problém zmírňují, ale neposkytují statistickou sílu. Pokud oba běhy téže ablace ukazují stejný směr, je pravděpodobnější že jde o efekt ablace, ne o náhodu. Například Q5 (lint warnings) v ablaci A: oba běhy hlásily 4 a 3 lint warnings,

zatímco r3 (plné instrukce) hlásil 1. Shoda obou běhů zvyšuje důvěru, že odebrání sekce Process skutečně ovlivnilo Q5. Naopak Q2 (referenční test pass rate) v ablaci B: jeden běh dosáhl 37/42 projitých testů, druhý jen 11/42. Tak velký rozptyl mezi dvěma běhy se stejnými instrukcemi znamená, že rozdíl oproti r3 mohl být způsoben nedeterminismem modelu, ne ablací. Výsledky ablací proto interpretujeme jako indikace, ne jako statisticky podložené závěry. V kombinaci s vedlejšími efekty popsány výše (r4) to znamená, že každá úprava instrukcí vyžaduje měření celé sady metrik, ne jen těch na které úprava cílila.

Efekt učení autora. Zlepšení mezi iteracemi (r1: 4/10 deterministických kritérií, r3: 7/10) nemusí plynout jen z lepších instrukcí. Autor se v průběhu iterací učil diagnostikovat selhání a formulovat opravy. Tento efekt nelze od efektu instrukcí oddělit. Diagnostická fáze (výběr příčiny selhání a návrh opravy) závisí výhradně na autorovi a nezávislé ověření nebylo provedeno. Částečnou mitigací je použití strukturovaného diagnostického rámce (sekce 3.3.4): diagnóza se opírala o naměřená data a literaturou podložené principy, ne o intuici. Přesto nelze vyloučit, že zkušenější autor by z téhož baseline dosáhl lepších výsledků rychleji.

Změny konfigurace mezi běhy. Běhy r1–r2 proběhly bez kontejnerové izolace, od r3 běží agent v Docker kontejneru. Od r4 byla změněna konfigurace modelu (parametry kontextového okna). Tyto změny jsou potenciálním zavádějícím faktorem: regrese r4 mohla být částečně způsobena změnou konfigurace, ne pouze přidáním dvou řádků do Constraints. Hlavní proměnné (model, instrukce, specifikace) zůstaly konzistentní. Temperature modelu nebyla explicitně nastavena. Experiment používal výchozí konfiguraci poskytovatele.

Tiché ukončení nástroje. Při ablačních bězích se OpenCode v některých případech tiše ukončil uprostřed práce agenta. Běhy s vyšší spotřebou kontextového okna (ablace A: ~44 spuštění testů oproti ~20 u ablaci B) byly postiženy častěji. Postižené běhy byly opakovány. Pravděpodobnou příčinou je běh agenta uvnitř Docker kontejneru (spojení s API poskytovatele, limity paměti nebo síťové timeouty), ale příčina nebyla potvrzena.

Nerozlišující metriky. Q1 (API contract match), Q6 (typecheck errors) a E3 (stabilita session) nepřinesly na této úloze žádné rozlišení. Q1 byla splněna a Q6 zůstala nulová ve všech devíti bězích. E3 nezaznamenala žádnou kompakci kontextu. Pravděpodobným vysvětlením je design úlohy: specifikace poskytuje explicitní TypeScript typy (Q1, Q6) a úloha je dostatečně malá na to, aby se kontext nezaplnil (E3).

Kvalitativní metriky bez validace. Hlavní závěry studie stojí na deterministické metrice. kvalitativní metriky slouží jako podpůrné indikátory, protože jejich spolehlivost nebyla validována proti lidskému hodnocení (Cohenovo κ). Jedinou z nich, na které stojí netriviální závěr, je Q8 (design quality): jako jediná metrika zachytila pokles designové kvality v ablacích, který deterministické metriky nehlásily. Bez κ validace ale nelze sílu tohoto závěru plně posoudit.

Kontrolované podmínky vs. reálný vývoj. Experiment probíhal v kontrolovaném prostředí: prázdný repozitář, jedna úloha s kompletní specifikací, fixní sada metrik. Reálný vývoj zahrnuje nejednoznačné požadavky, měnící se specifikace a integraci s existujícím kódem. Instrukce optimalizované pro kontrolované podmínky (verifikační kroky, explicitní příkazy) nemusí

fungovat v prostředí kde specifikace není kompletní nebo se mění v průběhu práce.

Jeden model, jeden nástroj, jeden projekt. Omezení plynoucí z jednoho modelu, jednoho projektu a deterministické specifikace diskutuje sekce 3.5. V praxi se tato omezení projevila zejména u procesní metriky (P1–P8): variabilita neumožňuje odlišit efekt instrukcí od nedeterminismu modelu bez většího počtu běhů. Výsledky jsou navíc specifické pro OpenCode a model MiniMax-M2.5. Jiné nástroje (GitHub Copilot, Cursor, Claude Code) mohou zpracovávat instrukční soubory odlišně. Zda by instrukce fungovaly stejně na projektech s vyšší nejednoznačností specifikace, na jiných modelech nebo s jinými nástroji, zůstává otevřenou otázkou (sekce 5.5).

5.4 Doporučení pro praxi

Následující doporučení vycházejí z pilotních iterací a ablací popsaných v kapitole 4. Konkrétní čísla a prahy platí pro tento model a typ projektu. Přenositelný je iterační postup (měř → diagnostikuj → uprav → měř znovu) a principy strukturování instrukcí.

Operacionalizace instrukcí: verifikovat, nikoli jen vyslovit.

V pilotních iteracích se opakoval vzorec: obecné pravidlo (“každé pole musí být použito”) agent ignoroval, zatímco explicitní příkaz s okamžitou zpětnou vazbou (`npx eslint, tsc --noEmit`) dodržoval spolehlivě i v bězích, kde ignoroval zbytek pracovního postupu (sekce 4.3.2). Ablace potvrdila komplementární stranu: odstranění verifikačních kroků (ablace A) vedlo k poklesu Q2 (referenční test pass rate) z 41/42 na 35–37/42 a nárůstu Q5 (lint warnings) z 1 na 3–4 varování. Breunig (Breunig, 2025) formuloval stejný princip: když agent instrukci ignoruje, nepomůže ji zopakovat; je třeba ji převést na konkrétní akci. Spektrum operacionalizace (obrázek 5.4) popisuje, po jaké ose se intervence pohybují: čím blíže je instrukce verifikovatelnému příkazu, tím spolehlivěji ji agent v této případové studii dodržoval.

Ablace B ale ukázala i druhou stránku. Odstranění sekce Package Quality ponechalo automatizované metriky (deterministické metriky) beze změny, zatímco Q8 (design quality) kleslo z 3/3 na 2/3 (sekce 4.3.3). Konvence zřejmě nepůsobí jako přímé vynucení, ale spíš jako *aktivace* latentních znalostí modelu, tedy jako připomínka toho, co se model v tréninkových datech naučil. Z toho plyne praktické rozlišení: měřitelné požadavky převést na verifikovatelné kroky v pre-PR checklistu, zatímco požadavky, které nelze měřit deterministicky (srozumitelnost dokumentace, vhodnost dekompozice), strukturovat jako nápovědu, která modelu připomíná žádoucí směr. Účinnost deterministické větve přitom závisí na existenci nástroje s jednoznačným výstupem. Tam, kde takový nástroj chybí, je míra operacionalizace principiálně nižší (sekce 5.5). Závěr o designové kvalitě stojí na Q8, tedy na podpůrné judge-based metrice bez κ validace, a je proto nutné jej číst opatrně.

Počítat s nedeterminismem a měřit proces.

Agent dodržoval verifikační příkazy deterministicky, ale vícekový pracovní postup (issue → branch → test → PR) nedeterministicky: pilotní běh r3 dosáhl P1 (issues before code) = 5/5, běh r5 při téměř identických instrukcích P1 = ~1/5 (sekce 5.3). Na úrovni výsledku (Q2) přitom rozdíl nemusel být patrný. procesní metriky (P1–P8) zachytily problém, který produktové metriky (Q1–Q8) samy o sobě neodhalily. Doporučení: nespolehat na jednorázové ověření výstupu, zavést měřitelná exit kritéria pokrývající proces i kvalitu a kontrolovat je opakovaně.

Iterovat na základě dat.

Přínos této práce nespočívá v konkrétní instrukční sadě, ale v postupu jejího návrhu: naměřit metriky, diagnostikovat příčinu selhání, provést cílenou úpravu instrukcí a změřit znovu (sekce 3.3.4). Tento cyklus je přenositelný nezávisle na modelu a projektu. Podmínkou je sada metrik pokrývající více dimenzí (proces, kvalitu, efektivitu), protože jednodimenzionální měření (např. jen test pass rate) může zakrýt problém v jiné dimenzi (sekce 5.1).

Praktický důsledek je přímočarý: místo delšího a obecnějšího instrukčního souboru je účelnější budovat kratší, měřitelný pracovní postup s jasnými verifikačními body a opakovaně ho ladit podle dat.

5.5 Náměty pro další výzkum

Případová studie otevřela několik otázek, které přesahují rozsah této práce.

Nedeterminismus vícekového pracovního postupu.

Agent dodržoval verifikační příkazy (jednokrokové akce) deterministicky, ale vícekový pracovní postup (issue → branch → test → implement → PR) nedeterministicky: r3 kompletně, r5 vůbec, při téměř identických instrukcích. Možná vysvětlení zahrnují ztrátu pozornosti v dlouhém kontextovém okně, stochastickou volbu mezi strukturovaným a nestrukturovaným vývojem z tréninku modelu a pozici instrukce v kontextu. Granulární ablace pracovního postupu (které kroky jsou kritické?) a opakované běhy se stejnými instrukcemi by tento fenomén pomohly lépe pochopit.

Kontinuita práce mezi agenty.

procesní metriky (P1–P8) měří transparentnost artefaktů (issues, commit zprávy, PR popisy). Otevřená otázka: stačí tato transparentnost k tomu, aby jiný agent (nebo člověk) navázal na

rozpracovaný projekt? Testování handoff scénářů by ověřilo, zda procesní instrukce vytváří nejen pozorovatelný, ale i přenositelný pracovní kontext.

Automatizace iteračního postupu.

Fáze Diagnóza a Úprava jsou v této práci prováděny manuálně autorem. Frameworky jako PromptWizard (Agarwal et al., 2024) a Prompt Alchemy („Prompt Alchemy: Automatic Prompt Refinement for Enhancing Code Generation“, 2025) ukazují, že cyklus analýzy selhání a návrhu úprav lze automatizovat. Kombinace automatizovaného prompt optimizeru s metrikami P/Q/E by umožnila rychlejší iteraci bez manuální diagnózy.

Ingestion checkpoint.

Pilotní data ukazují, že agent instrukce přečte (v transcriptu cituje jejich obsah), ale ne vždy je aktivuje jako řídicí smyčku běhu. Místo pracovního postupu z `AGENTS.md` použije vlastní postup odvozený ze specifikace. Ověřitelný checkpoint na začátku běhu (agent musí explicitně potvrdit přečtení a aktivaci pracovního postupu před prvním zápisem kódu) by mohl tento problém adresovat.

Mechanismy účinku instrukcí a unfaithful reasoning.

Naše data naznačují dva odlišné mechanismy: *vynucení* (verifikační kroky přímo kontrolují výstup) a *aktivace* (obecné konvence připomínají modelu znalosti z tréninku). Analogie existuje v prompt engineeringu: chain-of-thought prompting ukazuje, že minimální náповěda může aktivovat komplexní latentní schopnost modelu efektivněji než detailní instrukce. Systematický experiment s odstupňovanou specifikitou instrukcí, od náповěd (“piš modulární kód”) přes pravidla (“každé pole musí být použito”) po verifikační kroky (“spuť `tsc`, oprav chyby”), by mohl identifikovat, která míra konkrétnosti je pro který typ požadavku optimální. Otevřená je i otázka, zda se toto optimum posouvá se schopnostmi modelu. Lepší modely by mohly potřebovat méně specifické instrukce (analogicky k expertise reversal effect v kognitivní psychologii, kde instrukce účinné pro nováčky zpomalují experty).

Generalizovatelnost verifikačních kroků.

Účinnost verifikačních kroků v naší studii závisela na existenci deterministických nástrojů (`eslint`, `tsc`, test runner), které produkují jednoznačný výstup zpět do kontextu agenta. Kódování je v tomto ohledu specifická doména: většina požadavků na kvalitu má odpovídající nástroj. U jiných typů úloh (dokumentace, architektonická rozhodnutí, plánování) takové nástroje neexistují a operacionalizace se zastaví na úrovni pravidla nebo příkazu bez externího

feedbacku. Otevřená otázka je, zda principy operacionalizace platí i mimo kódování, nebo zda je jejich účinnost podmíněna dostupností deterministické zpětné vazby.

Rozšíření na další modely a projekty.

Výsledky platí pro jeden model (MiniMax-M2.5) a jeden typ projektu (deterministická business logika). Replikace s jinými modely, nedeterministickými doménami (UI, strojové učení) a většími projekty by ukázala, které poznatky jsou přenositelné a které specifické pro tento případ. Zvláště zajímavá je otázka projektů s vyšší nejednoznačností specifikace (sekce 5.3), kde by obecnější instrukce (enabling constraints) mohly být efektivnější než detailní příkazy.

Závěr

Tato práce navrhla sadu metrik a iterativní postup pro systematické navrhování a vyhodnocování instrukcí pro AI coding agenty a ablacemi prozkoumala vliv jednotlivých složek instrukcí. Pro všechny tři cíle případová studie systému upomínek faktur demonstrovala proveditelnost navrženého postupu a přinesla indikativní poznatky. Studie zahrnovala pět pilotních iterací a čtyři ablační běhy.

Prvním cílem bylo navrhnout sadu metrik pokrývající proces a kvalitu práce agenta, ne jen výsledek. Výsledná sada 19 metrik pokrývá tři dimenze odvozené z taxonomie Fentona a Biemana. Procesní metriky odhalily problémy, které výsledkové metriky samy o sobě nezachytily: běh s téměř plným skóre funkčních testů vykazoval nestabilní procesní compliance. Kombinace deterministických a kvalitativních metrik přinesla komplementární pohled, protože každý typ zachycuje jinou dimenzi chování agenta.

Druhým cílem bylo iterativním postupem navrhnout instrukce, které dovedou agenta k dodržování stanovených exit kritérií. Cyklus měření, diagnózy a úpravy vedl k měřitelnému zlepšení, ale ne monotónnímu: jedna iterace způsobila regresi, po které bylo nutné vrátit se k předchozí verzi instrukcí. Opakujícím se vzorcem úspěšných úprav bylo nahrazení obecného pravidla konkrétním příkazem s verifikačním krokem. Účinnost tohoto postupu závisela na dostupnosti deterministických nástrojů s jednoznačným výstupem. U požadavků bez takového nástroje je dosažitelná míra operacionalizace nižší.

Třetím cílem bylo ablacemi prozkoumat, které složky instrukční sady přispívají k měřenému chování agenta. Verifikační kroky se ukázaly jako neredundantní: jejich odebrání zhoršilo funkční korektnost i čistotu kódu. Konvence kvality kódu automatizované metriky neovlivnily, ale designová kvalita hodnocená LLM-as-judge klesla. Výsledky zároveň ukázaly, že procesní compliance je výrazně citlivá na nedeterminismus modelu. Stejná sada instrukcí proto může vést k odlišnému dodržení vícekrokového workflow.

Hlavním přínosem práce je iterativní postup a sada metrik, které může praktik aplikovat na vlastním projektu s vlastními prahy. Konkrétní instrukce a naměřené hodnoty platí pro tuto případovou studii. Přenositelný je postup, ne výsledná čísla. Práce je omezena na jeden model a jeden projekt. Závěry mají povahu analytické generalizace na teorii, nikoliv statistické generalizace na populaci.

Pro praktika z toho plyne jednoduché doporučení: nestačí sledovat, zda agent úkol vyřešil, ale i jak k řešení došel a jak kvalitní kód zanechal. Pro akademického čtenáře práce ukazuje, že instrukce lze studovat ne jen jako promptový artefakt, ale jako samostatně měřenou nezávislou proměnnou, jejíž účinek je třeba hodnotit přes proces, produkt i náklady.

Bibliography

- ACE-Bench: End-to-End Feature Development Benchmark [212 tasks from 16 repos; Claude 4 Sonnet + OpenHands: 7.5% on feature-level tasks]. (2025). <https://openreview.net/forum?id=41xrZ3uGuI>
- Agarwal, A., et al. (2024). PromptWizard: Task-Aware Prompt Optimization Framework [Microsoft Research. arXiv:2405.18369. Iterativní Score→Critique→Synthesize cyklus pro optimalizaci promptů.].
- Bacchelli, A., & Bird, C. (2013). Expectations, Outcomes, and Challenges of Modern Code Review. *Proceedings of the 35th International Conference on Software Engineering*, 712–721. <https://doi.org/10.1109/ICSE.2013.6606617>
- Beck, K. (2000). *Extreme Programming Explained: Embrace Change*. Addison-Wesley.
- Breunig, D. (2025). Don't Fight the Weights [Defines fighting-the-weights: when prompt instructions oppose trained model behavior; recognition signs and mitigation strategies]. <https://www.dbreunig.com/2025/11/11/don-t-fight-the-weights.html>
- Ehsani, R., et al. (2026). Where Do AI Coding Agents Fail? An Empirical Study of Failed Agentic Pull Requests in GitHub [33k agent PRs, 5 coding agents, taxonomy of failures]. *Proceedings of MSR 2026*. <https://arxiv.org/abs/2601.15195>
- FeatureBench: Benchmarking Agentic Coding for Complex Feature Development [Agents struggle when scope exceeds single-issue; feature-level tasks significantly harder]. (2026). *arXiv preprint arXiv:2602.10975*.
- Fenton, N. E., & Bieman, J. (2014). *Software Metrics: A Rigorous and Practical Approach* (3rd ed.) [Process vs. product vs. resource metrics taxonomy; GQM framework]. CRC Press.
- Gloaguen, T., Mündler, N., Müller, M., Raychev, V., & Vechev, M. (2025). Evaluating AGENTS.md: Are Repository-Level Context Files Helpful for Coding Agents? [LLM-generated context files reduce success rate; developer-written marginally help (+4%); context files increase cost 20%+; agents follow instructions but no performance gain; AGENTBENCH benchmark (138 instances, 12 repos)]. *arXiv preprint arXiv:2602.11988*. <https://arxiv.org/abs/2602.11988>
- Gotel, O. C., & Finkelstein, A. C. (1994). An Analysis of the Requirements Traceability Problem. *Proceedings of IEEE International Conference on Requirements Engineering*, 94–101.
- Guo, J., Huang, S., Li, M., Huang, D., Chen, X., Zhang, R., Guo, Z., Yu, H., Yiu, S.-M., Lio, P., & Lam, K.-Y. (2025). A Comprehensive Survey on Benchmarks and Solutions in Software Engineering of LLM-Empowered Agentic System [Over 150 papers surveyed]. *arXiv preprint arXiv:2510.09721*. <https://arxiv.org/abs/2510.09721>
- Hassan, A. E., Li, H., Lin, D., Adams, B., Chen, T.-H., Kashiwa, Y., & Qiu, D. (2025). Agentic Software Engineering: Foundational Pillars and a Research Roadmap [SASE framework, BriefingScript, MentorScript, SE4H/SE4A duality]. *arXiv preprint arXiv:2509.06216*. <https://arxiv.org/abs/2509.06216>

- Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design Science in Information Systems Research [Foundational DSR framework: build-evaluate cycle, 7 guidelines for design science research]. *MIS Quarterly*, 28(1), 75–105. <https://doi.org/10.2307/25148625>
- Humble, J., & Farley, D. (2010). *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Addison-Wesley.
- Chen, J., Lin, J., Xiong, Y., Lu, J., Zhang, H., & Xie, T. (2025). Rethinking the Value of Agent-Generated Tests in Autonomous Code Repair [83.2% tasks same outcome regardless of test writing; tests serve as observational feedback]. *arXiv preprint arXiv:2505.21615*.
- Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. d. O., Kaplan, J., Edwards, H., Burda, Y., Joseph, N., Brockman, G., Ray, A., Puri, R., Krueger, G., Petrov, M., Khlaaf, H., Sastry, G., Mishkin, P., Chan, B., Gray, S., . . . Zaremba, W. (2021). Evaluating Large Language Models Trained on Code [Introduces HumanEval benchmark (164 hand-written Python problems) and Codex model. pass@k metric for functional correctness.]. *arXiv preprint arXiv:2107.03374*. <https://arxiv.org/abs/2107.03374>
- IEEE Computer Society. (2024). *Guide to the Software Engineering Body of Knowledge* (Version 4.0). <https://www.computer.org/education/bodies-of-knowledge/software-engineering>
- ISO/IEC. (2019). *ISO/IEC 33020:2019 Information technology — Process assessment — Process measurement framework for assessment of process capability* (tech. rep.) (Process capability rating scheme in the ISO/IEC 330xx family; successor to ISO/IEC 15504 (SPICE)). International Organization for Standardization. Geneva, Switzerland. <https://www.iso.org/standard/74273.html>
- ISO/IEC. (2023). *Systems and software engineering – Systems and software Quality Requirements and Evaluation (SQuaRE) – Product quality model* (tech. rep. No. ISO/IEC 25010:2023). International Organization for Standardization. Geneva. <https://www.iso.org/standard/78176.html>
- Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2024). SWE-bench: Can Language Models Resolve Real-World GitHub Issues? [2294 tasks from real GitHub repositories, de facto benchmark for AI coding agents]. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/2310.06770>
- Jin, H., Huang, L., Cai, H., Yan, J., Li, B., & Chen, H. (2024). From LLMs to LLM-based Agents for Software Engineering: A Survey of Current, Challenges and Future [Six SE areas covered: requirement engineering, code generation, autonomous decision-making, software design, test generation, software maintenance.]. *arXiv preprint arXiv:2408.02479*. <https://arxiv.org/abs/2408.02479>
- Kim, O. (2025). DETAIL Matters: Measuring the Impact of Prompt Specificity on Reasoning in Large Language Models [Emory University. Framework pro evaluaci vlivu specifčnosti promptu na reasoning. 30 úloh, GPT-4 a O3-mini]. *arXiv preprint arXiv:2512.02246*. <https://arxiv.org/abs/2512.02246>
- Li, B., Latendresse, J., Abdalkareem, R., & Shang, W. (2026). Beyond Bug Fixes: Post-Merge Code Quality Issues in Agent-Generated Pull Requests [1210 merged agent PRs, SonarQube analysis. Merge success unreliable indicator of quality. Code smells,

- complexity, duplicated code persist.]. *Proceedings of the 23rd International Conference on Mining Software Repositories (MSR)*. <https://arxiv.org/abs/2601.20109>
- Li, X., Chen, W., Liu, Y., Zheng, S., Chen, X., He, Y., Li, Y., et al. (2025). SkillsBench: Benchmarking How Well Agent Skills Work Across Diverse Tasks [Curated Skills +16.2pp; self-generated Skills -1.3pp; 2–3 focused modules optimal; comprehensive documentation hurts (-2.9pp); smaller model + Skills can exceed larger model without; 84 tasks, 11 domains, 7308 trajectories]. *arXiv preprint arXiv:2602.12670*. <https://arxiv.org/abs/2602.12670>
- Lindenbauer, T., et al. (2025). The Complexity Trap: Simple Observation Masking Is as Efficient as LLM Summarization for Agent Context Management [Observation masking halves cost, matches LLM summarization; hybrid reduces cost 7–11% further]. *NeurIPS*.
- Liu, J., Wang, K., Chen, Y., Peng, X., Chen, Z., Zhang, L., & Lou, Y. (2024). Large Language Model-Based Agents for Software Engineering: A Survey [124 papers surveyed]. *arXiv preprint arXiv:2409.02977*. <https://arxiv.org/abs/2409.02977>
- Lulla, K., Zhu, M., Kalliamvakou, E., & Mohylevsky, Y. (2026). On the Impact of AGENTS.md Files on AI Coding Agents [124 PRs across 10 repos: -28% runtime, -20% output tokens with AGENTS.md; architectural info and coding conventions most effective]. *arXiv preprint arXiv:2601.20404*. <https://arxiv.org/abs/2601.20404>
- Mao, Y., He, J., & Chen, C. (2025). From Prompts to Templates: A Systematic Prompt Template Analysis for Real-world LLM Applications [Merged 4 frameworks (Google Cloud, Elavis Saravia, CRISPE, LangGPT); 7 component types; Directive 87% prevalence]. *Proceedings of the ACM International Conference on the Foundations of Software Engineering (FSE)*. <https://arxiv.org/abs/2504.02052>
- Mathews, N. S., & Nagappan, M. (2024). LLM-Based Test Generation as Bug Validation: Insights from Reproducing Real-World Bugs [68.1% generated test suites validate bugs instead of detecting them]. *Proceedings of the 1st ACM International Conference on AI-Powered Software (AIware)*. <https://doi.org/10.1145/3664646.3664766>
- McCabe, T. J. (1976). A Complexity Measure. *IEEE Transactions on Software Engineering, SE-2*(4), 308–320. <https://doi.org/10.1109/TSE.1976.233837>
- McCall, J. A., Richards, P. K., & Walters, G. F. (1977). *Factors in Software Quality. Volume I: Concepts and Definitions of Software Quality* (tech. rep. No. RADC-TR-77-369, Volume I) (Final technical report). General Electric Company, Information Systems Programs. Rome Air Development Center, Griffiss Air Force Base, New York. <https://cgi.csc.liv.ac.uk/~comp208/2013/GetTRDoc.pdf>
- McConnell, S. (2004). *Code Complete: A Practical Handbook of Software Construction* (2nd). Microsoft Press.
- McIntosh, S., Kamei, Y., Adams, B., & Hassan, A. E. (2016). An Empirical Study of the Impact of Modern Code Review Practices on Software Quality. *Empirical Software Engineering, 21*(5), 2146–2189. <https://doi.org/10.1007/s10664-015-9381-9>
- METR. (2025). Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity [RCT: 16 developers, 246 tasks; AI tools slowed experienced developers by 19%; developers believed they were 24% faster]. *arXiv preprint arXiv:2507.09089*. <https://arxiv.org/abs/2507.09089>

- METR. (2026). Many SWE-bench-Passing PRs Would Not Be Merged into Main [296 patches reviewed by 4 maintainers from 3 SWE-bench repos. ~24pp gap between automated pass rate and maintainer merge decisions. Technical report.]. <https://metr.org/notes/2026-03-10-many-swe-bench-passing-prs-would-not-be-merged-into-main/>
- Miguel, J. P., Mauricio, D., & Rodríguez, G. (2014). A Review of Software Quality Models for the Evaluation of Software Products. *International Journal of Software Engineering & Applications (IJSEA)*, 5(6), 31–53. <https://doi.org/10.5121/ijsea.2014.5603>
- Min, S., Lyu, X., Holtzman, A., Artetxe, M., Lewis, M., Hajishirzi, H., & Zettlemoyer, L. (2022). Rethinking the Role of Demonstrations: What Makes In-Context Learning Work? [Label space, input distribution a formát jsou klíčové pro ICL, ne správnost label-input mapování]. *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*. <https://arxiv.org/abs/2202.12837>
- Nonaka, I., & Takeuchi, H. (1995). *The Knowledge-Creating Company: How Japanese Companies Create the Dynamics of Innovation*. Oxford University Press.
- Panickssery, A., Bowman, S. R., & Feng, S. (2024). LLM Evaluators Recognize and Favor Their Own Generations [Causal link: self-recognition → self-preference; linear correlation; fine-tuning pushes recognition to 90%+]. *Advances in Neural Information Processing Systems (NeurIPS)*. <https://arxiv.org/abs/2404.13076>
- Papadakis, M., Kintis, M., Zhang, J., Jia, Y., Le Traon, Y., & Harman, M. (2019). Mutation Testing Advances: An Analysis and Survey [Mutation score stronger predictor of fault detection than structural coverage]. *Advances in Computers*, 112, 275–378. <https://doi.org/10.1016/bs.adcom.2018.03.015>
- Paulk, M. C., Curtis, B., Chrissis, M. B., & Weber, C. V. (1993). Capability Maturity Model, Version 1.1 [Definition of five maturity levels for software process; foundational reference for CMM/CMMI tradition of organizational process assessment.]. *IEEE Software*, 10(4), 18–27. <https://doi.org/10.1109/52.219617>
- Peffer, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2008). A Design Science Research Methodology for Information Systems Research. *Journal of Management Information Systems*, 24(3), 45–77. <https://doi.org/10.2753/MIS0742-1222240302>
- Prompt Alchemy: Automatic Prompt Refinement for Enhancing Code Generation [arXiv:2503.11085. Iterativní refinement promptů pro code generation, evaluate přes execution.]. (2025).
- Rafique, Y., & Mišić, V. B. (2013). The Effects of Test-Driven Development on External Quality and Productivity: A Meta-Analysis. *IEEE Transactions on Software Engineering*, 39(6), 835–856. <https://doi.org/10.1109/TSE.2012.28>
- Razavi, S. P., & Fard, F. H. (2025). What Did I Do Wrong? Quantifying LLMs’ Sensitivity and Consistency to Prompt Engineering [Up to 76 accuracy points difference from subtle formatting changes in few-shot settings]. *Proceedings of NAACL*. <https://arxiv.org/abs/2406.12334>
- Runeson, P., & Höst, M. (2009). Guidelines for Conducting and Reporting Case Study Research in Software Engineering. *Empirical Software Engineering*, 14(2), 131–164. <https://doi.org/10.1007/s10664-008-9102-8>

- Scale AI. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? [1865 human-verified tasks, adds explicit Requirements and Interface sections to issues]. *arXiv preprint arXiv:2509.16941*. <https://arxiv.org/abs/2509.16941>
- Shihab, E., Bird, C., & Zimmermann, T. (2012). The Effect of Branching Strategies on Software Quality. *Proceedings of the ACM-IEEE International Symposium on Empirical Software Engineering and Measurement*, 301–310. <https://doi.org/10.1145/2372251.2372305>
- Shin, J., Tang, C., Mohati, T., Nayebi, M., Wang, S., & Hemmati, H. (2025). Prompt Engineering or Fine-Tuning: An Empirical Assessment of Large Language Models for Code. *Proceedings of the 22nd International Conference on Mining Software Repositories (MSR)*. <https://arxiv.org/abs/2310.10508>
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N., & Scialom, T. (2023). Toolformer: Language Models Can Teach Themselves to Use Tools. *arXiv preprint arXiv:2302.04761*.
- Sommerville, I. (2016). *Software Engineering* (10th). Pearson.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.
- Verga, P., Hofstätter, S., Cer, D., & Thorne, J. (2024). Replacing Judges with Juries: Evaluating LLM Generations with a Panel of Diverse Models [Panel of LLM evaluators (PoLL) outperforms single GPT-4 judge; disjoint model families reduce intra-model bias; 7x cheaper]. *arXiv preprint arXiv:2404.18796*. <https://arxiv.org/abs/2404.18796>
- Watanabe, M., Li, H., Kashiwa, Y., Reid, B., Iida, H., & Hassan, A. E. (2025). On the Use of Agentic Coding: An Empirical Study of Pull Requests on GitHub [Under review. 567 Claude Code PRs, 157 projects, 83.8% acceptance rate]. *ACM Transactions on Software Engineering and Methodology*.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E. H., Le, Q. V., & Zhou, D. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models [Google Research. Few-shot CoT exempláře zlepšují reasoning na aritmetických, commonsense a symbolických úlohách]. *Advances in Neural Information Processing Systems (NeurIPS)*, 35. <https://arxiv.org/abs/2201.11903>
- Yang, J., Jimenez, C. E., Wettig, A., Liber, K., Narasimhan, K., & Press, O. (2024). SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering [ACI ablation: +10.7pp over baseline shell; context management and error guardrails largest gains]. *NeurIPS*.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. *International Conference on Learning Representations (ICLR)*.
- Yin, R. K. (2018). *Case Study Research and Applications: Design and Methods* (6th ed.) [Embedded single-case design; analytic generalization (to theory, not population)]. SAGE Publications.
- Yin, Z., Wang, J., Li, J., Shi, D., Wei, Y., Yue, Y., Liu, Z., Xia, X., & Lo, D. (2025). A Comprehensive Empirical Evaluation of Agent Frameworks on Code-centric Software Engineering Tasks. *arXiv preprint arXiv:2511.00872*.

- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena [Foundational LLM-as-judge paper; position bias, verbosity bias, self-enhancement bias; GPT-4 >80% human agreement]. *Advances in Neural Information Processing Systems (NeurIPS)*. <https://arxiv.org/abs/2306.05685>
- Zi, Y., Menon, H., & Guha, A. (2025). More Than a Score: Probing the Impact of Prompt Specificity on LLM Code Generation [PartialOrderEval framework. Partial order of prompts from minimal to maximally detailed. HumanEval + ParEval]. *arXiv preprint arXiv:2508.03678*. <https://arxiv.org/abs/2508.03678>

Přílohy

A. Formulář v plném znění

B. Zdrojové kódy výpočetních procedur

C. Baseline AGENTS.md

Baseline verze AGENTS.md (pilot-r1) a její souhrnná evoluce do pilot-r3 jsou uvedeny v kapitole 5 (obrázky 4.1 a 4.6).

D. Využití nástrojů umělé inteligence

Při přípravě práce byl využit nástroj Claude (Anthropic, modely Opus 4 a Sonnet 4) jako AI asistent v následujících oblastech:

Psaní textu práce. Nástroj byl využit pro drafting a úpravu textových částí (kapitoly 1–5), kontrolu konzistence argumentace a LaTeX formátování. Autor formuloval záměr a strukturu každé sekce; AI asistent navrhoval formulace, které autor revidoval a upravoval. Výzkumný design, argumentace a finální znění jsou autorovy vlastní.

Vyhledávání a shrnutí literatury. Nástroj byl využit k identifikaci relevantních zdrojů a shrnutí obsahu papers. Autor ověřoval relevanci a správnost každého zdroje před zařazením do textu; citace odkazují výhradně na zdroje přečtené a posouzené autorem.

Diagnostická analýza v experimentu. V kroku Diagnóza iteračního cyklu (sekce 3.3.4) byl nástroj využit jako analytický asistent: výzkumník popisoval naměřené výsledky, AI asistent navrhoval možné příčiny selhání a opravy instrukcí na základě literatury. Finální rozhodnutí o každé změně `AGENTS.md` bylo vždy na autorovi.

Implementace měřicí infrastruktury. Experimentální skripty (`new-run.ts`, `analyze-run.ts`, `judge.ts`) byly implementovány s asistencí AI nástroje na základě autorova návrhu specifikace metrik. Autor navrhl architekturu, definoval požadované výstupy a provedl validaci správnosti měření (příloha D).

AI nástroj nepouštěl experimenty, nevyhodnocoval výsledky a nerozhodoval o směru výzkumu. Za celý obsah práce nese plnou odpovědnost autor.