

Vysoká škola ekonomická v Praze

Fakulta informatiky a statistiky



# **Prototyp AI agenta: GenAI pro správu metadat v podnikovém prostředí**

## **DIPLOMOVÁ PRÁCE**

Studijní program: Informační systémy a Technologie

Studijní obor: Business Intelligence

Autor: Bc. Magdalena Staňková

Vedoucí diplomové práce: doc. Ing. Ota Novotný, Ph.D.

Praha, červen 2025

## **Prohlášení**

Prohlašuji a čestně uvádím, že jsem diplomovou práci s názvem „Prototyp AI agenta: GenAI pro správu metadat v podnikovém prostředí“ vypracovala samostatně, za použití v práci uvedených parametrů a literatury.

V Praze dne 25. 06. 2025

Bc. Magdalena Staňková

## **Poděkování**

Tímto bych ráda vyjádřila svou upřímnou vděčnost všem, kteří mě podporovali při psaní této diplomové práce a v rámci celého studia.

V první řadě děkuji svému vedoucímu práce, doc. Ing. Otovi Novotnému, Ph.D., za odborné vedení, cenné rady a trpělivost, kterou mi věnoval během tvorby této práce. Upřímné díky patří mé rodině a blízkým přátelům, kteří mi dodávali sílu v obtížných chvílích. Největší poděkování ale směřuje mému manželovi Ing. Štěpánu Staňkovi, který byl mojí oporou na každém kroku, bez něj by tato práce nevznikla v podobě, v jaké ji nyní držíte.

Děkuji ještě jednou všem za pomoc, lásku a důvěru.

## **Abstrakt**

Tato diplomová práce se zabývá problematikou správy metadat v podnikovém prostředí se zaměřením na možnosti využití generativní umělé inteligence. V kontextu rostoucího objemu a rozmanitosti dat představuje efektivní správa metadat klíčový předpoklad pro řízení datových aktiv a zajištění kvality informací v organizaci. Cílem práce je analyzovat aktuální přístupy k metadata managementu, identifikovat možnosti a limity využití generativní AI v této oblasti a navrhnout i experimentálně ověřit funkční prototyp AI agenta pro automatizovanou správu metadat. Výsledky práce poskytují praktická doporučení pro zavádění GenAI do metadatových procesů a přináší srovnání výkonnosti ručních a automatizovaných postupů. Závěry a doporučení mohou sloužit jako inspirace pro další implementace v rámci podnikového řízení dat.

## **Klíčová slova**

Generativní umělá inteligence, metadata, automatizace, AI agent, business intelligence

## **Abstract**

This thesis deals with the issue of metadata management in an enterprise environment with a focus on the possibilities of using generative artificial intelligence. In the context of increasing volume and variety of data, effective metadata management is a key prerequisite for managing data assets and ensuring information quality in an organization. The aim of this work is to analyze current approaches to metadata management, identify the possibilities and limits of using generative AI in this area, and design and experimentally validate a working prototype AI agent for automated metadata management. The results of the work provide practical recommendations for the implementation of GenAI in metadata processes and provide a comparison of the performance of manual and automated approaches. The conclusions and recommendations can serve as inspiration for further implementations within enterprise data management.

## **Keywords**

Generative artificial intelligence, metadata, automation, AI agent, business intelligence

# Obsah

|                                                                                           |    |
|-------------------------------------------------------------------------------------------|----|
| Úvod.....                                                                                 | 9  |
| 1 Rešerše: metadata a GenAI v kontextu řízení dat.....                                    | 13 |
| 1.1 Přehled literatury a současného stavu výzkumu.....                                    | 13 |
| 1.1.1 Akademické zdroje.....                                                              | 13 |
| 1.1.2 Praktické aplikace .....                                                            | 16 |
| 1.2 Klíčové oblasti aplikace GenAI v kontextu metadat.....                                | 18 |
| 1.2.1 Výhody a nevýhody nasazení GenAI v podnicích.....                                   | 20 |
| 1.2.2 Příklad aplikace metadat v různých odvětvích.....                                   | 21 |
| 1.3 AI agenti ve správě metadat .....                                                     | 23 |
| 1.3.1 Vymezení pojmu AI agent .....                                                       | 24 |
| 1.3.2 Princip fungování generativních AI agentů .....                                     | 25 |
| 1.3.3 Možnosti využití AI agentů v oblasti metadat .....                                  | 25 |
| 1.3.4 Přínosy oproti klasickým modelům GenAI.....                                         | 26 |
| 1.3.5 Výzvy a rizika AI agentů .....                                                      | 27 |
| 1.4 Shrnutí zjištění a prostor pro další rozvoj.....                                      | 27 |
| 2 Metadata management .....                                                               | 28 |
| 2.1 Význam metadat nejen v podnikovém prostředí .....                                     | 28 |
| 2.2 Role metadat v podnikové sféře .....                                                  | 28 |
| 3 Harmonizace metadat.....                                                                | 31 |
| 3.1 Proces harmonizace metadat .....                                                      | 31 |
| 3.1.1 Nástroje pro podporu harmonizace metadat.....                                       | 31 |
| 3.2 Metodologie harmonizace metadat.....                                                  | 32 |
| 3.2.1 Kritéria hodnocení úspěšnosti harmonizace.....                                      | 33 |
| 4 Analýza výchozího stavu správy metadat a identifikace vhodných míst pro využití AI..... | 34 |
| 4.1 Charakteristika manuální správy metadat.....                                          | 34 |
| 4.1.1 Zmapování hlavních problémů manuální správy metadat .....                           | 35 |
| 4.2 Využití GenAI pro správu metadat.....                                                 | 36 |
| 4.2.1 Identifikace příležitostí pro využití GenAI ve správě metadat .....                 | 37 |
| 4.3 Shrnutí hlavních zjištění kapitoly .....                                              | 38 |
| 4.3.1 Začlenění vlastního výzkumu do procesu správy metadat.....                          | 38 |

|       |                                                                        |    |
|-------|------------------------------------------------------------------------|----|
| 5     | Experimentální návrh a testování AI agenta pro správu metadat .....    | 39 |
| 5.1   | Cíl experimentu a rámec praktického řešení .....                       | 39 |
| 5.2   | Návrh architektury AI agenta .....                                     | 40 |
| 5.3   | Použité technologie a nástroje .....                                   | 41 |
| 5.4   | Vývoj prototypu AI agenta .....                                        | 42 |
| 5.5   | Nasazení a zpřístupnění agenta.....                                    | 43 |
| 5.5.1 | Kódové řešení a napojení na OpenAI API .....                           | 44 |
| 5.6   | Testování a vyhodnocení .....                                          | 49 |
| 5.6.1 | Metodika testování .....                                               | 49 |
| 5.6.2 | Testovací scénáře .....                                                | 50 |
| 5.6.3 | Výsledky testování AI agenta .....                                     | 52 |
| 5.7   | Shrnutí experimentální části .....                                     | 54 |
| 6     | Porovnání efektivity správy metadat před a po nasazení AI agenta ..... | 55 |
| 6.1   | Měření a porovnání vybraného use-case .....                            | 55 |
| 6.2   | Přínosy a omezení řešení .....                                         | 55 |
| 6.3   | Doporučení pro praxi a další rozvoj .....                              | 56 |
|       | Závěr .....                                                            | 58 |
|       | Použitá literatura .....                                               | 60 |
|       | Přílohy .....                                                          | I  |
|       | Příloha A: Kód zdrojových souborů AI agenta.....                       | I  |

## Seznam zkratk

|     |                                          |
|-----|------------------------------------------|
| GEN | generativní                              |
| AI  | umělá inteligence                        |
| GPT | generativní před-trénovaný transformátor |
| NLP | zpracování přirozeného jazyka            |
| LLM | velký jazykový model                     |



# Úvod

V dnešní digitální éře představují data jednu z nejcennějších komodit napříč odvětvími, což klade vysoké nároky na správné řízení dat. Metadata hrají klíčovou roli při efektivním řízení a využívání datových aktiv (Bourne, 2024). Dle Ramachandrana a ostatní autorů (2024) „*metadata pomáhají zajistit, aby společnosti zodpovědně trénovaly algoritmy na správných datech ve správném kontextu a v souladu s platnými předpisy, omezeními nebo zásadami.*“<sup>1</sup>

Generativní umělá inteligence představuje slibný nástroj pro správu metadat, neboť má předpoklady pro umožnění automatického generování a obohacování metadat, což usnadňuje jejich správu a následné využití (Ramachandran et al., 2024). Může například automaticky generovat popisky či anotace datovým objektům, identifikovat běžné obchodní termíny, či obohacovat metadata o kontextuální informace (Puli, 2024a). GenAI přitahuje v posledních letech pozornost odborníků díky své schopnosti vytvářet obsah či dané vzory na základě vstupních dat. Třetí čtvrtletní zpráva roku 2024 Deloitte AI Institute<sup>TM</sup> o stavu generativní AI ve firmách ukazuje, že 2/3 organizací, přesněji 67 %, zvyšují své investice do generativní AI, a to především kvůli jejímu potenciálu. Zpráva však poukazuje i na překážky GenAI ve společnostech, kdy tou nejzásadnější je řízení rizik (Deloitte, 2024).

## Vymezení problémové oblasti

V současné době čelí organizace stále větší složitosti při správě rozsáhlých a různorodých datových souborů. Nedostatečně harmonizovaná metadata představují zásadní překážku efektivní integrace dat, jejich dohledatelnosti a následného využití pro analytické či rozhodovací účely. Vzhledem k rostoucím požadavkům na transparentnost, kvalitu a interoperabilitu dat je potřeba nalézt nové přístupy, které umožní tuto problematiku řešit systematicky a s využitím moderních technologií (DAMA, 2017).

## Důvod výběru tématu a omezení práce

Výběr tématu této diplomové práce pramení především z autorčiny osobní zkušenosti, kdy vnímá, že generativní umělá inteligence se stala každodenní součástí její práce i osobního života a cítí, jak zásadně proměňuje nejen oblast business intelligence, ale i širší sféru řízení dat. Sleduje rychlý nástup nástrojů postavených na principech GenAI a zejména trend AI agentů, kteří čím dál více automatizuje a usnadňuje rutinní procesy. Autorka věří, že význam generativní AI v oblasti správy a harmonizace metadat bude nadále narůstat a stane se klíčovým prvkem moderního řízení dat. Téma zvolila nejen kvůli jeho aktuálnosti, ale i kvůli přesvědčení, že poznatky z této práce najdou praktické uplatnění v reálném firemním prostředí.

---

<sup>1</sup> Překlad Autorka

Omezení práce spočívá především v mimořádně dynamickém vývoji generativní umělé inteligence a souvisejících technologií. Nové nástroje, modely i přístupy se objevují v krátkých časových intervalech, což komplikuje jejich dlouhodobé srovnání a evaluaci. Další omezení představuje skutečnost, že v rámci experimentální části se autorka věnuje tvorbě AI agenta, přestože nemá silné programátorské zázemí, jejím cílem však bylo osvojit si nové dovednosti a prakticky si ověřit možnosti využití těchto technologií.

## **Cíle práce**

Hlavním cílem této práce je navrhnout a experimentálně ověřit prototyp AI agenta, který bude schopen efektivně podporovat proces správy a harmonizace metadat v podnikové praxi.

K naplnění hlavního cíle byly stanoveny následující dílčí cíle:

1. Provedení rešerše odborných zdrojů se zaměřením na problematiku metadata managementu a aktuální trendy v oblasti GenAI
2. Analýza a porovnání existujících metod pro správu a harmonizaci metadat.
3. Návrh, implementace a otestování funkčního prototypu AI agenta pro generování, obohacování a validaci metadat.
4. Porovnání výkonnosti správy metadat s využitím AI agenta a bez něj, doporučení pro budoucí využití generativní AI v oblasti metadata managementu.

## **Metody a způsob dosažení cíle práce**

K dosažení stanového cíle práce byla nejprve provedena rešerše odborné literatury, zaměřená na současné trendy a aplikační možnosti generativní umělé inteligence v oblasti správy a harmonizace metadat. Na základě zjištěných poznatků byla následně analyzována vhodnost jednotlivých přístupů a identifikovány klíčové výzvy spojené s implementací těchto metod v podnikovém prostředí.

Součástí metodického postupu byl návrh a experimentální ověření AI agenta pro správu a harmonizaci metadat. Tento prototyp byl implementován a testován na reálných datech, přičemž byly sledovány zejména aspekty efektivity, přesnosti a automatizace procesu generování a úpravy metadat.

Celkový přístup kombinuje metody literární rešerše, srovnávací analýzy a experimentální validace, což umožňuje komplexní zhodnocení potenciálu generativní AI v dané oblasti.

## **Struktura práce**

Práce je členěna do jednotlivých kapitol a má následující strukturu:

### **1. Rešerše: metadata a GenAI v kontextu řízení dat**

Úvodní kapitola této diplomové práce je zaměřena na zdokumentování přehledu současného stavu poznání v oblasti metadata managementu a generativní umělé inteligence. Je zde systematicky zmapována odborná literatura a aplikovaný výzkum, přičemž cílem je identifikace klíčových trendů, příležitostí a rizik spojených s využitím GenAI při správě a harmonizaci metadat. Výsledky rešerše poskytují teoretický základ pro analytické i experimentální části práce a zároveň vymezují rámec dalšího zkoumání v dané oblasti.

### **2. Metadata management**

Druhá kapitola této diplomové práce podrobně rozebírá role metadat v podnikovém prostředí. Kapitola navazuje na rešerši a blíže rozpracovává význam metadat, jejich klasifikaci a přínosy pro efektivní řízení datových aktiv. Důraz je kladen na praktické aspekty metadata managementu, s nimiž se organizace setkávají, a možnosti jejich řešení.

### **3. Harmonizace metadat**

Třetí kapitola této diplomové práce se zaměřuje na samotný proces harmonizace metadat v prostředí s různorodými datovými zdroji. Jsou zde podrobně popsány hlavní etapy harmonizačního procesu, používané metodiky a nástroje pro standardizaci a integraci metadat. Kapitola zároveň vymezuje kritéria pro hodnocení úspěšnosti procesu harmonizace.

### **4. Analýza výchozího stavu správy metadat a identifikace vhodných míst pro využití AI**

Čtvrtá kapitola diplomové práce přináší ucelený pohled na správu metadat, a to jak z perspektivy manuálních postupů, tak s ohledem na možnost automatizace prostřednictvím generativní umělé inteligence. Je zde zdokumentován proces manuální evidence a harmonizace metadat, včetně časové náročnosti a identifikace úzkých míst v pracovním postupu. Součástí je kvalifikovaný odhad vycházející z řízených rozhovorů se zástupci z praxe, na jejichž základě jsou určeny konkrétní oblasti, kde je ruční práce nejvíce zatěžující, časově náročná nebo náchylná k chybám. V druhé části kapitoly je představena možnost využití generativní AI a jsou identifikovány procesy, které by bylo vhodné zautomatizovat. Výstupy této analýzy tvoří základ pro návrh experimentálního řešení rozpracovaný v následující kapitole.

## **5. Experimentální návrh a testování AI agenta pro správu metadat**

V páté kapitole této diplomové práce jsou na základě poznatků z předešlé kapitoly navrženy, implementovány a otestovány klíčové funkce AI agenta pro podporu správy a harmonizace metadat, přičemž agent cílí zejména na automatizaci těch nejkritičtějších a nejvíce problematických míst celého procesu. Kapitola se zaměřuje na popis architektury řešení, výběr použitých technologií a metodiku experimentálního ověření přínosu automatizace

## **6. Porovnání efektivity správy metadat před a po nasazení AI agenta**

Šestá kapitola diplomové práce shrnuje a porovnává klíčové rozdíly mezi stavem správy metadat bez využití umělé inteligence a s nasazením AI agenta. Na základě výsledků experimentální části práce jsou zde zhodnoceny dopady automatizace na efektivitu, kvalitu a spolehlivost správy metadat. Kapitola rovněž obsahuje interpretaci hlavních přínosů a limitací řešení a nabízí doporučení pro další implementace v praxi i výzkumu.

## **Přínos práce**

Hlavním přínosem práce je návrh a experimentální ověření funkčního prototypu AI agenta, který dokáže automatizovat klíčové úlohy při správě a harmonizaci metadat v podnikovém prostředí. Výsledky experimentu ukazují, že generativní umělá inteligence může výrazně zefektivnit procesy spojené s generováním, kategorizací a kontrolou kvality metadat, což přináší úsporu času a snižuje míru manuálních chyb. Práce zároveň přináší ucelený přehled současných trendů v oblasti metadata managementu a inspiraci pro další rozvoj automatizovaných nástrojů, které mohou významně posílit kvalitu datových procesů ve firmách i ve veřejném sektoru. Navržený přístup může sloužit jako metodický základ pro další aplikace GenAI v oblasti data governance.

# 1 Rešerše: metadata a GenAI v kontextu řízení dat

Úvodní kapitola této diplomové práce je zaměřena na zdokumentování přehledu současného stavu poznání v oblasti metadata managementu a generativní umělé inteligence. Je zde systematicky zmapována odborná literatura a aplikovaný výzkum, přičemž cílem je identifikace klíčových trendů, příležitostí a rizik spojených s využitím GenAI při správě a harmonizaci metadat. Výsledky rešerše poskytují teoretický základ pro analytické i experimentální části práce a zároveň vymezují rámec dalšího zkoumání v dané oblasti.

## 1.1 Přehled literatury a současného stavu výzkumu

Cílem rešerše není pouze sumarizace dostupných přístupů, ale zejména kritická reflexe toho, jak lze GenAI využít ke zvýšení kvality a použitelnosti metadat. Na základě zjištěných poznatků jsou v práci rovněž naznačeny oblasti, které si zasluhují systematický rozvoj v rámci budoucího směřování metadata managementu. Rešeršní část je koncipována jako přehled relevantních odborných zdrojů a aplikovaných přístupů, které propojují oblast generativní AI s doménou metadata managementu.

Výzkum aplikace generativní umělé inteligence v oblasti metadata managementu je stále relativně novým, avšak dynamicky se rozvíjejícím směrem. S rozmachem velkých jazykových modelů (LLMs, anglicky Large Language Models), jako jsou GPT-4 či PaLM 2, se objevují nové možnosti, jak automatizovat procesy tvorby, validace i harmonizace metadat (Lorica, 2023).

### 1.1.1 Akademické zdroje

V této části se autorka věnuje rešerši a identifikaci akademických zdrojů, které se zabývají integrací generativní umělé inteligence do procesů správy metadat. Autorka se zaměřuje na ty zdroje, které popisují konkrétní aplikace, přínosy či výzvy spojené s využitím GenAI v této oblasti.

Hledané výrazy byly sestaveny z klíčových slov „generative AI“, „metadata management“, „metadata harmonization“ a „AI – powered metadata“. Mezi elektronické zdroje patří ProQuest, EBSCO, Web of Science a Google Scholar. K vyhledávání byly využity zdroje knihovny Vysoké školy ekonomické a byly provedeny v Q2 roku 2025. Seznam hledaných výrazů a výsledky vyhledávání jsou uvedeny v Tabulka 1.

| HLEDANÝ VÝRAZ                                                                   | Web of Science | ProQuest | EBSCO | Scopus |
|---------------------------------------------------------------------------------|----------------|----------|-------|--------|
| title ("generative AI") OR title ("genAI") AND title ("metadata management")    | 9              | 447      | 1     | 27     |
| title ("generative AI") OR title ("genAI") AND title ("metadata harmonization") | 35             | 4        | 0     | 0      |
| title ("AI-powered metadata")                                                   | 10             | 45       | 2     | 0      |
| Title ("AI agent/s") AND title ("metadata")                                     | 22             | 19       | 4     | 4      |

Tabulka 1: Nalezené zdroje ve stanovených vyhledávacích (vlastní zpracování)

Z provedené rešerše vyplývá, že kombinace generativní umělé inteligence a harmonizace metadat představuje velmi aktuální a dynamicky se rozvíjející oblast, která však vychází už z dřívějších zaměření. Databáze ProQuest poskytla autorce nejvyšší počet výsledků, a to napříč různými formulacemi dotazů, což naznačuje široké pokrytí tématu v aplikační i výzkumné rovině. Web of Science identifikoval menší množství záznamů, které jsou však přesnější a reflektují především vznikající akademický zájem o oblast metadata managementu a jeho propojení s AI. Databáze EBSCO v tomto ohledu přinesla pouze omezené množství výstupů, což může naznačovat, že se téma v jejím rámci zatím nerozšířilo do širšího výzkumu. Databáze Scopus vrátila 27 výsledků, z nichž pouze několik bylo relevantních.

Dodatečně byl rešeršní dotaz rozšířen o klíčová slova související s AI agenty, neboť právě ty představují jedno z technických řešení pro integraci GenAI do správy a obohacování metadat. Výsledky této části rešerše ukázaly, že téma AI agentů v souvislosti s metadaty je v odborné literatuře zastoupeno mírně, a ne moc konzistentně – ve všech databázích byly identifikovány jednotky až nižší desítky výsledků. Za relevantní byl pro účely práce zvolen zejména jeden článek dohledaný skrze databázi EBSCO, který popisuje konkrétní aplikaci AI agentů v oblasti správy metadat v rámci content management systémů.

Na základě prostudování abstraktů jednotlivých publikací autorka identifikovala ty, které považuje za relevantní pro tuto diplomovou práci, a dále je podrobněji rozebírá v následujících odstavcích.

Studie *Evaluating a large language model's ability to answer clinicians' requests for evidence summaries* autorů Blasingame, Koonce, Williams a kol. (2025), publikovaná v Journal of the Medical Library Association, nalezena skrze EBSCO databázi. Se zabývá využitím generativní umělé inteligence, konkrétně modelu GPT-4, v knihovnické praxi. Ačkoli se práce přímo nevěnuje harmonizaci metadat, je v kontextu rešerše částečně relevantní díky svému zaměření na uplatnění generativní umělé inteligence právě v prostředí knihoven a informačních služeb – ukazuje konkrétní případ, kde je AI nasazena pro zpracování a syntézu odborných informací. Přestože problematika metadat zde není hlavním tématem, lze studii považovat za přínosnou v širším rámci mapování

možností využití GenAI v práci s informacemi. Její zařazení do rešerše pomáhá ilustrovat současné trendy a může sloužit jako výchozí bod pro sledování dalších výzkumů.

Príspevek prezentovaný na konferenci Congress in Computer Science, Computer Engineering, & Applied Computing (CSCE) v roce 2023, konané v Las Vegas – *Metadata: An Integral Component of the Modern Data Strategy*, dohledaný skrze databázi ProQuest. Který se zaměřuje na klíčovou roli metadat v datovém řízení organizací a na potenciál generativní umělé. Studie explicitně propojuje oblast generativní AI a metadata governance, a to nejen na teoretické úrovni, ale i prostřednictvím praktického proof-of-concept experimentu využívajícího model GPT-3.5 a embedding model text-ada-002 na COVID-19 datasetu. Autoři ukazují, jak kvalita metadat ovlivňuje výstupy generativních modelů a zároveň, jak samotná GenAI může přispět k lepší interpretaci, integraci a správě metadat. Práce je pro tuto rešerši velmi přínosná, jelikož přináší jak analytický pohled, tak praktické ověření přínosů GenAI při harmonizaci datových struktur. Zároveň reflektuje důležité etické a technické otázky, jako jsou bezpečnost, zaujatost a ochrana soukromí.

Konferenční příspěvek *The Impact of AI on Metadata* autorky Charlene Chou (2024), nalezený prostřednictvím databáze Scopus, se věnuje dopadům generativní umělé inteligence na správu a tvorbu metadat. V rámci tzv. AI Study Group byly testovány různé generativní AI nástroje – jako ChatGPT, Claude nebo BERT – z hlediska jejich využitelnosti při vytváření metadat pro různé typy informačních zdrojů. Příspěvek zdůrazňuje nejen praktické přínosy těchto nástrojů, ale také otázky etiky, odpovědného využívání a potřeby nastavení vhodných metodických rámců.

Studie *Building Metadata Normalization Using Generative AI* autorů Borrisona, Aleksyho a Dixe (2024), publikovaná ve sborníku konference IEEE 19th Conference on Industrial Electronics and Applications (ICIEA), nalezena skrze databázi Web of Science. Se zabývá využitím předtrénovaných velkých jazykových modelů pro účely normalizace metadat ve smart building systémech. Ačkoli se zaměřuje na specifickou doménu řízení budov a energetické účinnosti, je v kontextu rešerše relevantní, neboť se přímo věnuje harmonizaci nestrukturovaných metadat pomocí generativní umělé inteligence. Studie dokládá, že použití modelů GenAI, bez nutnosti dodatečného tréninku, umožňuje strukturovat přirozený jazyk, čímž přispívá k jejich interoperabilitě a lepšímu využití v automatizovaných systémech. Zařazení této práce do rešerše ilustruje praktické využití generativních modelů v oblasti metadatového managementu.

Oficiální dokument *Request for Information on AI and Open Government Data Assets*, vydaný americkým Ministerstvem obchodu (2024), který byl nalezený skrze ProQuest, představuje významný příspěvek do diskuse o připravenosti veřejných dat pro využití v systémech generativní umělé inteligence. Ačkoli se nejedná o klasickou odbornou studii, dokument je v kontextu rešerše vysoce relevantní, neboť se věnuje harmonizaci, standardizaci a obohacování metadat. Dokument zdůrazňuje důležitost sémanticky bohatých a strojově srozumitelných formátů a znalostních grafů jako nástrojů pro zvýšení přístupnosti a kvality dat. Výzva dále poukazuje na nutnost sladění metadat s existujícími standardy a rozšiřuje diskuzi o důvěryhodnosti, transparentnosti a etickém využívání dat v prostředí GenAI.

Studie *Are we there yet? Evaluation of AI-generated metadata for online information resources* autorů Zavalin a Zavalina (2024), publikovaná online a nalezená přes Web of Science, se přímo zabývá problematikou automatického generování popisných metadat pomocí generativních AI nástrojů. Autoři provedli experimentální analýzu kvality metadat vytvořených pomocí tří různých AI

modelů, a to i včetně ChatGPT-4. Výsledky ukazují, že ačkoliv nástroje jako ChatGPT vykazují mírně lepší výsledky v oblasti úplnosti záznamů, celková přesnost metadat je zatím nízká a nezaručuje dostatečnou kvalitu pro profesionální informační služby. Studie je velmi přínosná pro tuto rešerši, neboť poskytuje konkrétní poznatky o limitech současné generativní AI při harmonizaci a tvorbě metadat, a zároveň zdůrazňuje potřebu lidské expertízy při zajištění kvality a funkčnosti.

Zpráva GrayMeta Iris Media Platform Adds AI-Powered Media Intelligence (2019), publikovaná v Business Wire a nalezená v databázi EBSCO, představuje firemní sdělení o nasazení AI do systému pro správu metadat v mediálním průmyslu. Přestože se nejedná o odbornou studii, ale o PR text, její zařazení do rešerše je opodstatněné – popisuje totiž konkrétní využití umělé inteligence pro zefektivnění práce s metadaty. Zejména při jejich vytváření, úpravě či časovém označování v rámci audiovizuálního obsahu, zmiňované funkce jako rozpoznávání řeči, scén či loga ukazují, jak lze umělou inteligenci zapojit do automatizovaných procesů v komerční praxi. Data zprávy poukazuje na to, že téma AI v metadatovém managementu není nové, ale představuje dlouhodobě sledovanou oblast vývoje, jejíž současný rozmach staví na předchozích technologiích a zkušenostech.

Příkladem aktuálního firemního využití generativní umělé inteligence a agentních přístupů v oblasti správy metadat je řešení společnosti Aprimo, které bylo identifikováno prostřednictvím databáze EBSCO a představuje relevantní ukázkou aktuálních trendů v komerční sféře. Ta v roce 2025 představila rozšířenou platformu AI agentů, která podporuje automatizaci napříč celým cyklem práce s obsahem – od plánování, přes generování metadat, až po transformaci a dodržování standardů značky. AI agenti zde zajišťují škálovatelnou automatizaci rutinních rozhodnutí a manuálních úkonů, čímž umožňují efektivnější řízení digitálních aktiv bez zvyšování složitosti systémů. Tento příklad ukazuje, že koncept AI agentů již není pouze teoretickým modelem, ale reálně nasazeným řešením ve správě metadat a obsahu na podnikovém stupni.

Akademická literatura poskytuje cenný rámec pro pochopení možností a limitů generativní AI v oblasti metadat. Pro úplný pohled je však vhodné doplnit jej o analýzu praktických v reálném podnikatelském prostředí, čemuž se věnuje následující podkapitola.

### 1.1.2 Praktické aplikace

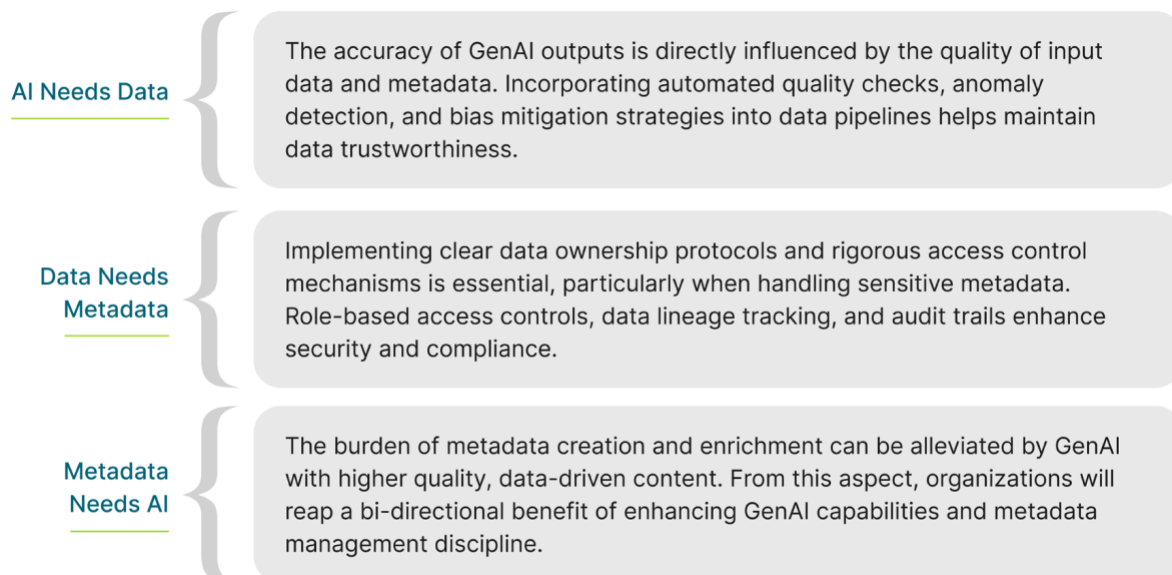
Pro rozšíření rešerše o praktické aplikace generativní umělé inteligence ve správě metadat je důležité pochopit, jak přední technologické společnosti implementují tyto technologie v reálných podmínkách. Zatímco akademický výzkum poskytuje teoretické základy a experimentální ověření, komerční praxe ukazuje, jak jsou tyto koncepty převáděny. Analýza přístupů společností jako Informatica a Guidehouse odhaluje, jak GenAI přispívá k automatizaci, zlepšení kvality dat a efektivnějšímu rozhodování v oblasti správy metadat.

Společnost Informatica v rámci svého řešení pro správu hlavních dat – *Master Data Management (MDM)* integruje generativní umělou inteligenci s cílem zvýšit přesnost dat, automatizovat procesy a zlepšit uživatelský komfort při práci s rozsáhlými datovými soubory. Podle oficiálního přehledu využití, GenAI usnadňuje klasifikaci, sjednocování a obohacování dat, například pomocí automatického tagování produktových záznamů, konsolidací duplicit nebo validací neúplných datových profilů. Generativní modely zároveň přispívají k vyšší kvalitě spravovaných dat tím, že dokážou na základě přirozeného jazyka pomáhat uživatelům orientovat se v datech a podporovat



rozhodování. V případě platformy CLAIRE od Informatiky se ukazuje, že nasazení GenAI výrazně zkracuje čas potřebný pro klasifikaci dat a zvyšuje produktivitu týmu.

Společnost Guidehouse ve svém příspěvku od Karen Bourne: *Metadata Management an GenAI: Mutualistic Accelerators* popisuje potenciál generativní umělé inteligence jako katalyzátoru pokročilé správy metadat v datově orientovaných organizacích. Integrace GenAI umožňuje automatizovanou tvorbu nebo i obohacování metadat, čímž napomáhá snižovat tzv. metadatový dluh (anglicky: metadata debt) a zároveň poskytuje nové nástroje pro podporu datově podloženého rozhodování. Autoři zdůrazňují, že přínosy GenAI zasahují všechny hlavní oblasti metadat – technickou, provozní i byznysovou – a že její využití umožňuje hlubší pochopení datových toků, uživatelských dotazů nebo i kontextu využití dat. Guidehouse zároveň upozorňuje, že úspěšné nasazení těchto technologií vyžaduje správné propojení s existujícími systémy, průběžné vyhodnocování dopadů a implementaci etických zásad, zejména v oblastech ochrany soukromí, transparentnosti a řízení rizik.



Obrázek 1: Propojení mezi AI, daty a metadatami (Bourne, 2024)

Vztah mezi generativní umělou inteligencí, daty a metadatami je oboustranný a vzájemně podmíněný, jak můžeme vidět na Obrázek 1, který přehledně shrnuje, že nejen GenAI potřebuje kvalitní a strukturované vstupy, ale i metadata těží z automatizace, kterou umožňuje právě generativní AI. Obrázek zároveň ilustruje důležitost lidského dohledu a řízení přístupu v rámci správy metadat, zejména v kontextu bezpečnosti, souladu s regulacemi a transparentnosti.

V následujících odstavcích autorka podrobněji rozebírá význam jednotlivých částí z Obrázek 1, které přeložila pro účely práce samaObrázek 1.

## 1. Umělá inteligence potřebuje data

*„Přesnost výstupů generativní AI je přímo ovlivněna kvalitou vstupních dat a metadat. Začlenění automatických kontrol kvality, detekce anomálií a strategie pro zmírnění zaujatosti (anglicky bias) do datových toků pomáhá udržovat důvěryhodnost dat.“*

Tento překlad klade důraz na to, že GenAI sama o sobě nemůže fungovat správně bez kvalitních vstupů. Metadata jsou klíčová pro správnou funkčnost modelů. Automatizace a kontrola kvality vstupních dat jsou tedy nezbytné pro dosažení spolehlivých výstupů.

## **2. Data potřebují metadata**

*„Zavedení jasných pravidel pro vlastnictví dat a důsledné mechanismy řízení přístupu je zásadní, zejména při práci s citlivými metadaty. Rolemi řízené přístupy, sledování datového původu a kontrolní záznamy zvyšují bezpečnost a zajištění souladu.“*

Tato část zdůrazňuje nezbytnost silné data governance jako nedílnou součást práce s metadaty, tedy správy, bezpečnosti a souladu s předpisy. Metadata zajišťují kontext pro data: kdo je vytvořil, kdo s nimi může pracovat, jak byla dříve upravována, aby byla srozumitelná, dohledatelná a správně spravována.

## **3. Metadata potřebují umělou inteligenci**

*„Zátěž spojenou s tvorbou a obohacováním metadat lze zmírnit pomocí generativní AI, která poskytuje kvalitnější a datově podložený obsah. Z tohoto pohledu získávají organizace oboustranný přínos – zlepšení schopností generativní AI a zároveň zkvalitnění řízení metadat.“*

V této části se ukazuje, že vztah mezi AI a metadaty není jednostranný. Metadata nejen podporují GenAI, ale sama mohou z umělé inteligence těžit, zejména co se týče efektivnějšího vytváření, aktualizace a rozšiřování. Automatizace metadatových procesů tak může zlepšit celý ekosystém správy dat.

# **1.2 Klíčové oblasti aplikace GenAI v kontextu metadat**

Generativní umělá inteligence nachází v oblasti metadata managementu uplatnění napříč několika klíčovými oblastmi, které pokrývají technické, procesní i organizační aspekty práce s daty. Moderní GenAI nástroje přispívají ke zvyšování kvality, konzistence i přístupnosti metadat a zároveň podporují jejich efektivnější správu a využití v souladu s regulačními požadavky. Důležitou roli zde hrají i inteligentní agenti, kteří díky schopnosti samostatného rozhodování a učení rozšiřují možnosti klasických nástrojů.

GenAI je specifická podmnožina umělé inteligence zaměřená na tvorbu nového obsahu, jako jsou texty, obrázky, zvukové záznamy nebo i komplexní modely. Na rozdíl od klasických modelů AI, které se specializují na klasifikaci nebo analýzu dat, GenAI dokáže na základě vstupních dat generovat nové informace. Tento přístup je postaven na pokročilých technologiích, jako jsou transformery a hluboké neuronové sítě (Brown et al., 2020). Jedním z nejvýznamnějších přelomů v oblasti GenAI bylo představení architektury transformerů, které umožňují modelům zpracovávat data ve větších souvislostech díky mechanismu zvanému „attention“ (pozornost). Tento mechanismus pomáhá modelu pochopit, jak jednotlivé části vstupních dat souvisejí a jak je lze efektivně zpracovat (Vaswani et al., 2017).

Například modely jako GPT od společnosti OpenAI, využívají transformery k pochopení a generování přirozeného jazyka na základě velkých tréninkových dat. Transformers také umožňují paralelní zpracování dat, což je zásadní pro jejich efektivitu při velkých objemech dat. Hluboké neuronové sítě pak fungují jako základní stavební prvek GenAI. Tyto sítě jsou schopny analyzovat složité vzory ve vstupních datech a na jejich základě vytvářet výstupy, které napodobují reálné jevy. Jejich použití sahá od generování textů a obrázků až po pokročilé simulace nebo analýzu datových vzorů (Goodfellow et al., 2016).

Následující řádky přibližují konkrétní oblasti aplikace generativní umělé inteligence v této doméně.

## **1. Automatizace generování a obohacování metadat**

Generativní AI umožňuje automatizované vytváření a obohacování metadat, čímž zvyšuje efektivitu a konzistenci datových popisů. Například studie od Singh a spol. představuje metodu využívající vyhledávání rozšířené (anglicky retrieval-augmented) o generativní modely k automatickému generování popisů pro datové katalogy, což vede k výraznému zlepšení vyhledatelnosti a použitelnosti datových sad (M. Singh et al., 2025).

## **2. Zlepšení vyhledatelnosti a přístupnosti dat**

Kvalitní metadata jsou klíčová pro efektivní vyhledávání, organizaci a interpretaci datových zdrojů. Integrace AI do procesů správy metadat může umožnit lepší organizaci a klasifikaci dat, což následně usnadňuje nalezení a využití relevantních dat, což podporuje informovaná rozhodnutí. Studie od Martorana a spol. ukazuje, jak lze využít velké jazykové modely k automatickému přiřazování témat sloupcům v datových sadách, což zlepšuje jejich vyhledatelnost a interoperabilitu (Martorana et al., 2024).

## **3. Podpora správy dat a dodržování předpisů**

Kromě technické podpory hraje GenAI klíčovou roli také v oblasti řízení dat a zajištění souladu s legislativními a etickými požadavky. Automatizací procesů, jako je sledování původu dat (anglicky data lineage) a validace metadat, přispívá k lepší transparentnosti a dodržování předpisů. Příkladem je studie od Sundaram a Musen, která demonstruje, jak AI může standardizovat metadata v souladu s komunitními standardy, což zvyšuje kvalitu a důvěryhodnost dat (Sundaram & Musen, 2025).

## **4. Nasazení inteligentních agentů pro správu metadat**


Inteligentní agenti založení na generativní AI představují pokročilý přístup k automatizaci správy metadat. Tyto agenti mohou samostatně provádět úkoly, jako je detekce nekonzistencí, nebo i obohacování metadat a jejich audit v reálném čase. Například platforma Oracle Cloud Infrastructure využívá generativní AI agenty k interakci s podnikovými datovými úložišti prostřednictvím přirozeného jazyka, což umožňuje efektivnější správu a využití dat (Oracle Cloud Infrastructure, 2025). Koncept inteligentních agentů bude detailněji rozpracován v samostatné kapitole, která se zaměřuje na jejich principy, architekturu a praktické uplatnění v metadatových procesech.

### 1.2.1 Výhody a nevýhody nasazení GenAI v podnicích

Generativní umělá inteligence přináší podstatné výhody, které mohou podnikům pomoci zefektivnit jejich procesy a zvýšit konkurenceschopnost. Jednou z hlavních výhod je výrazné zlepšení efektivity. Automatizace rutinních úkolů, jako je generování reportů, odpovědi na zákaznické dotazy nebo analýza dat, šetří čas a snižuje náklady, což umožňuje zaměstnancům soustředit se na strategičtější činnosti (Marin, 2024). Další významnou výhodou je schopnost personalizace, GenAI dokáže analyzovat uživatelská data a vytvářet obsah na míru jednotlivým zákazníkům, což vede k lepšímu zákaznickému zážitku a větší spokojenosti. V neposlední řadě nabízí GenAI příležitost k inovacím. Díky schopnosti generovat nové modely, simulace a optimalizace podnikových procesů pomáhá objevovat nové možnosti, které by byly tradičními metodami obtížně dosažitelné.

Navzdory mnoha výhodám má nasazení GenAI také svá omezení a rizika. Jedním z hlavních problémů je otázka ochrany dat. Generativní modely vyžadují přístup k velkým množstvím dat, což může zvýšit riziko jejich zneužití nebo narušení soukromí, zejména pokud nejsou zavedeny dostatečné bezpečnostní mechanismy (Das, 2024). Implementace těchto modelů je rovněž náročná z hlediska financí a odbornosti. Vyžaduje značné investice do infrastruktury, školení personálu a tréninku modelů, což může být překážkou zejména pro menší firmy (IMD, 2023).

Generativní AI představuje nejen technologický nástroj, ale potenciální klíčový prvek v moderním metadata managementu. Pro její efektivní využití je však zásadní porozumět samotnému procesu harmonizace metadat, tedy tomu, jak data vznikají, jak jsou udržována a využívána v organizacích.



Obrázek 2: Porozumění typům metadat (Bourne, 2024)

Obrázek 2 doplňuje výše uvedené členění metadat a rozšiřuje jej o další dimenzi, která je v kontextu digitální transformace a nástupu generativní umělé inteligence stále důležitější, a to jejich propojení s konkrétními oblastmi využití a automatizace. Vizualizace ukazuje, že metadata v podnikových systémech lze dále dělit na:

- **Technická metadata** - např. informace o formátu, tabulkách, sloupcích či databázích
- **Provozní metadata** - např. data o přístupu, logy, pravidla používání
- **Obchodní/business metadata** - např. pojmy, štítky, kontext použití dat

K těmto třem kategoriím jsou přiřazeny tzv. AI akcelerátory, které reprezentují konkrétní domény, ve kterých může umělá inteligence významně podpořit automatizaci či zkvalitnění procesů. Například v případě technických metadat se jedná o automatizovanou inventarizaci a katalogizaci datových aktiv, u provozních metadat o využití pravidel a rozpoznávání vzorů v chování uživatelů nebo systémech, zatímco business metadata jsou obohacována zejména o sémantickou vrstvu a kontextové informace. Na pravé straně schématu jsou znázorněny příklady praktických funkcionalit, jejichž realizaci umožňuje právě kombinace těchto přístupů: patří mezi ně například automatizované vyhledávání a identifikace dat, průběžná aktualizace katalogů, detekce anomálií, generování syntetických dat, implementace přirozeně jazykového vyhledávání nebo automatizované tagování a kontextové obohacování metadatových záznamů.

Tato vizualizace potvrzuje, že správné nastavení metadat a jejich propojení s AI nástroji představuje základní předpoklad pro úspěšné řízení dat v moderním podnikovém prostředí.

## **1.2.2 Příklad aplikace metadat v různých odvětvích**

Metadata nacházejí široké uplatnění v různých odvětvích. Ve zdravotnictví pomáhají organizovat lékařské záznamy, sledovat vývoj pacienta nebo spravovat data pro klinické studie. Maloobchod využívá metadata k optimalizaci skladových zásob, sledování zákaznických preferencí a personalizaci nabídek. V oblasti informačních technologií metadata umožňují efektivní správu rozsáhlých databází, podporují analytické nástroje a usnadňují integraci různých systémů (Puli, 2024b). Správně spravovaná metadata tak nejen zlepšují přístup k datům, ale také zvyšují efektivitu procesů a umožňují organizacím lépe čelit výzvám moderního podnikání.

### **1.2.2.1 Zdravotnictví**

Jak by ale vypadalo výše zmiňované zdravotnictví, kdyby se zde metadata využívala na 100 % svého potenciálu? To by znamenalo, že veškerá zdravotnická data by byla perfektně strukturována, aktuální a plně interoperabilní mezi různými systémy a institucemi (Octopai, 2020). To by přineslo mnoho zásadních přínosů:

#### **1. Zlepšení klinického rozhodování**

Metadata umožňují zdravotníkům rychlý přístup k informacím o pacientech, jako jsou anamnéza, alergie, výsledky laboratorních testů nebo předepsaná medikace. Díky tomu by lékaři mohli rychleji a přesněji rozhodovat o diagnózách a následné léčbě (DeBrow, 2024). Klinické rozhodovací systémy (CDSS, v angličtině clinical decision support system), které pracují s metadaty, prokazatelně zvyšují přesnost rozhodování a zlepšují výsledky léčby pacientů, omezují lékařské chyby a zvyšují efektivitu tím, že lékařům poskytují doporučení založená na důkazech. Nicméně implementace, přijetí a správa těchto systémů zůstává zdravotnickou výzvou (Chen et al., 2023).

#### **2. Efektivní řízení nemocnic a zdravotnických zařízení**

Metadata mohou pomoci optimalizovat využívání zdrojů, jako jsou lůžka, přístroje či zdravotnický personál, a zároveň podpořit plánování provozu. V krizových situacích, jako je pandemie COVID-19, by metadata mohla pomoci lépe sledovat dostupnost ventilátorů, vakcín nebo ochranných prostředků a řídit distribuci těchto zdrojů (Fabreau et al., 2021).

Systematická přehledová studie analyzující 22 výzkumů zjistila, že využití optimalizačních modelů založených na metadatech vedlo k výraznému zlepšení efektivity distribuce omezených zdrojů, jako jsou ventilátory, lůžka a vakcíny, a přispělo k lepší kontrole šíření epidemie (Wang et al., 2024).

### **3. Snížení chybovosti a zlepšení péče**

Metadata mohou pomoci eliminovat chyby při sdílení informací mezi zdravotnickými zařízeními. Například při převozu/překladi pacienta z jedné nemocnice do druhé by metadata zajistila, že veškeré informace o léčbě, diagnózách a alergiích budou správně přeneseny a zohledněny. Dalším příkladem je využití metadat k monitorování užívaných léčiv - metadata umožňují automatickou detekci možných kontraindikací mezi užívanými léky, což snižuje riziko nežádoucích interakcí a zlepšuje bezpečnost léčby, zároveň také může zvýšit důvěru u pacientů (de Mello et al., 2022).

Například, technologie jako barcodové skenování při podávání léků (BCMA, v angličtině Barcode medication administration technology) zajišťují, že pacient obdrží správný lék ve správné dávce a čase. Tato technologie výrazně snižuje počet chyb o 48,3 % při podávání léků a zvyšuje bezpečnost pacientů (Mulac et al., 2021).

#### **1.2.2.2 Maloobchod**

V maloobchodním sektoru mohou metadata také hrát klíčovou roli například při optimalizaci skladových zásob, sledování zákaznických preferencí nebo při personalizaci nabídek. Pokud by metadata byla v maloobchodě využita naplno, znamenalo by to vytvoření vysoce adaptivního systému, kde by každá interakce zákazníka, pohyb produktu nebo i dodavatelský tok byl nejen zaznamenán, ale zároveň zanalyzován a využit k predikci budoucího chování.

##### **1. Optimalizace skladových zásob**

Metadata umožňují maloobchodníkům efektivně řídit zásoby a předvídat poptávku. Například společnost Levi's využívá RFID technologii (anglicky radio frequency identification, tedy identifikace pomocí rádiových vln) k sledování zásob v reálném čase, což vede k lepší dostupnosti produktů a zvýšení prodeje. Detego, poskytovatel softwaru pro správu zásob, uvádí, že jejich řešení vedla k nárůstu prodeje o 3–10 % (McDowell, 2019).

##### **2. Sledování zákaznických preferencí**

V dnešní době zákazníci nejenže oceňují personalizaci, ale často ji i očekávají. Studie společnosti McKinsey ukazuje, že 71 % spotřebitelů očekává personalizované interakce, a 76 % z nich je frustrováno, pokud jim značky nedokážou nabídnout relevantní zážitky (Lindecrantz et al., 2020). Tato očekávání vedou k tomu, že zákazníci podvědomě chtějí, aby si obchody pamatovaly jejich preference a nákupní historii. Když jim obchody následně nabídnou odpovídající produkty, zvyšuje se jejich spokojenost a loajalita.

### **3. Personalizace nabídek**

Personalizace nabídek v maloobchodě se stále více zaměřuje na využití dat o předchozích nákupech zákazníků a analýzu podobných produktových variant. Tento přístup umožňuje obchodníkům nabízet zákazníkům relevantní produkty, které odpovídají jejich preferencím a nákupnímu chování. Například e-shopy mohou analyzovat historii nákupů zákazníka a na základě toho doporučovat produkty, které jsou často kupovány společně nebo jsou podobné těm, které si zákazník již zakoupil (Gregor, 2021).

#### **1.2.2.3 Informační technologie**

V oblasti informačních technologií jsou metadata nezbytná pro efektivní správu rozsáhlých databází, podporu analytických nástrojů a usnadnění integrace různých systémů. Dalo by se říct, že představují páteř, která umožňuje systémům mluvit společným jazykem.

##### **1. Správa databází**

Metadata poskytují kontext k datům uloženým v databázích, což usnadňuje jejich správu a zajišťuje konzistenci. Například technická metadata obsahují informace o struktuře databáze, datových typech a vztazích mezi tabulkami (Shaikh, 2024).

##### **2. Podpora analytických a BI nástrojů**

Metadata zlepšují kvalitu dat a umožňují efektivnější analýzu. Například nástroje pro správu metadat, jako je Informatica, využívají metadata k poskytování kontextu pro analytické nástroje, což vede k lepším obchodním rozhodnutím (Bannocks, 2019).

##### **3. Integrace systémů**

Metadata usnadňují integraci různých systémů tím, že poskytují jednotný pohled na data. Například technická metadata umožňují propojení různých databází a systémů, což zajišťuje hladkou výměnu dat mezi nimi (Shaikh, 2024).

### **1.3 AI agenti ve správě metadat**

V posledních letech lze v oblasti správy metadat sledovat významný posun, který souvisí s nástupem nástrojů využívajících principy umělé inteligence, včetně tzv. AI agentů – autonomních softwarových entit schopných samostatně vnímat své prostředí, rozhodovat se a jednat za účelem dosažení stanovených cílů. Na rozdíl od tradičních generativních modelů umělé inteligence, které generují výstupy na základě jednotlivých vstupů, AI agenti operují v rámci komplexních úloh, plánují kroky a adaptují se na měnící se podmínky (Shivaram, 2025). Tato schopnost činí AI agenty zvláště vhodnými pro správu metadat, kde je třeba neustále dynamicky reagovat a zajišťovat konzistenci a kvalitu metadat napříč systémy.

Význam AI agentů v oblasti správy metadat je potvrzen i rostoucím zájmem podniků o jejich implementaci. Podle zprávy společnosti LangChain z roku 2024 se AI agenti stávají nedílnou

součástí pracovních postupů napříč odvětvími, od automatizace rutinních úkolů po asistenci při analýze dat či generování kódu.

Implementace AI agentů ve správě metadat však přináší i nové výzvy, jako je potřeba definovat standardizovaná metadata pro jejich efektivní fungování, zajistit transparentnost jejich rozhodovacích procesů a ochrana před potenciálními riziky. Například společnost Salesforce zdůrazňuje, že metadata jsou klíčovým prvkem úspěšného ekosystému, protože umožňují AI systémům a agentům interpretovat, adaptovat se a škálovat napříč rozsáhlými a komplexními datovými sadami (Tallapragada, 2025).

V následujících podkapitolách se autorka podrobněji zaměří na konkrétní aspekty využití nejen AI agentů ve správě metadat, jejich přínosy, omezení a perspektivy dalšího vývoje v této oblasti.

### 1.3.1 Vymezení pojmu AI agent

Zatímco klasické generativní modely slouží především k jednorázové produkci výstupů na základě konkrétního vstupu, AI agenti představují další vývojový stupeň, který propojuje schopnosti GenAI s principy autonomie, plánování a paměti.

V oblasti umělé inteligence je pojem „agent“ definován jako entita, která vnímá své okolí prostřednictvím senzorů a na základě tohoto vnímání činí akce prostřednictvím efektorů s cílem maximalizovat užitek v čase. Tento koncept je základem pro vývoj systémů, které jsou schopny autonomního rozhodování a jednání v různých prostředích (Russell & Norvig, 2022). Klíčovým aspektem inteligentního agenta je jeho schopnost jednat racionálně, tj. vybírat takové akce, které maximalizují očekávaný užitek na základě dostupných informací. Tento princip je znám jako princip maximální očekávané užitečnosti (anglicky maximum expected utility, zkratkou MEU) a je základním kamenem rozhodovací teorie v oblasti umělé inteligence (Danesh, 2020).

AI agenti se vyznačují několika klíčovými vlastnostmi:

- **Autonomie** – schopnost jednat bez přímého lidského zásahu.
- **Cílené plánování** – formulace a aktualizace plánů k dosažení stanovených cílů.
- **Učení a adaptace** – schopnost zlepšovat se na základě zkušeností a změn v prostředí.

Příkladem implementace AI agentů jsou projekty jako Auto-GPT a BabyAGI, které využívají velké jazykové modely k autonomnímu plnění komplexních úkolů (Sullivan, 2023). Tyto systémy jsou schopny generovat, prioritizovat a vykonávat úkoly na základě předem definovaných cílů, čímž demonstrují praktické využití agentního přístupu v oblasti umělé inteligence (Vogel, 2023).

#### 1.3.1.1 Srovnání klasických generativních modelů a agentního přístupu


Klasické nástroje generativní umělé inteligence, jako jsou ChatGPT, Claude nebo Gemini, jsou navrženy jako reaktivní modely, které generují odpověď na základě jediného vstupu bez uchovávání dlouhodobého kontextu či schopnosti samostatného plánování. Využívají architekturu transformátorů a fungují na principu pravděpodobnostního doplňování textu, což z nich činí výkonné nástroje pro generování obsahu, sumarizaci textů nebo překladu jazyků (Brown et al., 2020; Vaswani et al., 2017).



Oproti tomu agentní architektura rozšiřuje schopnosti generativní AI tím, že integruje paměť, plánování a rozhodovací mechanismy. AI agenti dokáží nejen reagovat na podněty, ale také formulovat cíle, rozdělit úkoly do dílčích kroků, přizpůsobovat se okolnímu prostředí nebo se učit z předchozí zkušenosti. Agentní přístup tedy posouvá umělou inteligenci z pouhého generování výstupů ke skutečnému autonomnímu rozhodování (Park et al., 2023).

### 1.3.2 Princip fungování generativních AI agentů

Obrázek 3 znázorňuje základní architekturu a workflow tohoto přístupu – uživatelský dotaz je převeden do podoby vhodné pro zpracování, systém prohledá datové úložiště, seřadí relevantní dokumenty podle sémantické relevance, vytvoří odpověď a doplní ji odkazy na použitá data. Takové řešení má významný potenciál pro automatizaci správy metadat, zejména při vytváření sémantických anotací, kategorizaci dokumentů či sledování data lineage (Oracle Cloud Infrastructure, 2025).



Obrázek 3: Princip fungování generativních AI agentů v prostředí OCI, (Oracle Cloud Infrastructure, 2025)

### 1.3.3 Možnosti využití AI agentů v oblasti metadat

Vzhledem k rostoucí komplexitě datových systémů a potřebě efektivní správy metadat ve společnostech, nabízejí AI agenti inovativní přístupy k automatizaci a zlepšení procesů. Tato část práce analyzuje, jak AI agenti přispívají k automatickému mapování datových polí, kontextualizaci metadat a zastupování uživatelů při správě datových katalogů.

AI agenti umožňují automatické mapování datových polí napříč systémy, kdy na základě historických vzorů a učením se z předchozích mapovacích úloh identifikují odpovídající atributy mezi heterogenními zdroji bez manuální intervence (Naresh, 2024). Díky schopnosti kontextualizace a generování metadat na základě interakce s více zdroji dokáží agenti kombinovat popisná, strukturální i sémantická metadata, což vede k bohatšímu a přesnějšímu popisu datových objektů. AI agenti mohou také zastupovat uživatele při správě datových katalogů – automatizují orchestrace promptů, plánují periodické úlohy pro aktualizaci katalogu a provádějí auditní kontroly, aniž by byl nutný přímý lidský zásah (Gaur, 2024).

AI agenti umožňují nejen automatizaci dílčích metadatových operací, ale také koordinaci komplexních úloh napříč systémy. Následující pasáž shrnuje klíčové případy jejich využití v rámci organizací orientovaných na data.

### **1.3.4 Přínosy oproti klasickým modelům GenAI**

Ve srovnání s tradičními generativními modely, které reagují jednorázově na statický prompt bez uchování kontextu, přináší inteligentní AI agenti řadu zásadních výhod, jež podporují efektivní a škálovatelné řízení metadat.

#### **1. Uchování kontextu a paměť**

AI agenti si na rozdíl od běžných generativních modelů uchovávají historii předchozích interakcí a učí se z předchozích kroků, což jim umožňuje správně navazovat na dřívější operace a zohledňovat širší kontext úlohy. Naopak klasické GenAI modely zpracovávají každý vstup izolovaně, bez schopnosti reflektovat předchozí kontext (Vora, 2025).

#### **2. Paralelní zpracování více úloh**

Díky architektuře založené na spolupracujících agentech mohou AI agenti rozdělit komplexní workflow do nezávislých dílčích úloh, které zpracovávají paralelně, čímž značně zkracují celkový čas plnění úkolu. Tradiční GenAI modely musí úlohy vykonávat sekvenčně, což je často pomalejší a méně efektivní (Vora, 2025).

#### **3. Autonomní rozhodování a adaptace**

Zatímco klasické GenAI modely vyžadují opakovaný zásah uživatele pro každou iteraci, AI agenti fungují na principu uzavřené smyčky vnímání–rozhodování–akce, která jim umožňuje autonomně iterovat nad dílčími kroky úlohy, vyhodnocovat výsledky a adaptovat své chování podle nových informací. Naproti tomu GenAI modely vyžadují opakovaný zásah uživatele a úpravu promptu pro každou iteraci (Admetrics, 2025).

#### **4. Integrace do složitých workflow/architektur**

Agentní systémy jsou navrženy s důrazem na modularitu a integraci. Jejich zapojení do existujících podnikově orientovaných architektur, jako jsou mikroslužby nebo event-driven modely, je relativně přímočaré. Agentní logika tak může plynule spolupracovat s dalšími komponentami datové infrastruktury (Vora, 2025), na rozdíl od klasických modelů, které často fungují jako izolované API bez širší interoperability, černé skříňky.

#### **5. Vyšší kvalita a konzistence výstupů**

Díky uchování paměti, schopnosti validace a kontrolních mechanismů v reálném čase produkují AI agenti kvalitnější a konzistentnější metadata. Mohou například automaticky odhalovat a opravovat chyby, validovat výstupy vůči schváleným standardům a harmonizovat popisné struktury napříč systémy (Colback, 2025). Naproti tomu tradiční GenAI modely vykazují vyšší míru variability a jsou náchylnější k nekonzistentním výstupům mezi jednotlivými spuštěními.

### 1.3.5 Výzvy a rizika AI agentů

Přestože AI agenti přinášejí významné výhody pro automatizaci metadatových procesů, jejich autonomní charakter vyvolává řadu nových rizik a výzev.

Nasazení AI agentů do produkčních metadatových workflow naráží na obtížnou predikovatelnost jejich chování – emergentní jevy, tedy nečekané vlastnosti systému, které se objeví bez předchozího naprogramování či předvídání, a mohou ohrozit dosažení stanovených cílů (Zorz, 2025). Což zvyšuje riziko nekontrolovatelných chyb. Současně je nezbytné zavést robustní auditovatelnost a kontrolu výstupů, včetně detailního logování rozhodovacích kroků a auditních stop, aby bylo možné vystopovat původ i validitu generovaných metadat (Colback, 2025). Autonomní povaha agentů navíc vyžaduje přidělení trvalých přístupových oprávnění k API a interním systémům, což zvyšuje bezpečnostní rizika neautorizovaného přístupu či úniku citlivých dat především při špatném nastavení agenta. Kvalita a přesnost metadat se bez důkladné validace vůči referenčním zdrojům nebo lidské kontrole může snížit, a vést tak k nekonzistencím, které narušují důvěru.

Navíc je třeba zohlednit etické a právní aspekty, včetně souladu s GDPR a autorskými právy, aby nedošlo k porušení ochrany osobních údajů (Wong & Saade, 2025). V neposlední řadě integrace inteligentních AI agentů do stávající infrastruktury klade vysoké nároky na design API, kompatibilitu s datovými standardy a pečlivé architektonické plánování (Rosenbush, 2025), což je samo o sobě náročný a nákladný proces.

Přínosy AI agentů v oblasti metadat jsou nesporné, nicméně jejich plnohodnotné nasazení vyžaduje jak robustní technologickou infrastrukturu, tak jasně definované etické a bezpečnostní rámce. Bez důsledné validace a kontrolních mechanismů může docházet k systémovým chybám, které ohroží důvěryhodnost celého metadatového prostředí.

## 1.4 Shrnutí zjištění a prostor pro další rozvoj

Rešeršní část ukázala, že generativní umělá inteligence představuje slibný nástroj pro automatizaci a zkvalitnění správy metadat. Klíčové přínosy zahrnují zrychlení tvorby metadat, jejich obohacování o sémantické informace, zajištění větší konzistence napříč systémy i podporu souladu s regulačními požadavky. Významnou roli zde sehrávají zejména AI agenti, kteří díky své architektuře umožňují samostatné rozhodování, plánování a adaptaci při řešení komplexních úloh v rámci metadatových procesů. Zároveň se však ukazuje, že zavádění těchto technologií do praxe s sebou nese řadu výzev. Patří mezi ně například absence jednotných rámců pro hodnocení kvality generovaných metadat, složitost jejich validace nebo nedostatečné mechanismy pro sledování a kontrolu rozhodování autonomních systémů. Také otázky bezpečnosti, transparentnosti a etiky zůstávají částečně otevřené, a to zejména při práci s citlivými nebo regulovanými daty.

## 2 Metadata management

Druhá kapitola této diplomové práce podrobně rozebírá role metadat v podnikovém prostředí. Kapitola navazuje na rešerši a blíže rozpracovává význam metadat, jejich klasifikaci a přínosy pro efektivní řízení datových aktiv. Důraz je kladen na praktické aspekty metadata managementu, s nimiž se organizace setkávají, a možnosti jejich řešení.

### 2.1 Význam metadat nejen v podnikovém prostředí

Data představují jeden z nejcennějších podnikových zdrojů současnosti. Aby organizace mohly svá data efektivně využívat, potřebují kvalitní metadata, která zajišťují jejich kontext, konzistenci a dostupnost. Metadata jsou tak klíčovým nástrojem nejen pro správu dat, ale i pro zajištění souladu s předpisy a podporu analytických procesů (Bratková, 2012; Mosha & Ngulube, 2023).

Bez sjednocených pravidel pro popis dat se organizace potýkají s problémy, které ztěžují integraci, sdílení nebo i opakované použití dat. Podle Zeng a Qin je „*nedostatek jednotného přístupu k metadatům významnou překážkou při budování robustních datových ekosystémů.*“<sup>2</sup> V této souvislosti představuje generativní umělá inteligence významnou příležitost – nejenže zefektivňuje tvorbu metadat, ale její schopnost analyzovat a chápat kontext umožňuje i jejich sjednocení a harmonizaci napříč doménami (Zeng & Qin, 2023).

„*Více než 60 % organizací podle Gartneru nedokáže plně využít potenciál svých AI řešení právě kvůli roztržitému a nekoordinovanému řízení dat, což výrazně snižuje jejich schopnost generovat hodnotu z datových iniciativ.*“<sup>2</sup> (Gartner, 2024) Metadata jsou základem správy dat, protože umožňují organizacím poskytovat klíčové výhody, jako je opětovné využití dat, jasná identifikace datových aktiv používaných v regulačních rolích, zlepšené řízení rizik a lepší posouzení dopadu změn (Modernize Data Management to Drive Value, 2025).

### 2.2 Role metadat v podnikové sféře

Metadata jsou strukturované informace, které popisují, vysvětlují, lokalizují nebo jinak usnadňují správu, vyhledávání a porozumění datům. Hrají klíčovou roli, a to nejen v podnikovém prostředí, kde poskytují kontext k datovým zdrojům a umožňují efektivní využití v různých fázích životního cyklu dat, hrají zásadní roli nejen při organizaci a správě datových aktiv, ale i při zajištění jejich kvality, dohledatelnosti a souladu s regulačními požadavky.

Podle DAMA-DMBoK jsou metadata klíčovým nástrojem pro řízení datových domén a umožňují organizacím „*porozumět tomu, kde se data nacházejí, jak jsou propojena, kdo za ně odpovídá a jak*

---


<sup>2</sup> Překlad Autorka

*se mění v čase.*<sup>3</sup>“ Metadata tak podporují jak technickou správu dat, tak jejich obchodní hodnotu: od klasifikace aktiv přes podporu kvality dat až po zajištění souladu s předpisy (DAMA, 2017).

Pro lepší a praktičtější ilustraci využití metadat v každodenním životě lze uvést příklad digitální fotografie. Při pořízení snímku digitálním fotoaparátem nebo i chytrým telefonem se kromě samotného obrazového obsahu automaticky zaznamenávají doplňující informace, známé jako EXIF metadata (anglicky Exchangeable Image File Format). Tato metadata zahrnují technické parametry snímku, jako jsou: datum a čas pořízení, nastavení expozice (clona, čas závěrky nebo ISO), informaci, zda byl použit blesk, model použitého zařízení či GPS souřadnice místa pořízení a další parametry, které společně umožňují efektivní organizaci a vyhledávání snímků v digitálních knihovnách, jak můžeme vidět na Obrázek 4 Obrázek 5 (Dolečková, 2016).



Obrázek 4: Zobrazení EXIF metadat v počítači (Dolečková, 2016)



Obrázek 5: Zobrazení EXIF metadat ve foto-editoru (Dolečková, 2016)

Dalším příkladem využití metadat v běžném životě může být příklad elektronické faktury, digitálního dokumentu, který obsahuje nejen viditelné údaje, jako jsou položky zboží/služeb, ale také metadata, která zahrnují informace o datu vystavení a splatnosti, identifikaci dodavatele a odběratele, číslo faktury, daňové identifikační číslo (DIČ) a údaje o platbě, jako je bankovní účet či variabilní symbol. Tato metadata umožňují účetním systémům automatizovat zpracování faktur, sledovat platby a zajišťovat souladu s daňovými předpisy.

<sup>3</sup> Překlad Autorka

Například standard ISDOC od Ministerstva vnitra České republiky definuje strukturu elektronických faktur v České republice a specifikuje, jaká metadata musí být součástí faktury pro zajištění její správné interpretace a zpracování (MVČR, 2022).

Z praktického hlediska je vhodné metadata rozlišovat do tří základních kategorií, přičemž každá z těchto kategorií plní odlišnou, ale vzájemně propojenou roli.

### **1. Popisná metadata**

Poskytují základní informace o obsahu dat, jako jsou například název, autor, datum vytvoření, formát, jazyk nebo klíčová slova. Tyto informace umožňují snadnou identifikaci a vyhledávání dat v rámci datových systémů. Typickým příkladem jejich využití je například systém digitální knihovny, kde uživatel vyhledává dokumenty podle autora nebo tématu. Popisná metadata se často stávají součástí tzv. datového katalogu, který slouží jako přehledné rozhraní pro koncové uživatele.

### **2. Strukturální metadata**

Zaměřují se na popis způsobu, jakým jsou data uspořádána, a na vztahy mezi jednotlivými datovými objekty. Umožňují například pochopit, že určitá tabulka v databázi je součástí širší relační struktury, nebo že kapitola v dokumentu patří pod konkrétní sekci. Tento typ metadata je důležitý nejen pro vizualizaci dat, ale především pro správnou interpretaci datových souvislostí při analytickém zpracování. Již zmiňovaným příkladem pak může být organizace jednotlivých kapitol v elektronickém dokumentu nebo hierarchická struktura databáze.

### **3. Administrativní metadata**

Zahrnují technické informace potřebné pro správu dat, jako jsou údaje o přístupu, oprávnění k práci s daty, záznamy o modifikacích, historie přenosů nebo informace o platnosti a původu dat. Tato metadata jsou klíčová zejména při nastavování pravidel správy dat, zabezpečení nebo pro podporu auditních a compliance aktivit (Shiller & Larochelle, 2024).

V kontextu podnikové informatiky hrají metadata klíčovou roli při řízení datových toků, zajištění souladu s regulacemi a vytváření důvěry v analytické výstupy. Moderní organizace proto implementují tzv. datové katalogy (v angličtině data catalogs), které slouží jako centrální úložiště metadata a umožňují uživatelům lépe porozumět původu, kvalitě a významu jednotlivých datových sad. Datové katalogy představují jednu z nejdůležitějších technologií v oblasti data governance, protože pomáhají organizacím porozumět hodnotě jejich dat prostřednictvím kontextu (Saux, 2024).

I přes své značné přínosy mohou být metadata zdrojem problémů. Mezi nejčastější výzvy spojené se správou metadata patří nekonzistence, vznikající, pokud jsou metadata spravována na různých platformách bez jednotného standardu. To může vést k rozdílným ve formátu nebo obsahu a ztížit efektivní využití dat. Další častým problémem může být neaktualnost metadata, která může způsobit, že uživatelé pracují se zastaralými informacemi. Manuální zadávání metadata je náchylné k chybám, což dále snižuje jejich kvalitu a spolehlivost (Storage, 2024a).

## 3 Harmonizace metadat

Třetí kapitola této diplomové práce se zaměřuje na samotný proces harmonizace metadat v prostředí s různorodými datovými zdroji. Jsou zde podrobně popsány hlavní etapy harmonizačního procesu, používané metodiky a nástroje pro standardizaci a integraci metadat. Kapitola zároveň vymezuje kritéria pro hodnocení úspěšnosti procesu harmonizace.

### 3.1 Proces harmonizace metadat

Harmonizace metadat je proces sladění, sjednocení a standardizace různorodých metadatových struktur, terminologií a formátů tak, aby bylo možné efektivně integrovat data z různých systémů a domén. Tento proces zahrnuje jak technické transformace, tak i sémantické vyrovnání významu jednotlivých polí, čímž umožňuje bezproblémovou výměnu a společné využívání dat (DAMA, 2017). Tento proces zahrnuje systematické kroky od sběru přes analýzu a transformaci až po integraci, jejichž cílem je vytvořit konzistentní, strukturovanou a opakovatelně použitelnou kolekci metadat napříč různými systémy a doménami (Teradata, 2024).

#### 1. Identifikace a sběr metadat

Proces harmonizace metadat obvykle začíná identifikací relevantních zdrojů a sběrem existujících datových popisů. V této fázi je klíčové zachytit veškeré dostupné informace, které následně slouží jako základ pro další analýzu a standardizaci.

#### 2. Analýza a standardizace

V navazujícím kroku jsou získaná metadata analyzována, aby bylo možné odhalit nejasnosti, duplicity nebo chyby v terminologii. Následně se metadata sjednocují prostřednictvím předem definovaných pravidel, harmonizačních schémat či ontologií, což umožňuje sladit rozdílné formáty i struktury napříč zdroji (Gucer, 2020).

#### 3. Integrace a správa metadat

V závěrečné fázi jsou harmonizovaná metadata integrována do cílového úložiště či datového katalogu. Součástí tohoto procesu je také jasné určení odpovědností za údržbu, pravidelnou aktualizaci a správu přístupových práv (DAMA, 2017).

#### 3.1.1 Nástroje pro podporu harmonizace metadat

Aby byl proces harmonizace metadat efektivní, organizace často využívají specializované nástroje, které umožňují standardizaci, mapování a obohacení datových popisů.

Existuje množství technických i softwarových řešení, která usnadňují sběr, standardizaci a integraci metadat v rámci harmonizačního procesu. Klíčovou roli hrají nástroje založené na ontologických rámcích, jako je SSSOM (Simple Standard for Sharing Ontological Mappings), které umožňují sdílení a poměrování mapování mezi různými ontologiemi prostřednictvím jednoduchého, standardizovaného formátu CSV s definovanými sloupci (Matentzoglou et al., 2022).

Dále jsou významné metody využívající shlukování (anglicky clustering) a embeddingová řešení, například Gonçalves et al. popisují přístup založený na shlukování názvů polí metadat a jejich vyrovnávání s termíny ontologií pomocí embeddingových modelů, což vede k vyšší přesnosti ve srovnání s tradičními nástroji pro přiřazování popisů. Kromě toho se v praxi využívají platformy, které poskytují API pro přímý přístup k bohatým ontologickým zdrojům a nástroje, sloužící pro automatizované přiřazování termínů k metadatům (Gonçalves et al., 2019). Pro orchestraci celého procesu harmonizace se často využívají workflow nástroje, např. Apache NiFi nebo KNIME, které umožňují sestavení pipelines pro sběr, transformaci a integraci dat (KNIME, 2017; LubaBelokon, 2018). Tyto nástroje společně tvoří robustní rámec pro podporu standardizace a sjednocení metadat v heterogenních datových prostředích.

K těmto akademickým nástrojům se řadí i komerční řešení, která integrují GenAI do datových katalogů, například IBM Knowledge Catalog nebo Google Cloud Document AI, které umožňují automatizované vytváření, kontrolu i klasifikaci metadat díky NLP funkcím, modelům založeným na transformerech a embedovacím přístupům (Google Cloud, 2024; IBM, 2024). Některé platformy kombinují plavidlové a strojově učení, aby podpořily transformační fázi harmonizace, a zároveň uchovávají auditní stopy pro správu kvality a dohledatelnost změn.

## 3.2 Metodologie harmonizace metadat

Proces harmonizace metadat představuje soubor systematických kroků, jejichž cílem je sjednotit a optimalizovat popisná, strukturální a administrativní metadata napříč různými systémy, doménami a datovými zdroji. Klíčovými fázemi tohoto procesu jsou zejména sběr, analýza, transformace a integrace metadat (Teradata, 2024). Sběr metadat zahrnuje identifikaci a agregaci existujících popisů datových entit ze všech relevantních zdrojů v organizaci, včetně strukturovaných databází, dokumentových úložišť nebo externích katalogů (Gucer, 2020).

Následující fáze analýzy je zaměřena na identifikaci nesrovnalostí, redundancí a nekonzistencí v pojmenování či struktuře metadat, které často vznikají v důsledku rozdílných interních standardů, verzí nebo individuálních úprav v rámci jednotlivých systémů (Boone, 2024). Transformace metadat pak využívá harmonizačních pravidel, mapovacích tabulek nebo ontologií k sjednocení formátů, terminologie i struktur napříč celým ekosystémem organizace (Egan & Moreno, 2024).

Zásadní roli v této fázi mohou hrát i pokročilé nástroje generativní umělé inteligence, které dokáží automatizovaně navrhovat optimální převody a validace (Shapiro, 2024). Posledním krokem je integrace harmonizovaných metadat do centrálních katalogů či úložišť, kde jsou spravována v souladu s definovanými pravidly data governance a bezpečnostní politikou organizace. Efektivní harmonizace vyžaduje jasné vymezení zodpovědností za jednotlivé fáze procesu, včetně role data stewardů či správců metadat, což podporuje jak dlouhodobou udržitelnost řešení, tak možnost další automatizace (DAMA, 2017).



Při volbě konkrétní metodologie harmonizace je nezbytné přihlížet k povaze spravovaných dat, existující architektuře systémů a organizačním požadavkům. Standardy jako DAMA-DMBoK doporučují řídit harmonizaci metadat v úzké vazbě na celkovou datovou strategii podniku, přičemž klíčovým principem je dosažení konzistence, interoperability a vysoké kvality datových popisů v celém datovém ekosystému (DAMA, 2017). V praxi to znamená nejen aplikaci technických nástrojů, ale i zavedení procesů pro kontinuální údržbu a revizi metadat na úrovni celé organizace.

### 3.2.1 Kritéria hodnocení úspěšnosti harmonizace

Úspěšná harmonizace metadat je podstatná pro zajištění kvality datových procesů a jejich efektivního využití. Hodnocení úspěšnosti harmonizace je možné provádět na základě několika měřitelných kritérií, která zohledňují jak technické, tak i organizační aspekty:

#### 1. **Konzistence** (základní kritérium pro hodnocení harmonizace)

Metadata by měla být jednotná napříč všemi systémy a zdroji, což zahrnuje jejich formát, strukturu i obsah. Konzistentní metadata minimalizují chyby způsobené nesouladem mezi různými systémy a umožňují spolehlivější integraci dat. Jednotná metadata také zvyšují důvěru uživatelů v kvalitu dat, což je zásadní například v oblastech, jako je zdravotnictví nebo finance (Teradata, 2024).

#### 2. **Snížení chybovosti**

Harmonizace metadat snižuje množství manuálních oprav a zásahů, které mohou být nejen časově náročné, ale také náchylné k dalším chybám. Automatizované procesy generování a správy metadat, které využívají generativní umělou inteligenci, pomáhají minimalizovat lidské chyby a zajistit přesnější zpracování dat (Gucer, 2020).

#### 3. **Přesnost a úplnost metadat**

Metadata by měla obsahovat všechny relevantní informace pro správu a vyhledávání dat. Například v oblasti e-commerce je přesnost metadat klíčová pro zajištění správně popsanych a kategorizovaných produktů, což napřímo ovlivňuje uživatelskou zkušenost (Egan & Moreno, 2024).

#### 4. **Efektivita procesů**

Efektivita je dalším měřítkem, které odráží, jak harmonizace zkracuje dobu potřebnou k vyhledání, analýze a použití dat. Zlepšení efektivity lze měřit například snížením doby odezvy při zpracování datových dotazů nebo zrychlením integrace nových datových zdrojů do stávajících systémů (Stamp, 2024). Efektivní harmonizace dat tak podporuje rychlejší rozhodovací procesy a zvyšuje produktivitu organizace

#### 5. **Škálovatelnost a flexibilita**

Harmonizační strategie by měla být schopna přizpůsobit se neustále rostoucím objemům dat a novým požadavkům organizace. Nástroje založené na GenAI poskytují flexibilitu při zpracování různorodých datových zdrojů a umožňují rychlé přizpůsobení novým standardům (Gucer, 2020).

## 4 Analýza výchozího stavu správy metadat a identifikace vhodných míst pro využití AI

Čtvrtá kapitola diplomové práce přináší ucelený pohled na správu metadat, a to jak z perspektivy manuálních postupů, tak s ohledem na možnost automatizace prostřednictvím generativní umělé inteligence. Je zde zdokumentován proces manuální evidence a harmonizace metadat, včetně časové náročnosti a identifikace úzkých míst v pracovním postupu. Součástí je kvalifikovaný odhad vycházející z řízených rozhovorů se zástupci z praxe, na jejichž základě jsou určeny konkrétní oblasti, kde je ruční práce nejvíce zatěžující, časově náročná nebo náchylná k chybám. V druhé části kapitoly je představena možnost využití generativní AI a jsou identifikovány procesy, které by bylo vhodné zautomatizovat. Výstupy této analýzy tvoří základ pro návrh experimentálního řešení rozpracovaný v následující kapitole.

První část kapitoly vychází z informací získaných prostřednictvím řízených rozhovorů se třemi kolegy z praxe – dvěma specialisty z bankovního prostředí a jedním odborníkem z oblasti telekomunikací. Tito respondenti si přáli zůstat v anonymitě a stejně tak, jako nemohou být poskytována ani reálná firemní data, nicméně jejich zkušenosti poskytly cenný pohled na každodenní rutinu i úskalí ruční správy metadat ve velkých společnostech.

### 4.1 Charakteristika manuální správy metadat

Manuální správa metadat je v mnoha organizacích stále běžnou realitou. Tento proces často zahrnuje ruční doplňování popisných informací, přiřazování tagů, validaci datových typů či indikaci případných problémů v kvalitě dat (Farmer, 2024). Právě tyto kroky bývají časově náročné, náchylné k chybám a závislé na znalostech konkrétních uživatelů. V praxi to vede k časté nekonzistenci, duplicitám a nižší spolehlivosti evidovaných metadat (Bratková, 2012; Storage, 2024b).

V praxi zahrnuje manuální správa metadat především ruční doplňování popisných informací ke sloupcům tabulek, reportům či jiným datovým objektům. Pracovníci často validují datové typy a popisy jednotlivých atributů, aby ověřili správnost a úplnost evidovaných metadat. Významnou část procesu tvoří také přiřazování tagů a kategorií, které však mnohdy probíhá bez jasně definovaného standardu, což může vést k nejednotnosti napříč systémy. Kontrola duplicity záznamů probíhá převážně manuálně. Z rozhovorů také vyplynulo, že manuální správa metadat je vysoce časově náročná a závislá na individuálních znalostech konkrétních pracovníků. Typicky trvá několik desítek hodin až dní zpracovat, doplnit nebo zkonkretizovat metadata většího datového souboru, zejména pokud je nutné ověřovat informace napříč různými systémy. Častým problémem je rovněž zvýšené riziko chyb, a to jak v důsledku lidského faktoru, tak kvůli neaktuálním nebo nepřesným popisům, které se následně negativně odrážejí na celkové kvalitě datového katalogu. Další limitací je nízká konzistence napříč týmy a odděleními, neboť různí pracovníci často používají odlišné termíny, tagy i způsoby evidence.

Výše popsané skutečnosti potvrzují, že ruční správa metadat je nejen náročná na čas a lidské kapacity, ale zároveň zvyšuje pravděpodobnost vzniku chyb a nekonzistence v rámci celého datového prostředí. Právě tyto limity představují motivaci pro hledání možností automatizace a zavedení nástrojů na bázi umělé inteligence, které by mohly významně přispět k efektivitě a kvalitě správy metadat.

#### **4.1.1 Zmapování hlavních problémů manuální správy metadat**

Manuální správa metadat v praxi často naráží na celou řadu problémů, které mohou výrazně ovlivnit kvalitu i efektivitu práce s daty v organizaci. Na základě rozhovorů s odborníky z bankovního a telekomunikačního sektoru, kteří si přáli zůstat v anonymitě, lze tyto hlavní problémy shrnout do několika klíčových oblastí, popsaných na následujících řádcích.

##### **1. Nedostatek standardizace postupů**

Ve většině organizací neexistuje pevně definovaná metodika ani závazné postupy pro evidenci metadat, což vede k tomu, že jednotliví pracovníci zaznamenávají informace různými způsoby. Výsledkem je značná nejednotnost v zápisech, která následně komplikuje dohledávání a sdílení metadat napříč organizací. Chybějící standardy zároveň znemožňují efektivní kontrolu kvality a brání automatizaci rutinních činností.

##### **2. Závislost na zkušenostech konkrétních pracovníků**

Kvalita správy metadat je do velké míry ovlivněna osobní znalostí a zkušenostmi konkrétních zaměstnanců, kteří mají na starost jejich evidenci a aktualizaci. Pokud dojde ke změně personálního obsazení nebo k zastupování v nepřítomnosti, může se výrazně snížit plynulost a přesnost práce, protože noví nebo méně zkušení pracovníci často nemají dostatečný přehled o struktuře či historii metadat. Tato závislost rovněž omezuje možnost efektivního rozdělování úloh mezi členy týmu.

##### **3. Chybovost způsobená manuálním zadáváním**

Manuální vkládání a validace údajů je náchylné k omylům, ať už jde o překlepy, opomenutí nebo chybné přiřazení informací. V prostředí s velkým množstvím dat je riziko vzniku chyb ještě vyšší, protože dlouhodobě opakovaná rutinní práce vede k únavě a snižuje pozornost pracovníků. Chyby často nejsou odhaleny ihned, což má za následek šíření do dalších procesů a systémů.

##### **4. Nekonzistence v používání tagů a popisů**

Různá oddělení nebo týmy často využívají odlišné terminologie či popisování stejných datových entit. Tato nejednotnost vede ke vzniku duplicitních nebo konfliktních záznamů, a také komplikuje integraci metadat z více systémů. Výsledkem je snížená spolehlivost a transparentnost datových katalogů.

Jedním z nejvýraznějších důsledků výše popsaných problémů je značné časové zatížení, které s manuální správou metadat nevyhnutelně souvisí, právě této oblasti se podrobněji věnuje následující podkapitola.

#### 4.1.1.1 Nejméně efektivní kroky v procesu

Za nejméně efektivní a zároveň časově nejnáročnější kroky byly označeny zejména sjednocování popisů a doplňování chybějících či neaktuálních údajů, jež vyžadují opakovanou manuální kontrolu a častou komunikaci mezi členy různých týmů. Tyto činnosti často zdržují celý proces harmonizace metadat a zvyšují riziko vzniku chyb, neboť závisí na dostupnosti informací i ochotě jednotlivých pracovníků spolupracovat napříč organizační strukturou. Absence automatizovaných nástrojů dále prodlužuje časovou náročnost těchto operací a vede k opakovanému řešení stejných problémů v různých částech organizace.

#### Časové zatížení manuální správy metadat

Vysoká časová náročnost představuje zásadní limit manuální správy metadat, což se odráží zejména při zpracování rozsáhlejších datových sad. Odhady získané v rámci řízených rozhovorů ukazují, že tyto činnosti mohou v případě rozsáhlejších dat zabrat několik hodin až celý pracovní den, a to zejména tehdy, pokud je nutné vyhledávat informace napříč více systémy nebo opakovaně validovat tytéž údaje. Absence standardizovaných postupů celý proces dále prodlužuje a zvyšuje riziko chyb. Časová náročnost manuální správy metadat tak výrazně ovlivňuje celkovou efektivitu práce datových stewardů a analytiků a ukazuje na potřebu zavedení automatizovaných nástrojů založených na umělé inteligenci, které by mohly tento proces výrazně zefektivnit.

## 4.2 Využití GenAI pro správu metadat

Aplikace GenAI na správu metadat otevírá mnoho možností pro organizace, které chtějí zlepšit správu svých dat. GenAI vyniká při vytváření a obohacování metadat, kdy automaticky generuje štítky a anotace pro různá datová aktiva. Tato schopnost přesahuje rámec generování popisů databázových objektů, jako jsou tabulky a sloupce, nebo identifikace běžných obchodních termínů. GenAI umožňuje sofistikované obohacování metadat, jako je obchodní kontext odvozený z pozorování vzorů používání dat, transformací datových linií a koncových bodů a trendů dotazů uživatelů<sup>4</sup> (Bourne, 2024).

S rostoucím objemem dat a komplexitou informačních systémů se stále častěji uplatňují technologie umělé inteligence. Generativní AI, využívající modely jako GPT, přináší nové možnosti automatizace metadatových procesů: od popisu a kategorizace dat po detekci nekonzistencí či návrh oprav. Tento přístup však přináší i výzvy, zejména v oblasti kvality, bezpečnosti a standardizace výstupů (Shapiro, 2024).

---

<sup>4</sup> Překlad Autorka

## 4.2.1 Identifikace příležitostí pro využití GenAI ve správě metadat

Cílem této podkapitoly je identifikovat proces v rámci správy metadat, který je vhodný pro experimentální ověření přínosů automatizace pomocí generativní umělé inteligence. Na základě analýzy předchozích kapitol bylo zjištěno, jaké činnosti jsou z pohledu uživatelů nejvíce zatěžující, náchylné k chybám a časově nejnáročnější:

- **Generování metadat:** popisy metadat, určení typu metadat
- **Revize dat:** kontrola kvality dat – doplňování chybějících údajů, úprava chybných údajů
- **Náhled metadat**

Automatizace těchto oblastí prostřednictvím AI agenta by mohla významně přispět ke zvýšení efektivity správy metadat, snížení chybovosti a zajištění vyšší konzistence v evidovaných údajích. Právě generativní umělá inteligence představuje zásadní inovaci v procesu harmonizace metadat, jelikož umožňuje automatizovat, zrychlit a zkvalitnit několik klíčových kroků v rámci životního cyklu metadat (Shapiro, 2024).

### 1. Automatizované generování a obohacování metadat

V počáteční fázi sběru a popisu dat lze GenAI efektivně nasadit k automatickému vytváření popisných a kontextových metadat, a to na základě analýzy obsahu. Moderní modely LLM umožňují vytvářet relevantní anotace, klíčová slova a souhrny bez nutnosti rozsáhlé manuální práce. Nasazení generativních modelů v této fázi by zvýšilo efektivitu a snížilo riziko lidských chyb, tím zajistilo vyšší míru konzistence v popisech napříč systémy (Egan & Moreno, 2024).

### 2. Automatizace mapování a převodu metadat

Ve fázi transformace a harmonizace metadat lze GenAI aplikovat k automatickému mapování mezi různými formáty a strukturami pomocí pokročilých nástrojů, jako je Simple Standard for Sharing Ontological Mappings (SSSOM), v kombinaci s generativními modely pro generování překladových pravidel (Matentzoglou et al., 2022).

### 3. Detekce nekonzistencí a automatický audit

V pokročilých fázích lze GenAI využít k detekci nekonzistencí, duplicit či chyb v metadatech, a také k automatizovanému auditu souladu se zvolenými standardy. AI modely zde mohou samostatně procházet datové katalogy, identifikovat anomálie a navrhnout korekce, a to v reálném čase. To má potenciál zásadně urychlit a zpřesnit procesy kontroly kvality, které jsou tradičně velmi časově náročné (Stamp, 2024).

### 4. Podpora škálovatelnosti a integrace nových zdrojů

Nasazení GenAI umožňuje efektivní škálování procesů harmonizace, zejména při integraci nových datových zdrojů nebo při změně schémat. Generativní modely dokáží rychle navrhnout transformace pro nové typy metadat, čímž umožňují pružně reagovat na měnící se potřeby organizace (Teradata, 2024).

Společnost IBM integrovala generativní AI do svého produktu IBM Knowledge Catalog, což umožňuje automatické obohacování metadat a zajišťuje jejich konzistenci napříč systémy (Boone, 2024). Dalším příkladem využití, je nástroj Document AI Custom Extractor od společnosti Google Cloud. Tento nástroj využívá GenAI k rychlé a přesné klasifikaci dokumentů a extrakci relevantních dat. Je navržen tak, aby dokázal pracovat s různými formáty nestrukturovaných dokumentů,

identifikoval klíčové informace a automaticky je zařadil do odpovídajících kategorií. To umožňuje organizacím výrazně zrychlit proces zpracování dokumentů, zlepšit přesnost výstupů a zajistit konzistenci správy metadat napříč systémy. Tento přístup nachází uplatnění například ve finančním sektoru, kde se využívá ke zpracování faktur a smluv, nebo v oblasti zdravotnictví, kde pomáhá při kategorizaci lékařských záznamů a laboratorních výsledků (Egan & Moreno, 2024).

Z výstupů identifikovaných v této podkapitole je patrné, že navržené příležitosti využití GenAI ve správě metadat odpovídají oblastem shrnutým v podkapitole 1.2 Klíčové oblasti aplikace GenAI v kontextu metadat. Výsledky analýzy tedy potvrzují, že praktické příležitosti rozpoznané v rámci rešerše odpovídají i zkušenostem a potřebám zjištěným v rámci analýzy aktuálního stavu v organizacích.

## **4.3 Shrnutí hlavních zjištění kapitoly**

Kapitola jednoznačně ukázala, že manuální procesy spojené s evidencí, validací a harmonizací metadat představují významnou časovou, kapacitní i kvalitativní zátěž pro datové týmy. Identifikovaná úzká místa a opakující se rutinní úkony, jež jsou pro pracovníky obtížně zvládnutelné ve velkém objemu a s vysokou mírou přesnosti, představují nejvhodnější příležitost pro nasazení automatizovaného řešení na bázi umělé inteligence. Automatizace těchto činností slibuje nejen výrazné zrychlení a zjednodušení správy metadat, ale i snížení chybovosti, zajištění vyšší konzistence a možnost efektivního sdílení datových informací napříč celou organizací.

Ráda bych touto cestou poděkovala odborníkům, kteří byli ochotni podělit se o své praktické zkušenosti a pohled na každodenní správu metadat, a to především prostřednictvím přátelských rozhovorů a ukázek běžných pracovních situací. Přestože z důvodu ochrany důvěrných informací není možné uvádět konkrétnější detaily ani jména respondentů, jejich postřehy a zkušenosti významně přispěly k dalšímu směřování vývoje AI agenta a k identifikaci oblastí vhodných pro automatizaci.

### **4.3.1 Začlenění vlastního výzkumu do procesu správy metadat**

Na základě analýzy výchozího stavu a identifikovaných úzkých míst ve správě metadat byla v této práci zvolena konkrétní oblast pro návrh experimentálního řešení. Jako modelový případ byla vymezena evidence a správa metadat pro tabulkové datové soubory CSV, neboť tento scénář reprezentuje běžnou situaci ve firemní praxi a umožňuje dobře otestovat možnosti automatizace základních úkonů, jako je generování popisných metadat, kategorizace, revize kvality a návrh oprav. Zadáání AI agenta proto cíleně pokrývá zejména procesy, které byly vyhodnoceny jako nejvíce zatěžující a chybové – automatickou analýzu struktury souboru, generování metadat, detekci problémů v datech a návrh akčních kroků pro jejich zlepšení.

Cílem navrženého agenta není pokrýt veškeré oblasti popsané v rešerši, ale zaměřit se na prakticky ověřitelný a dostatečně reprezentativní případ, který bude možné experimentálně testovat na otevřených a anonymizovaných datových sadách. Tento úzce vymezený scénář zároveň vytváří solidní základ pro případné další rozšíření a úpravy agenta podle potřeb různých typů organizací. Výsledné zadání a návrh řešení jsou detailně rozpracovány v následující páté kapitole

## 5 Experimentální návrh a testování AI agenta pro správu metadat

V páté kapitole této diplomové práce jsou na základě poznatků z předešlé kapitoly navrženy, implementovány a otestovány klíčové funkce AI agenta pro podporu správy a harmonizace metadat, přičemž agent cílí zejména na automatizaci těch nejkritičtějších a nejvíce problematických míst celého procesu. Kapitola se zaměřuje na popis architektury řešení, výběr použitých technologií a metodiku experimentálního ověření přínosu automatizace.

Na základě vymezení v kapitole 4 je zadáním tohoto agenta automatizovat proces evidence a správy metadat pro tabulková data, a to prostřednictvím generování popisných metadat, detekce chyb v datech a návrhu akčních kroků, které běžně zatěžují datové týmy v podnikovém prostředí.

### 5.1 Cíl experimentu a rámec praktického řešení

Cílem této experimentální části bylo navrhnout a validovat funkční prototyp AI agenta, který by mohl být využit pro efektivní správu metadat. Agent by měl být schopen nejen analyzovat strukturu vstupních dat, ale také generovat vhodné popisné a klasifikační informace, které slouží ke katalogizaci a organizaci datových zdrojů. Klíčovým aspektem tohoto řešení je využití moderních metod umělé inteligence a jejich implementace do použitelné webové aplikace.

Autorka při návrhu prototypu AI agenta vycházela z rámce DAMA-DMBoK (DAMA, 2017), přičemž si explicitně vymezila oblast metadat, kterou měl agent pokrýt – zejména popisná metadata, technické informace o datech, návrh klasifikačních tagů a detekci základních kvalitativních nedostatků. Na základě rešerše uvedené v kapitole 1.2 Klíčové oblasti aplikace GenAI v kontextu metadat si autorka stanovila čtyři dílčí cíle, které tvořily konceptuální rámec a výchozí strukturu návrhu AI agenta:

1. **Schopnost rozpoznat strukturu vstupního datasetu** (např. názvy sloupců, datové typy, přítomnost chybějících hodnot).
2. **Generování** sémanticky odpovídajících **popisných metadat**, která by byla využitelná při katalogizaci datových zdrojů.
3. **Kategorizace dat** pomocí návrhu tagů a tříd, případně identifikace vhodné klasifikace podle datového obsahu.
4. **Detekce a indikace** potenciálních **problémů v kvalitě dat**, jako jsou chybné znaky, narušené kódování, prohozené sloupce nebo nekonzistence ve formátu.

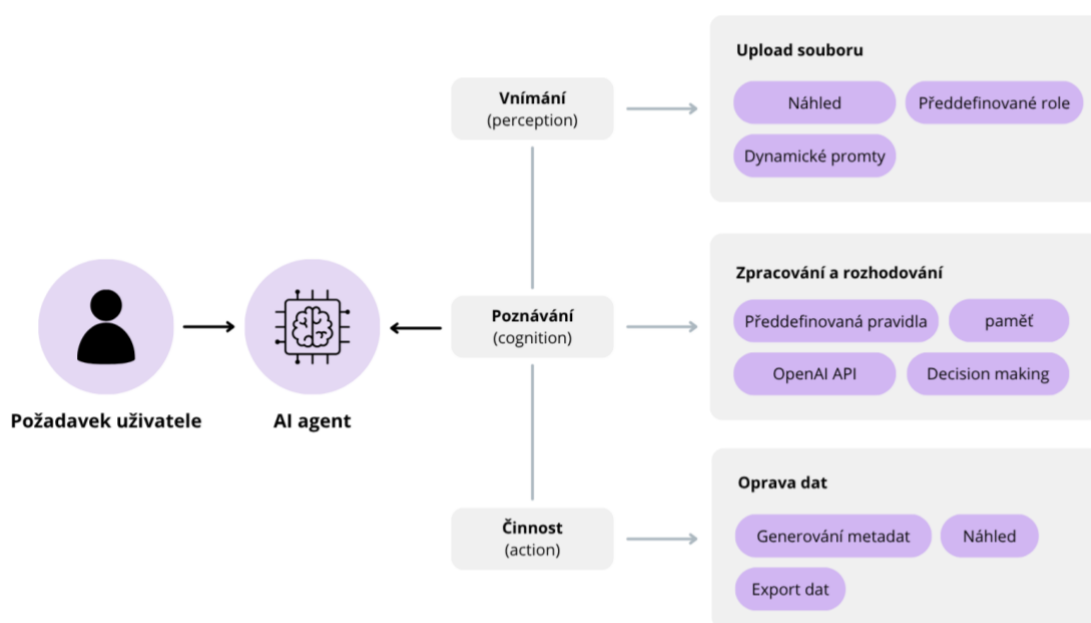
Očekávaným přínosem navrženého agenta je zefektivnění úloh spojených se správou dat, zrychlení procesu klasifikace a zpřístupnění metod umělé inteligence i méně technickým uživatelům. Projekt využívá moderní jazykové modely, nástroje pro práci s daty v jazyce Python a cloudové platformy pro nasazení aplikace.

## 5.2 Návrh architektury AI agenta

Při návrhu agenta byly zvažovány tři hlavní přístupy: pravidlový systém, systém založený na jazykových modelech a hybridní přístup. Na základě dostupnosti technologií a požadavku na flexibilitu a generování metadat v přirozeném jazyce byla zvolena varianta s využitím LLM, konkrétně modelů dostupných přes rozhraní OpenAI API.

Systém je složen z následujících komponent:

- **Frontend:** webové uživatelské rozhraní vytvořené pomocí platformy Streamlit, kdy uživatel vkládá CSV soubor a následně vidí výsledky analýzy a generovaných metadat.
- **Backend:** aplikační logika psaná v jazyce Python. Komunikuje s modelem přes API a zajišťuje zpracování vstupních dat.
- **AI komponenta:** jazykový model od OpenAI, který generuje textové výstupy – návrhy metadat, anotací a klasifikací.
- **Datové úložiště:** prototyp pracuje s dočasnými daty přímo v paměti aplikace, případně s lokálními CSV soubory (při budoucím rozšíření by mohl využívat napojení do databáze).



Obrázek 6: Ilustrační schéma architektury, vytvořeno přes Canva (vlastní zpracování)

Ilustrační schéma architektury na Obrázek 6 vychází z principu „Perception – Cognition – Action“ (Pulvermüller et al., 2014) a je navrženo tak, aby uživateli poskytlo intuitivní i hloubkovou podporu při správě metadat.

První vrstva, **Vnímání** (anglicky perception), slouží k zachycení a předzpracování vstupních dat. Uživatel zde prostřednictvím komponenty pro nahrávání souboru odesílá CSV, které je okamžitě validováno a načteno do paměti aplikace. Klíčovou součástí této fáze jsou také systémové prompty („Jsi datový analytik…“) a dynamicky generovaný prompt, jenž se skládá podle struktury právě načteného datasetu.



Druhá vrstva, **Poznávání** (anglicky cognition), představuje jádro rozhodování. Dynamicky složený prompt odesílá do modelu GPT-3.5-turbo, který vygeneruje výstup – stručný popis sloupců spolu s jejich datovými typy a významem a poté seznam potenciálních chyb či neobvyklých hodnot. Paralelně běží heuristická kontrola chybějících hodnoty, typů dat a vyhledávání extrémních či nestandardních vstupů. Tato paměť následně umožňuje zachovat kontext konverzace, který lze později použít uvnitř chatovacího rozhraní.

Třetí vrstva, **Činnost** (anglicky action), zajišťuje interaktivní zpřístupnění výsledků, odděleném expanderu se zobrazí chatovací rozhraní, které reaguje na každou otázku uživatele a vytváří novou zprávu s aktualizovaným promptem. Kromě okamžité textové odezvy agent nabízí také možnost exportu vygenerovaných metadat či upraveného souboru.

Celý tento tok, od nahrání souboru přes vyhodnocení v modelu až po interaktivní chat a export, garantuje, že agent nejen pasivně zobrazí informace, ale aktivně data vnímá, uvažuje nad nimi a následně i koná prostřednictvím přehledných vizualizací a nástrojů pro další zpracování.

## 5.3 Použité technologie a nástroje

Finální verze AI agenta byla postavena v programovacím jazyce **Python**, který autorce poskytl potřebnou flexibilitu při zpracování dat i práci s externími jazykovými modely. Pro datovou manipulaci a analýzu byly využity knihovny **pandas** a **numpy**, které umožnily načítání CSV souborů, identifikaci typů dat, detekci chyb i přípravu náhledu.

Uživatelské rozhraní bylo realizováno pomocí frameworku **Streamlit**, který umožňuje vytvářet interaktivní webové aplikace bez potřeby složité front-endové logiky. Aplikace byla veřejně nasazena nejprve přes Streamlit Cloud, později přes **Hugging Face Spaces**, což umožnilo snadnou online dostupnost.

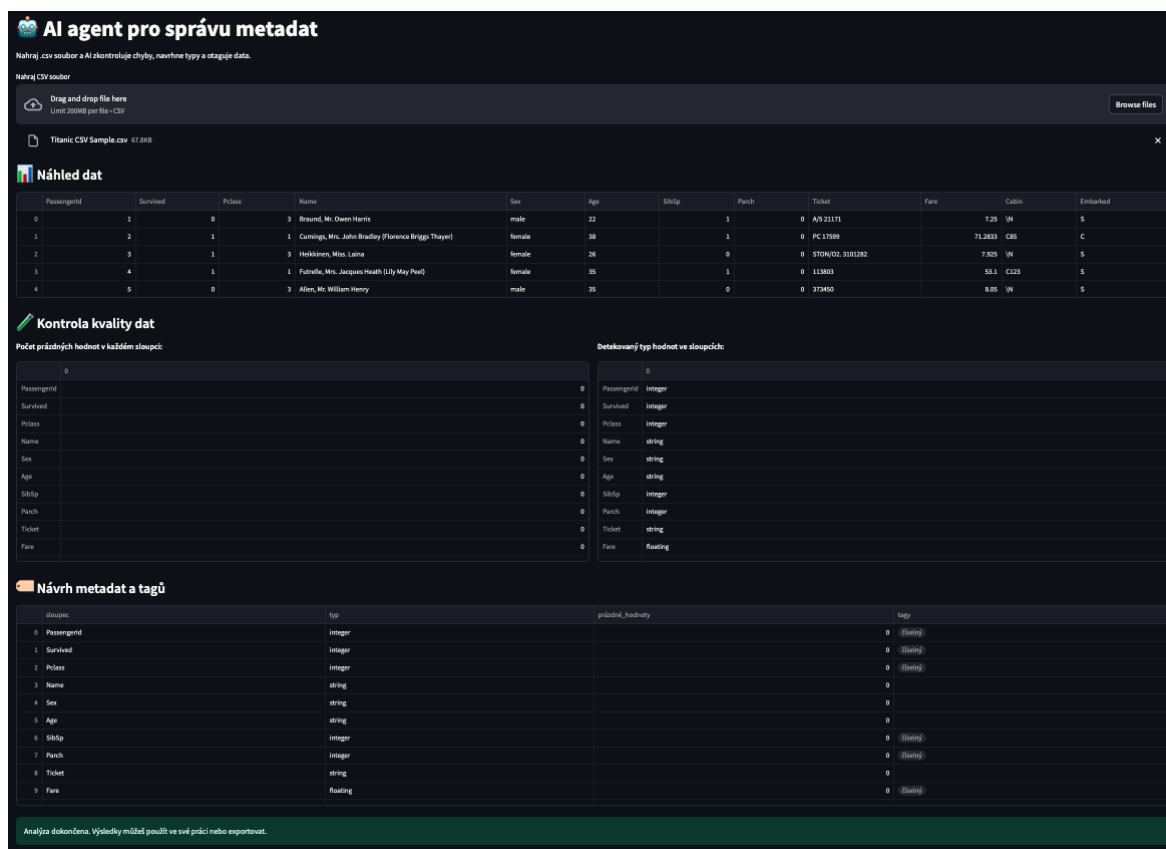
Klíčovou komponentou systému je připojení k **OpenAI API**, konkrétně k modelu GPT-3.5-turbo, který byl využit pro generování stručných popisů datových sloupců a odpovídání na dotazy uživatele k obsahu datasetu. Práce s API byla řízena přímo z backendu a optimalizována pomocí strukturovaných promptů. Systém dále obsahuje vlastní moduly pro detekci problémů v kvalitě dat a návrh akčních kroků k jejich nápravě, které byly naprogramovány v rámci samostatných Python skriptů.

Vzhledem k tomu, že se autorka systematicky nevěnuje programování, sehrála v procesu návrhu a vývoje AI agenta zásadní roli asistence jazykového modelu ChatGPT (ChatGPT, 2025). Právě díky interaktivní konzultaci s tímto nástrojem bylo možné překonat řadu technických překážek, ať už šlo o výběr vhodného frameworku, návrhu architektury systému nebo o samotnou implementaci. V rámci této spolupráce se ukázalo, že LLM může sloužit nejen jako zdroj znalostí, ale především jako aktivní partner při tvorbě aplikace, což samo o sobě potvrzuje potenciál AI pro podporu vývoje aplikací bez hlubšího technického zázemí uživatele.

## 5.4 Vývoj prototypu AI agenta

Vývoj AI agenta probíhal iterativně, s cílem navrhnout aplikaci, která dokáže na základě strukturovaného vstupního souboru automaticky rozpoznat strukturu dat, odhalit chyby v kvalitě, navrhnout popisná metadata a reagovat na dotazy uživatele. Hlavní důraz byl kladen na praktičnost, čitelnost výstupů a online dostupnost bez nutnosti instalace. Před vytvořením finální verze AI agenta autorka testovala několik vývojových prostředí, která by umožnila spojit analýzu dat a AI výstupy do přístupné webové aplikace.

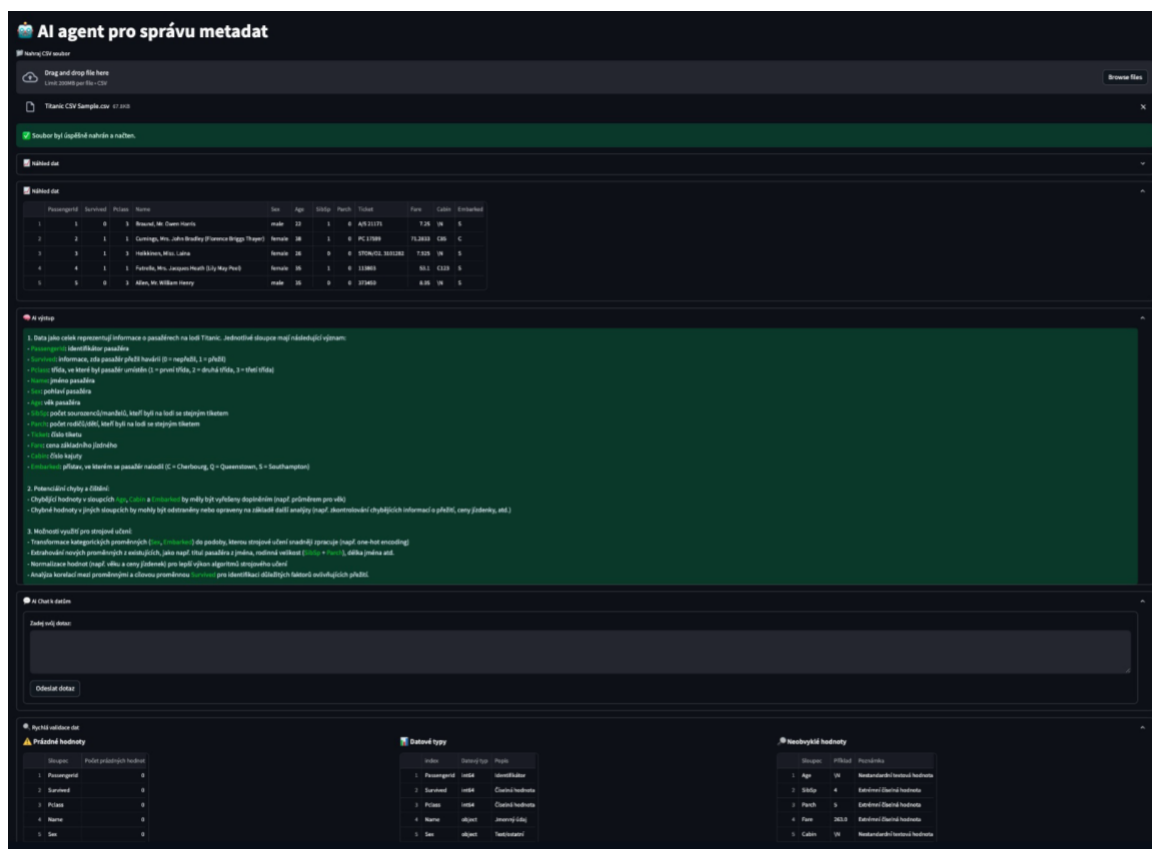
První pokus proběhl ve **Streamlit** prostředí, kde vznikl funkční validátor CSV souborů. Zobrazoval náhled dat, kontroloval kvalitu a navrhoval tagy, ale ještě nevyužíval AI model, je funkční na adrese: <https://ai-metadata-agent.streamlit.app/> a jeho vizuál je vidět na Obrázek 7. Pokus o jeho rozšíření ztroskotal na problému s připojením k OpenAI API a také na velmi dlouhé době načítání aplikace ve Streamlit Cloud, která v některých případech trvala i několik minut.



Obrázek 7: CSV validátor – první verze, vytvořen přes Streamlit

Druhou variantou byl **Google Colab**, který se ukázal jako nevhodný pro vývoj webové aplikace, jelikož umožňoval pouze práci se skripty, nikoliv interaktivní výstupy. Zvažováno bylo i lokální řešení, ale to bylo zamítnuto kvůli požadavku na veřejně dostupnou a otestovatelnou aplikaci.

Jako nejvhodnější se nakonec ukázalo prostředí **Hugging Face Spaces**, kde bylo možné aplikaci stabilně spustit, správně připojit OpenAI API a zahájit vývoj plnohodnotného AI agenta. Ten byl schopen generovat popisky, detekovat problémy a reagovat na dotazy uživatele, první prototyp je možné vidět na Obrázek 8.



Obrázek 8: První prototyp AI agenta, vytvořen v Hugging Face Spaces

Po těchto zkušenostech se autorka rozhodla využít prostředí Hugging Face Spaces, které umožňovalo spolehlivé připojení k OpenAI API i provoz aplikace online. Záměrně se rozhodla začít od začátku, aby mohla k návrhu AI agenta řádně přistupovat – promyšleněji, strukturovaněji a s důrazem na cílovou funkcionalitu. Tento krok následně vedl k vytvoření finální verze, jejíž návrh je popsán v následující kapitole.

## 5.5 Nasazení a zpřístupnění agenta

Finální verze AI agenta byla nasazena do prostředí Hugging Face Spaces, které poskytuje jednoduchý způsob, jak zpřístupnit aplikace využívající strojové učení přímo ve webovém prohlížeči. Toto řešení bylo zvoleno na základě zkušeností z předchozí fáze vývoje a splnilo požadavky na veřejnou dostupnost, stabilní provoz a možnost nasazení bez složité serverové infrastruktury.

Aplikace je dostupná online na adrese: <https://huggingface.co/spaces/hajm17/AI-metadata-agent-smart>

Uživatel zde může jednoduše nahrát soubor ve formátu CSV, který je následně zpracován systémem. Aplikace zobrazí náhled dat, provede kontrolu kvality (např. chybějící hodnoty, problémy s datovými typy), vygeneruje návrhy metadat a popisů pomocí jazykového modelu a nabídne možnost interakce s AI agentem prostřednictvím textového pole. Na základě dotazů pak agent reaguje odpověďmi, které vychází z obsahu daného datasetu. Dále je k dispozici automatizovaný návrh akčních kroků a možnost exportu očištěných dat i odpovídajících metadat.

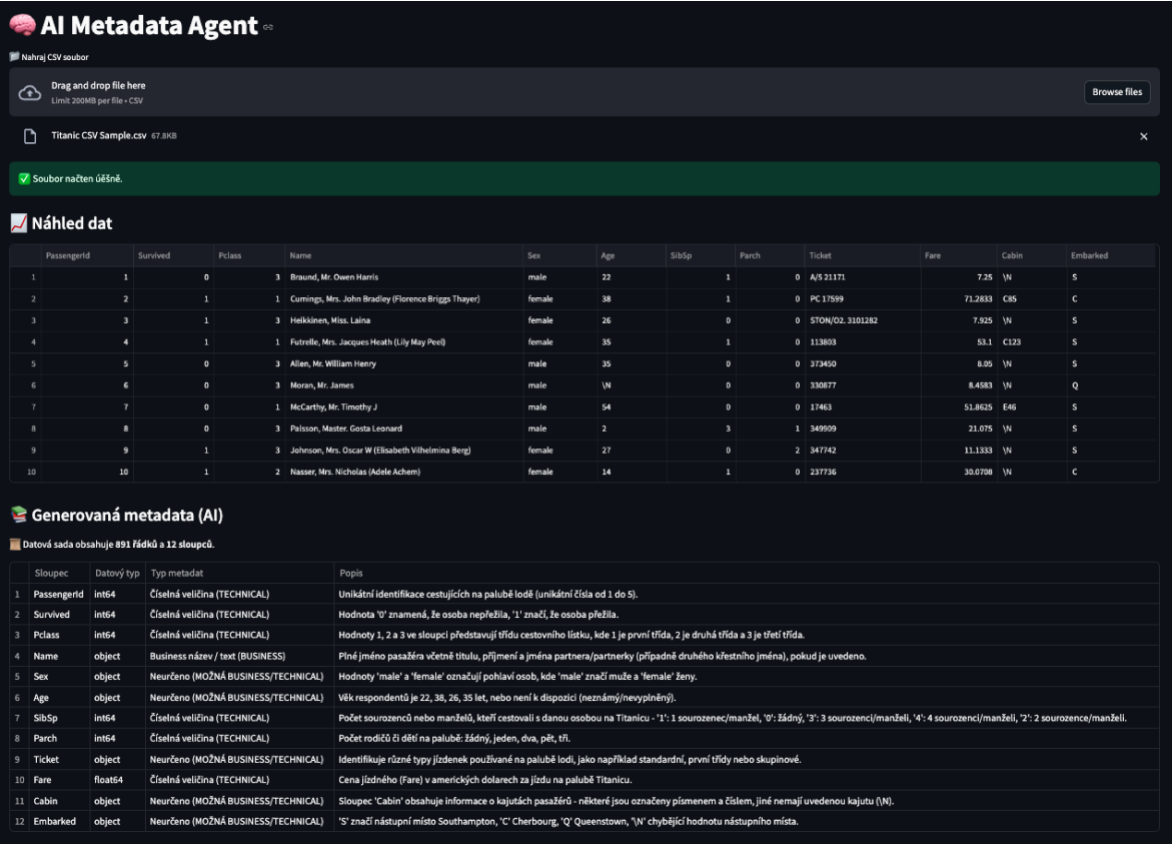
Spuštění agenta nevyžaduje žádnou instalaci – vše běží v prohlížeči. Uživatelské rozhraní je vytvořeno ve frameworku Streamlit, což zajišťuje přehlednost a jednoduchou obsluhu i pro méně technicky orientované uživatele. Veškeré výpočty a API volání probíhají v rámci cloudové instance. O běh aplikace se stará samotná platforma Hugging Face, která poskytuje základní infrastrukturu a zajišťuje automatické načítání prostředí při přístupu uživatele. Logování a případná diagnostika chyb probíhá přímo přes rozhraní dané platformy.

Nasazení do prostředí Hugging Face tak autorce umožnilo nejen snadné zpřístupnění AI agenta, ale i jeho praktické testování s různými datovými vstupy v reálném čase, které si přiblížíme v následující kapitole.

### 5.5.1 Kódové řešení a napojení na OpenAI API


Základ aplikace byl vytvořen v souboru `streamlit_app.py`, který obsahuje kompletní logiku od nahrání dat přes analýzu až po výstupy pro uživatele. Aplikace je postavena modulárně – pomocí několika vlastních funkcí importovaných ze souborů `quality_checker.py`, `agent_core.py` a `metadata_engine.py`, čímž je kód přehledně strukturován podle jednotlivých částí zpracování.

Po spuštění aplikace uživatel nahraje CSV soubor prostřednictvím `st.file_uploader`. Data jsou následně načtena pomocí knihovny `pandas` a zobrazena jako náhled. Poté je aktivována funkce pro generování metadat, která nejprve interně detekuje typy sloupců a základní charakteristiky, a poté pro každý sloupec připraví vstupní prompt pro volání modelu GPT-3.5-turbo přes OpenAI API. Výsledkem je jeden souvislý popis pro každý sloupec, který je přehledně zobrazen v tabulce. Tuto první část aplikace můžeme vidět na Obrázek 9.



Obrázek 9: Vizuál vytvořeného AI agenta; nahrání a náhled datového souboru, generování metadat a popis sloupců pomocí AI

Vedle toho aplikace spouští kontrolu kvality dat (např. prázdné hodnoty, podezřelé znaky nebo nekonzistentní formáty) a následně generuje akční plán, který navrhuje vhodné nápravné kroky. Součástí rozhraní je i jednoduchý textový chat, ve kterém může uživatel klást dotazy ohledně datasetu. Agent pracuje s kontextem dat (souhrn statistik, typy a hodnoty sloupců) a poskytuje odpovědi omezené výhradně na to, co lze z dat vyčíst, uživatel si může prohlížet i historii dotazů, což reprezentuje Obrázek 10.



Obrázek 10: Vizuál vytvořeného AI agenta; kontrola kvality dat a návrh akčního plánu, otázky na AI agenta

Tyto návrhy jsou doplněny také možností spustit automatizované opravy, nebo se podívat na opravený náhled dat či generovaná metadat a následně exportovat očištěná data a odpovídající metadata jako CSV. Celkový možný export je viditelný na Obrázek 11.

**Automatické opravy a export**

[Spustit opravy a nabídnout export](#)

**Opravy / metadata byly vygenerovány.**

- ✓ **Generated opravy**
  - **Droppec Name:** odstranění nevalidní texty (např. 'N/A', 'T').
  - **Droppec Sex:** odstranění nevalidní texty (např. 'N/A', 'T').
  - **Droppec Age:** odstranění nevalidní texty (např. 'N/A', 'T').
  - **Droppec Ticket:** odstranění nevalidní texty (např. 'N/A', 'T').
  - **Droppec Cabin:** odstranění nevalidní texty (např. 'N/A', 'T').
  - **Droppec Embarked:** odstranění nevalidní texty (např. 'N/A', 'T').

**Náhled upravených dat:**

| PassengerId | Survived | Přijím | Jméno | Sex | Věk | Stáje | Posád | Ticket | Fare | Cabin | Embarked |
|-------------|----------|--------|-------|-----|-----|-------|-------|--------|------|-------|----------|
| 1           | 0        | 0      | 0     | 0   | 0   | 0     | 0     | 0      | 0    | 0     | 0        |
| 2           | 1        | 1      | 1     | 1   | 1   | 1     | 1     | 1      | 1    | 1     | 1        |
| 3           | 1        | 1      | 1     | 1   | 1   | 1     | 1     | 1      | 1    | 1     | 1        |
| 4           | 1        | 1      | 1     | 1   | 1   | 1     | 1     | 1      | 1    | 1     | 1        |
| 5           | 0        | 0      | 0     | 0   | 0   | 0     | 0     | 0      | 0    | 0     | 0        |
| 6           | 0        | 0      | 0     | 0   | 0   | 0     | 0     | 0      | 0    | 0     | 0        |
| 7           | 0        | 0      | 0     | 0   | 0   | 0     | 0     | 0      | 0    | 0     | 0        |

[Stáhnout upravený CSV](#)

**Generovaná metadata:**

| Typ            | Podoba (vlastní) | Podoba (standard) | Podoba (standard) |
|----------------|------------------|-------------------|-------------------|
| 1. PassengerId | 0-1              | 0-1               | 0-1               |
| 2. Survived    | 0-1              | 0-1               | 0-1               |
| 3. Příjím      | 0-1              | 0-1               | 0-1               |
| 4. Jméno       | 0-1              | 0-1               | 0-1               |
| 5. Sex         | 0-1              | 0-1               | 0-1               |
| 6. Age         | 0-1              | 0-1               | 0-1               |
| 7. Stáje       | 0-1              | 0-1               | 0-1               |
| 8. Posád       | 0-1              | 0-1               | 0-1               |
| 9. Ticket      | 0-1              | 0-1               | 0-1               |
| 10. Fare       | 0-1              | 0-1               | 0-1               |

[Stáhnout metadata CSV](#)

Obrázek 11: Vizuál vytvořeného AI agenta; popis úprav – očištěná data, metadata a možnost exportu výstupů

Pro zajištění funkčnosti celé aplikace bylo sestaveno i konfigurační prostředí v podobě souboru `requirements.txt`, který definuje potřebné knihovny a jejich verze.

```
1 streamlit
2 pandas
3 numpy
4 altair
5 openai>=1.1.0,<2.0.0
6 tabulate
```

Výpis 1: Requirements.txt (vlastní zpracování)

Tyto knihovny zajišťují jak frontend aplikace (`streamlit`, `altair`), tak zpracování dat (`pandas`, `numpy`) a práci s modelem (`openai`). Díky tomuto nastavení lze aplikaci snadno zreplikovat nebo nasadit v jiném prostředí, které podporuje Python.

Tímto způsobem bylo vytvořeno jednoduché, ale plně funkční řešení, které kombinuje datovou analýzu, umělou inteligenci a interaktivní rozhraní v jednom přístupném webovém nástroji. Veškerý zdrojový kód využitý při implementaci AI agenta je uveden v Příloze A, což umožňuje úplnou replikaci, či hlubší analýzu.

### 5.5.1.1 Napojení na OpenAI API

Napojení na model GPT je realizováno prostřednictvím knihovny `openai`, a to pomocí rozhraní `openai.chat.completions.create`. API klíč je načítán z prostředí tak, aby nebyl uložen přímo v kódu. Díky tomu je možné bezpečně nasazovat aplikaci v cloudovém prostředí, kde je klíč zadán přes systémové proměnné.

Aby bylo možné do aplikace integrovat výstupy generované pomocí jazykového modelu GPT, bylo nutné zajistit přístup k rozhraní OpenAI API. Proces začínal registrací uživatelského účtu, kde bylo nezbytné aktivovat fakturaci. Autorka původně předpokládala, že samotný účet u služby ChatGPT postačí, nicméně přístup k programovému rozhraní API je samostatná služba, která vyžaduje přidání platební karty a aktivaci předplatného.

Po úspěšné aktivaci byl v uživatelském rozhraní vygenerován API klíč, tzv. secret key, který slouží jako jedinečný identifikátor při každém volání API. Jedná se o citlivou informaci, která nesmí být zveřejněna v samotném kódu. V aplikaci je proto klíč načítán bezpečně přes proměnné prostředí, konkrétně pomocí konstrukce `os.getenv("OPENAI_API_KEY")`. Díky tomu lze aplikaci nasazovat do cloudu bez rizika, že by byl klíč viditelný v repozitáři nebo přímo v souboru.

Veškeré dotazy na jazykový model jsou v aplikaci odesílány pomocí knihovny `openai`, která komunikuje s modelem gpt-3.5-turbo. Při každém volání je modelu předán konkrétní „prompt“, který může být buď součástí systému (např. role datového analytika), nebo dynamicky vygenerováno na základě dat uživatele, např. seznam sloupců nebo výběr hodnot. Prompt slouží jako dotaz, který je předán modelu v rámci „chat completion“ požadavku, přičemž výsledkem je textová odpověď, která je dále zobrazena uživateli (OpenAI Platform, 2025).

V kódu autorka uvádí ukázky, které demonstrují specifikaci 2 promptů: pro stručné vysvětlení významu hodnot ve sloupci a pro kontextovou analýzu celého datasetu.

```
1 TYP METADAT - nastavení chování pro výstup ve sloupci Popis
2
3 prompt = (
4     f"Popiš velmi stručně a výstižně význam hodnot ve sloupci '{column}' na základě těchto
5     příkladů: {values_preview}."
6     f"Vrať jednu ucelenou krátkou větu do 125 znaků bez názvu sloupce."
7 )
8 response = openai.chat.completions.create(model="gpt-3.5-turbo",
9     messages = [
10         {"role": "system", "content": "Jsi datový analytik, který stručně a konzistentně vysvětluje
11         význam hodnot ve sloupcích datového souboru."},
12         {"role": "user", "content": prompt},
13     ]
14 )
```

Výpis 2: Ukázka promptování v AI agentovi 1 (vlastní zpracování)


```

1  AI CHAT - nastavení chování chatu
2
3  prompt = (
4      f"Zde je přehled datasetu:\n"
5      f"📊 Statistika:\n{summary}\n\n"
6      f"📌 Sloupce:\n{columns_info}\n\n"
7      f"Dotaz: {user_query}"
8  )
9  with st.spinner("🧠 AI agent přemýšlí..."):
10     try:
11         response = openai.chat.completions.create(
12             model="gpt-3.5-turbo",
13             messages=[
14                 {"role": "system", "content": "Odpovídej výhradně podle datového souboru. Nepřidávej domněnky mimo data."},
15                 {"role": "user", "content": prompt},
16             ]
17         )

```

Výpis 3: Ukázka promptování v AI agentovi 2 (vlastní zpracování)

Samotné využívání OpenAI API je zpoplatněno na základě počtu zpracovaných tokenů, jednotek textu, které model přijímá a generuje (OpenAI Help Center, 2025). Pro každé volání modelu je důležité správně navrhnout prompt tak, aby model nejen pochopil kontext, ale také poskytl výstup ve vhodné formě a požadované délce. V aplikaci bylo experimentováno s různými formulacemi, s cílem dosáhnout konzistentních a srozumitelných výstupů. Tato schopnost dynamického promptování se ukázala jako klíčová pro kvalitu návrhů metadat i celkovou funkčnost AI agenta.



Obrázek 12: Přehled využití OpenAI API během implementace AI agenta za červen 2025

Tento způsob integrace AI modelu je standardní praxí v moderních aplikacích a zajišťuje jak bezpečnost, tak flexibilitu při dalším rozšiřování nebo úpravách chování agenta.



## 5.6 Testování a vyhodnocení

Po dokončení funkční verze AI agenta byla připravena metodika pro jeho systematické otestování a vyhodnocení, spolu s kritérii hodnocení praktické využitelnosti. Cílem je posoudit, jak si agent vede při analýze reálných dat, generování metadat, rozpoznávání problémů v kvalitě dat a interakci s uživatelem. Testování je navrženo tak, aby zahrnovalo jak objektivní metriky výkonnosti, tak i subjektivní hodnocení použitelnosti z pohledu koncových uživatelů.

Testování AI agenta probíhalo na několika volně dostupných datových sadách ve formátu CSV, které byly vybrány s cílem reprezentovat běžné scénáře správy metadat ve firemní praxi. U každé datové sady byl připraven testovací scénář, v němž byly zohledněny různé úrovně kvality vstupních dat, včetně simulovaných chyb a neúplností. Průběh testování byl systematicky zaznamenáván, včetně popisu vstupů, vygenerovaných výstupů agenta a vyhodnocení podle předem stanovených kritérií relevance, přesnosti, rychlosti a robustnosti. Výsledky byly následně shrnuty do tabulky a slouží k objektivnímu posouzení přínosů i limitací navrženého řešení.

### 5.6.1 Metodika testování

Cílem této části je popsat postup, kterým bylo realizováno testování navrženého AI agenta pro automatizovanou správu metadat. Testovací scénáře vycházejí z práce s běžnými CSV soubory obsahujícími tabulková data, jež reprezentují typické vstupy, se kterými se v praxi setkávají datoví správci a analytici. S ohledem na ochranu důvěrných informací a v souladu s přístupem popsáním v předchozí kapitole byla pro testování AI agenta využita pouze volně dostupná data, nikoliv data z reálného firemního prostředí.

Testování probíhalo na několika vybraných datových sadách, které byly záměrně upraveny tak, aby simulovaly různé úrovně kvality vstupních dat. Byly například odstraněny hlavičky, vytvořeny chybějící/nulové hodnoty, zaměněny datové typy nebo uměle vytvořeny duplicity a nekonzistence. Každý testovací scénář tak reflektoval běžné situace, s nimiž se lze při ruční správě metadat v organizaci setkat. Pro každý scénář byl definován konkrétní cíl testu a celý průběh testování byl systematicky zaznamenáván, včetně popisu vstupních dat, vygenerovaných výstupů agenta a poznámek.

Datové sady používané pro testování zahrnují: dataset „*IBM HR Analytics Employee Attrition & Performance*“ (personální data), „*Financial Transactions Dataset*“ (finanční a bankovní transakce) a „*Retail Sales Dataset*“ (prodejní údaje). Tyto datasety byly zvoleny s ohledem na jejich podobnost s reálným firemním prostředím a možnost ověřit chování AI agenta v různých doménových scénářích. Pro každý z nich byly připraveny specifické testovací scénáře zahrnující různé úrovně kvality vstupních dat, simulované chyby a úpravy.

Vzhledem k tomu, že cílem práce bylo ověřit nejen technickou stránku řešení, ale i jeho praktickou použitelnost, byly do hodnocení zařazeny jak objektivní metriky (např. rychlost, přesnost, robustnost), tak i subjektivní pohled na srozumitelnost a přehlednost výstupů o kterých se autorka zmiňuje na následujících řádcích.

### 5.6.1.1 Kritéria hodnocení

Výstupy agenta jsou hodnoceny podle několika hlavních kritérií:

- **Relevance návrhů metadat** – zda jsou vygenerované popisy sloupců srozumitelné, výstižné a odpovídají obsahu dat (výsledné číslo je stanoveno kvalifikovaným odhadem),
- **Přesnost klasifikace typů dat** – schopnost správně odhadnout, zda se jedná např. o identifikátor, kategorii, číselnou hodnotu apod.
- **Rychlost odezvy** – jak rychle probíhá načtení, analýza a generování výstupů;
- **Robustnost při zhoršené kvalitě vstupu** – jak agent reaguje, pokud jsou data neúplná, chybně formátovaná nebo jinak narušená,
- **Subjektivní použitelnost** – jak přehledné a srozumitelné jsou výstupy z pohledu běžného uživatele.

Kritéria hodnocení úspěšnosti AI agenta vycházejí z rámce definovaného v teoretické části práce, konkrétně v podkapitole 3.2.1 Kritéria hodnocení úspěšnosti harmonizace a lehce je upravují. Zatímco teoretická kritéria reflektovala zejména obecné požadavky na konzistenci, přesnost, úplnost a efektivitu harmonizace metadat, v experimentální části jsou tato měřítka dále konkretizována. Oproti původnímu konceptu je navíc kladen důraz na rychlost odezvy systému a srozumitelnost výstupů pro běžné uživatele.

### 5.6.2 Testovací scénáře

Následující část kapitoly prezentuje konkrétní výsledky testování navrženého AI agenta. Pro každý testovací scénář byly zaznamenány jak vstupní podmínky, tak i výstupy generované agentem včetně stručného komentáře k jejich kvalitě a srozumitelnosti. Pro testování a vyhodnocení AI agenta byly využity datové sady stažené z platformy Kaggle.com. Vzhledem k tomu, že autorka neměla možnost pracovat s interními firemními daty, byl při výběru kladen důraz na to, aby vybrané datasety co nejvíce napodobovaly reálné scénáře z praxe. Volba padla na datasety reflektující personální údaje, finanční transakce i oblast prodeje, což umožnilo otestovat chování agenta v různých doménách typických pro běžné firemní prostředí.

Pro účely testování byly zvoleny takové metriky, které zohledňují nejen technickou kvalitu generovaných metadat, ale také uživatelskou zkušenost a robustnost řešení při práci s daty různé kvality. Výsledky jednotlivých scénářů jsou prezentovány v následujících částech.

#### 1. Testovací scénář – personální data

Jako první testovací scénář byl zvolen dataset „IBM HR Analytics Employee Attrition & Performance“, který reprezentuje oblast personálních dat pro simulaci HR procesů ve firmách. Tento soubor nebyl nijak upravován a sloužil k ověření základní funkčnosti AI agenta při zpracování kvalitních, dobře strukturovaných dat.

AI agent byl schopen automaticky analyzovat datovou strukturu, správně identifikovat typy jednotlivých sloupců a vygenerovat popisná metadata ke všem položkám v datasetu. V rámci kontroly kvality dat agent upozornil na několik hodnot, které vyhodnotil jako potenciálně extrémní, avšak žádná z nich nebyla ve skutečnosti nereálná. Přesnost klasifikace datových typů

byla odhadnuta na přibližně 95 % (kvalifikovaný odhad). Rychlost odezvy systému byla velmi dobrá, většina úloh byla zpracována v řádu několika sekund. Výsledky byly celkově hodnoceny jako robustní a agent byl schopen úspěšně zvládnout vstupní data bez zásadních problémů. Subjektivní hodnocení autorky potvrdilo spokojenost s výstupy, s výhradou k detailnějšímu popisu některých upravených sloupců, kde je pro praxi vždy vhodné provést dodatečnou validaci.

## 2. Testovací scénář – finanční transakce

Druhým testovaným scénářem byl dataset „Financial Transactions Dataset“, který svou strukturou odpovídá typickým záznamům o bankovních či účetních transakcích ve firemním prostředí. Pro účely testování byl tento soubor záměrně upraven:

- „id“ u 3 záznamů byla odstraněna hodnota
- „card\_brand“ úmyslně pozměněny 3 hodnoty („Viiisa“, „MasterKard“, „Amexex“), aby bylo možné ověřit, jak si agent poradí s identifikací chyb a nekonzistencí ve vstupních datech

AI agent byl schopen automaticky určit datové typy a vygenerovat popisná metadata ke všem položkám v datasetu. V rámci revize dat správně identifikoval chybějící hodnoty ve sloupci „id“ a v automatických opravách nabídl jejich nahrazení mediánem. U sloupce „card\_brand“ dokázal zachytit nesrovnalost ve tvaru „Masterkard“ a označil ji za pravděpodobnou chybu v názvu, avšak ostatní „poškozené“ hodnoty již neidentifikoval ani v revizi dat.

Relevance popisu a základní analýzy byla na první pohled opět dobrá, nicméně přesnost klasifikace i robustnost při detekci všech záměrných chyb již byla nižší – přibližně 80 % (kvalifikovaný odhad). Rychlost odezvy agenta byla přibližně 10 sekund a systém zvládl úlohu pouze částečně. Subjektivně lze konstatovat, že model přehlédl a ani neopravil všechny zadané chyby ve sloupci card\_brand, což potvrzuje, že při práci s méně zjevným nebo netypickým poškozením dat je stále nutná dodatečná kontrola ze strany uživatele.

## 3. Testovací scénář – prodejní data

Třetím testovaným scénářem byl dataset „Retail Sales Dataset“, který je svým obsahem i strukturou blízký typickým záznamům o prodejkách, zákaznících a finančních operacích ve firemním prostředí. Pro účely testování byla tato datová sada výrazně upravena:

- „date“ změna 5 záznamů na extrémní hodnoty (roky 1999, 2001, 2013, 2026, 2035) a u jednoho záznamu upraveno na neexistující datum 2023-02-30
- „customerID“ odstranění prefixu „CUST“ u 3 záznamů, čímž se změnil formát hodnot
- „gender“ vymazání 7 záznamů
- „age“: zadání extrémních hodnot (3, 89, 132 let) u 3 záznamů
- „total\_amount“: vytvoření 2 extrémně vysokých hodnot (25 000 a 13 500 481), vymazání 3 záznamů a přepsání 3 hodnot na textový zápis („twenty-five“, „fifty“, „hundred“).

AI agent byl při analýze schopen rozpoznat základní datové typy a vytvořit popisy ke všem sloupcům. V revizi dat správně identifikoval chybějící hodnoty ve sloupcích „gender“ a „total\_amount“, označil podezřelou hodnotu ve sloupci age (132), nicméně si nevšiml nejnižší hodnoty (3). Agent také rozpoznal, že u sloupce „total\_amount“ není správně určený datový typ,

místo číselné veličiny jej vyhodnotil jako objekt, protože se v něm nacházely textové hodnoty. Bohužel změny ve sloupci „date“, včetně neexistujícího data, 30. února 2023, agent neodhalil ani po explicitním dotazu v rámci chatu. Změny ve sloupci „customerID“ nebyly v revizi dat identifikovány, ale při přímé interakci v chatu byl agent schopen nesprávné záznamy přesně určit. Prázdné záznamy ve sloupci „gender“, správně určil, extrémní hodnoty ve sloupci „age“ identifikoval po dodatečném dotazu v chatu, ale nijak je dále neoznačil.

Celkově byly popisy agentem vygenerované správně, zejména díky jasné a explicitní struktuře datasetu. Přesnost klasifikace byla přibližně 75 % (kvalifikovaný odhad), rychlost odezvy se pohybovala okolo 10 sekund. Robustnost lze hodnotit jako částečnou – agent přehlédl některé změny a extrémní hodnoty, které nebyl schopen najít ani po opakovaném dotazu. Výsledky však i přes zmíněná omezení ukazují, že agent může být užitečným pomocníkem při základní analýze metadat, i když je v některých případech nezbytná následná validace nebo uživatelská kontrola.

### 5.6.2.1 Omezení a rizika

Přestože byl AI agent navržen s důrazem na praktickou použitelnost a dostupnost, je třeba počítat s určitými omezeními, která vyplývají jak z povahy využití technologie, tak i z kontextu samotné práce. Autorka aplikaci navrhovala samostatně, bez hlubší programátorské praxe, a výsledný prototyp proto není profesionálním komerčním řešením, ale akademickým návrhem s cílem ověřit možnosti využití jazykových modelů v oblasti správy metadat.

Jedním z hlavních rizik je tzv. halucinace jazykového modelu, tedy situace, kdy model GPT-3.5-turbo vygeneruje nepravdivý nebo smyšlený obsah, a to zejména pokud je vstup nejednoznačný nebo chudý na kontext. V neposlední řadě je třeba zohlednit i technické a provozní limity související s využíváním OpenAI API. Každé volání modelu spotřebovává určité množství tzv. tokenů, a cena za provoz se s jejich objemem postupně zvyšuje. U větších datasetů nebo opakovaných dotazů tak může docházet ke zpomalení odezvy a zvýšení nákladů, což je důležité při plánování nasazení v praxi.

Celkově je však třeba tato omezení chápat v kontextu – aplikace byla navržena jako důkaz konceptu v rámci diplomové práce, a i přes výše uvedené limity prokázala, že jazykové modely mají v oblasti metadatového zpracování značný potenciál.

### 5.6.3 Výsledky testování AI agenta

Výsledky testování navrženého AI agenta na třech datových sadách ukázaly, že agent si velmi dobře poradí se základní strukturou a popisem metadat u kvalitních, dobře formátovaných dat. V případě personálních údajů byla přesnost a robustnost hodnocena jako vysoká. U dat s úmyslně zavedenými chybami, poškozeními či netypickými hodnotami se ukázalo, že agent je schopen detekovat většinu běžných problémů, avšak některé méně zjevné nebo neobvyklé nesrovnalosti přehlédl. Přesto však poskytl srozumitelné výstupy, které mohou významně usnadnit základní analýzu metadat. Závěrem lze konstatovat, že AI agent je vhodným nástrojem pro podporu správy metadat, zejména pokud jeho výstupy procházejí dodatečnou validací ze strany odborníka.

Přehledné shrnutí výsledků testování pro jednotlivé scénáře je uvedeno v Tabulka 2.

| DATASET                                           | Úprava/poškození dat                                                                                                                                                                                                              | Testovaný scénář                                                                        | Výstup agenta                                                                                                                                                            | Relevance popisu                                             | Přesnost klasifikace | Rychlost odezvy | Robustnost | Subjektivní poznámka                                                                         |
|---------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------|----------------------|-----------------|------------|----------------------------------------------------------------------------------------------|
| IBM HR Analytics Employee Attrition & Performance | Bez úprav                                                                                                                                                                                                                         | Funkčnost agenta, kvalita vstupních dat                                                 | Agent správně určil datové typy, vygeneroval popisy, upozornil na několik extrémních hodnot (žádná nereálná)                                                             | Relevantní, ale je nutné ověřit detailní popisy              | cca 95 %             |                 | Výborná    | Výstupy robustní, pro praxi doporučena následná validace                                     |
| Financial Transactions Dataset                    | „id“: odstraněna hodnota u 3 záznamů<br>„card_brand“: úmyslně pozměněno 3 hodnoty („Viiisa“, „MasterKard“, „Amexex“)                                                                                                              | Rozpoznání problémů s kvalitou a detekce „poškozených“ hodnot                           | Agent správně identifikoval chybějící hodnoty ve „id“, detekoval „Masterkard“, ostatní změny přehlédl                                                                    | Relevantní na první pohled, u „card_brand“ pouze částečně    | cca 80 %             | <10 s           | Částečná   | Některé chyby agent neodhalil, vhodná uživatelská kontrola                                   |
| Retail Sales Dataset                              | „date“: extrémní a neexistující hodnoty (5 záznamů)<br>„customerID“: změna formátu na číslo (3 záznamy)<br>„gender“: vymazáno 7 hodnot<br>„age“: extrémní hodnoty (3, 89, 132)<br>„total_amount“: extrémní hodnoty, prázdné, text | Změna typů sloupců, detekce chyb, určení správného typu a rozpoznání poškozených hodnot | Agent správně identifikoval většinu chyb, u některých sloupců (např. „date“, „customerID“) přehlédl úpravy; typ „total_amount“ určil jako objekt kvůli textovým hodnotám | Popisy správné, u některých extrémů pouze po doptání v chatu | cca 75 %             | cca 10 s        | Částečná   | Některé extrémní hodnoty agent nerozeznal, popisy celkově vhodné, potřebná následná kontrola |

Tabulka 2: Výsledky testování a vyhodnocení AI agenta na testovacích scénářích (vlastní zpracování)

## 5.7 Shrnutí experimentální části

V rámci experimentální části byla navržena, implementována a nasazena funkční verze AI agenta pro podporu správy metadat. Výsledkem je webová aplikace, která umožňuje nahrání tabulkového souboru, jeho automatickou analýzu, generování popisných metadat a základní detekci problémů v kvalitě dat. Aplikace dále umožňuje komunikaci s uživatelem prostřednictvím přirozeného jazyka, včetně navrhování akčních kroků a exportu očištěných výstupů - agent nabízí základní funkcionality, které by při dalším vývoji mohly být dále rozšířeny například o pokročilejší práci s typologií dat, kontextové doplňování chybějících informací, podporu vícejazyčnosti nebo napojení na externí datové katalogy. Vývoj probíhal s důrazem na použitelnost pro běžné datové scénáře a jednoduchost obsluhy, zejména z pohledu netechnického uživatele.

Vlastní testování agenta probíhalo na třech vybraných datových sadách simulujících firemní prostředí, přičemž pro každý scénář byla ověřována nejen základní funkčnost, ale také schopnost detekce chyb, relevance výstupů a uživatelská přívětivost. Výsledky prokázaly, že agent je schopen dobře zvládnout popis a klasifikaci dat ve standardních případech a efektivně upozornit na běžné chyby, jako jsou chybějící hodnoty nebo extrémní hodnoty v datech. V případech složitějších nebo méně zjevných poškození však model některé nesrovnalosti přehlédl nebo nevyhodnotil správně, což potvrzuje, že je stále potřeba následná uživatelská validace a kontrola.

Z pohledu autorky, která není profesionální vývojářkou, šlo o cennou zkušenost s návrhem aplikace postavené na jazykovém modelu a její zpřístupnění v online prostředí. Projekt ukázal, že i při omezených technických znalostech je možné s využitím moderních nástrojů, jako je OpenAI, Streamlit nebo Hugging Face, sestavit funkční prototyp, který propojuje datovou analytiku s AI výstupy. Z hlediska reálného přínosu lze prototyp vnímat jako proof-of-concept, který demonstruje potenciál využití jazykových modelů při automatizované správě metadat.

Závěrem lze konstatovat, že aplikace splnila definované cíle návrhu a implementace AI agenta v oblasti metadat a vytváří solidní základ pro další výzkum, úpravy nebo rozšíření do praxe. Výsledky experimentálního testování, které jsou shrnuty v tabulce 2, jasně ukazují, že generativní AI může významně zefektivnit rutinní správu metadat, přičemž další rozvoj by měl směřovat zejména k vyšší robustnosti a přesnosti při práci s neúplnými nebo nestandardními daty.

## 6 Porovnání efektivity správy metadat před a po nasazení AI agenta

Šestá kapitola diplomové práce shrnuje a porovnává klíčové rozdíly mezi stavem správy metadat bez využití umělé inteligence a s nasazením AI agenta. Na základě výsledků experimentální části práce jsou zde zhodnoceny dopady automatizace na efektivitu, kvalitu a spolehlivost správy metadat. Kapitola rovněž obsahuje interpretaci hlavních přínosů a limitací řešení a nabízí doporučení pro další implementace v praxi i výzkumu.

### 6.1 Měření a porovnání vybraného use-case

Porovnání efektivity bylo provedeno na základě vybraného use-case, kterým byla evidence a správa metadat nad typickým tabulkovým souborem CSV. V rámci analytické části práce byly na základě řízených rozhovorů identifikovány hlavní úzká místa a časová náročnost manuální správy metadat, která obvykle zahrnuje ruční doplňování popisů, kontrolu datových typů a odhalování chyb či nekonzistencí.

Po nasazení AI agenta došlo k významnému zrychlení a zjednodušení procesu. Automatická analýza datové struktury, generování popisných metadat, identifikace typů sloupců a revize kvality vstupních dat proběhly ve většině případů v řádu několika sekund, a to i u větších souborů. Výsledky testování (v Tabulka 2) ukazují, že AI agent dosáhl vysoké přesnosti při generování metadat u standardních, dobře strukturovaných dat, zatímco při práci s daty obsahujícími chyby nebo netypické hodnoty byla robustnost částečně nižší, cca 75–80 %.

### 6.2 Přínosy a omezení řešení

Implementace AI agenta pro automatizovanou správu metadat přinesla ve srovnání s tradičním manuálním postupem řadu zásadních přínosů, které se promítly do všech sledovaných metrik i celkové efektivity procesu. Nejvýraznějším přínosem byla výrazná úspora času potřebného k analýze, generování popisných metadat a revizi kvality dat. Zatímco manuální evidence metadat je v praxi časově velmi náročná a často vyžaduje opakované konzultace či korekce, nasazení AI agenta umožnilo provést kompletní analýzu datové struktury, identifikaci typů sloupců a detekci běžných chyb v řádu několika sekund. Tento časový rozdíl je obzvláště patrný u větších datových souborů, kde by ruční kontrola zabrala pravděpodobně i několik dní. Automatizace tak významně snižuje časovou zátěž pro datové správce.

Dalším klíčovým přínosem je zvýšení konzistence a jednotnosti výstupů. AI agent generuje popisná metadata a návrhy klasifikace v jednotném stylu, což usnadňuje sdílení a další využití dat napříč týmy nebo odděleními. Zároveň se i snižuje riziko vzniku překlepů, duplicit nebo nejednoznačných popisů, které jsou v praxi častým problémem manuální evidence. Výsledky testování ukazují, že

agent je schopen generovat relevantní a srozumitelné popisy, které poskytují uživatelům lepší přehled o datech a usnadňují jejich orientaci v datových zdrojích. Neméně důležitým přínosem je schopnost AI agenta automaticky rozpoznávat běžné chyby v kvalitě dat, jako jsou chybné hodnoty, podezřelé datové typy nebo extrémní hodnoty.

Přestože přínosy nasazení AI agenta jsou zřejmé, experiment také odhalil několik omezení a slabin agenta, která je potřeba vnímat v kontextu současného stavu generativních modelů i celkové povahy řešení. Prvním z nich je omezená schopnost agenta odhalit méně zjevné či netypické chyby ve vstupních datech. V rámci testovacích scénářů se ukázalo, že model si dobře poradí s běžnými typy chyb, jako jsou prázdné nebo extrémní hodnoty, avšak některé záměrně vytvořené anomálie, například pozměněný formát dat nebo neexistující datum, přehlédl, případně na ně nereagoval ani po explicitním dotazu uživatele. Výsledky tak potvrzují závěry současné literatury, že generativní AI je velmi silná v rutinních, často se opakujících úlohách, ale u méně typických nebo doménově specifických problémů může být její úspěšnost omezená (Y. Singh, 2023). Dalším limitem je závislost na kvalitě a srozumitelnosti vstupních dat. AI agent generuje své výstupy především na základě vzorů a informací, které dokáže vyčíst ze samotného datasetu. Pokud jsou vstupní data neúplná, nejednoznačná nemusí být výsledné popisy zcela přesné či dostatečně informativní. V těchto případech je nutné, aby výstupy AI agenta prošly následnou odbornou validací, která zajistí jejich správnost a použitelnost v praxi.

Významným omezením, které může ovlivnit škálovatelnost a provozní nasazení řešení, jsou i technologická a provozní omezení spojená s využíváním komerčních modelů generativní AI. Každé volání modelu je zpoplatněno na základě počtu zpracovaných tokenů, což při zpracování větších datových sad nebo při častém používání může vést ke zvýšeným provozním nákladům.

Závěrem lze shrnout, že přestože AI agent přináší v oblasti správy metadat jednoznačné zrychlení, zvýšení konzistence a úsporu lidských kapacit, jeho výstupy by měly být vždy chápány jako návrh či základ pro další odbornou validaci. Největšího přínosu dosahuje zejména v rutinních úlohách, kde je třeba rychle a konzistentně generovat popisy, kontrolovat datové typy a odhalovat běžné chyby. Pro dosažení plného potenciálu je však vhodné automatizované řešení kombinovat s odborným dohledem a průběžně rozvíjet jak samotný model, tak znalostní bázi agenta podle konkrétní domény a potřeb organizace.

## 6.3 Doporučení pro praxi a další rozvoj

Závěrem, na základě výsledků experimentu lze v současné době vnímat AI agenta především jako užitečný podpůrný nástroj pro kontrolu, validaci či revizi již existujících metadatových výstupů, nikoli jako samostatné řešení vhodné k okamžitému nasazení do produkčního prostředí. Praktické využití prototypu by mělo být omezeno zejména na situace, kdy je potřeba rychle ověřit konzistenci nebo základní kvalitu dat, případně získat první návrh popisných metadat, jež následně projdou expertní kontrolou.

Pokud by měl být AI agent využitelný v reálné firemní praxi ve větším měřítku, bylo by vhodné rozšířit jeho možnosti mimo zpracování jednoduchých CSV souborů, například o možnost napojení na interní databáze, datové katalogy nebo jiné zdroje dat. Stejně tak by bylo žádoucí doplnit robustnější integrační vrstvu umožňující propojení s existujícími systémy správy dat v organizacích.



Významným směrem pro další rozvoj je rovněž rozšíření funkcionalit směrem k podpoře širší škály datových formátů a automatizované synchronizaci s firemní infrastrukturou. Pro další rozvoj autorka doporučuje podpořit standardizaci výstupů, zvýšit auditovatelnost AI agentů a zaměřit se na jejich snadnou integraci do běžných nástrojů metadata managementu, včetně dostupnosti pro netechnické uživatele.

Zásadní zůstává otázka etiky, bezpečnosti a ochrany dat, implementace generativní AI do správy metadat vyžaduje důsledné posouzení možných rizik, zavedení vhodných bezpečnostních opatření a nastavení transparentních pravidel pro kontrolu a audit výstupů. Prohlubování výzkumu v oblasti etických aspektů, governance i optimalizace nákladů je nezbytné pro dlouhodobou udržitelnost a důvěryhodnost těchto nástrojů v praxi (Hagendorff, 2024).

Z pohledu autorky má zvolený přístup potenciál stát se hodnotným doplňkem existujících procesů, ovšem pouze za předpokladu, že bude agent vždy sloužit jako podpora pro kvalifikovanou lidskou rozhodovací roli a jeho výstupy budou podrobovány pečlivé revizi. Případné nasazení do firemního prostředí vyžaduje další vývoj, integraci a rozsáhlé testování podmínkách v konkrétní organizace.

# Závěr

Diplomová práce se věnovala problematice harmonizace a správy metadat v podnikovém prostředí s důrazem na možnosti využití generativní umělé inteligence. Hlavním cílem bylo navrhnout a experimentálně ověřit funkční prototyp AI agenta, který může podpořit automatizaci a zvýšit efektivitu klíčových činností spojených se správou metadat.

Na základě rešerše odborných zdrojů a analýzy aktuálních přístupů v oblasti metadata managementu byly identifikovány hlavní příležitosti i rizika spojená s nasazením generativní AI v této doméně. Experimentální část práce ukázala, že navržený AI agent je schopen generovat popisná metadata, rozpoznávat základní kvalitativní problémy v datech a významně urychlit běžné rutinní úkony, které by jinak vyžadovaly značné časové kapacity. Výsledky testování dále potvrdily, že prototyp je přínosný zejména při zpracování standardních, dobře strukturovaných dat, kde dochází ke zrychlení a zvýšení konzistence výstupů. Naopak v případě složitějších nebo nekonzistentních vstupních dat je stále nezbytná odborná validace a uživatelský dohled, což odpovídá současným limitům generativních modelů.

Přestože byl navržený AI agent koncipován především jako podpůrný nástroj pro kontrolu a validaci metadat, experiment jasně ukázal jeho potenciál jako doplňku stávajících firemních procesů. Praktické využití však předpokládá další rozvoj směrem k rozšíření integračních možností, jako je napojení na firemní databáze či datové katalogy a podpora širšího spektra datových formátů. Významnou oblastí zůstává i zajištění robustní bezpečnosti, transparentnosti a etické správnosti využívaných řešení, což je nutné ve všech oborech práce s daty.

Z pohledu přenositelnosti lze konstatovat, že poznatky a postupy ověřené v této práci jsou využitelné nejen v analyzovaném prostředí, ale i v širším spektru potenciálních uživatelů. Klíčovým přínosem je pak ukázka možností využití generativní AI v konkrétní praxi a formulace praktických doporučení pro její odpovědnou implementaci.

Práce zároveň poukázala na zásadní limity, především rychlý vývoj technologií, omezený rozsah testování a nutnost odborné validace výstupů. Pro budoucí výzkum se nabízí rozšíření experimentu na komplexnější datové scénáře, hlubší integrace do firemních systémů a průběžné sledování dopadů nasazení AI na procesy správy metadat.

| DÍLČÍ CÍL                                                                                                                                                     | ČÁST, KDE BYL CÍL NAPLNĚN                                                                                                                         |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>DC1:</b> Provedení rešerše odborných zdrojů se zaměřením na problematiku metadata managementu a aktuální trendy v oblasti GenAI                            | 1. Rešerše: metadata a GenAI v kontextu řízení dat                                                                                                |
| <b>DC2:</b> Analýza a porovnání existujících metod pro správu a harmonizaci metadat.                                                                          | 2. Metadata management a GenAI<br>3. Harmonizace metadat<br>4. Analýza výchozího stavu správy metadat a identifikace vhodných míst pro využití AI |
| <b>DC3:</b> Návrh, implementace a otestování funkčního prototypu AI agenta pro generování, obohacování a validaci metadat.                                    | 5. Experimentální návrh a testování AI agenta pro správu metadat                                                                                  |
| <b>DC4:</b> Porovnání výkonnosti správy metadat s využitím AI agenta a bez něj, doporučení pro budoucí využití generativní AI v oblasti metadata managementu. | 6. Porovnání efektivity správy metadat před a po nasazení AI agenta                                                                               |

Tabulka 3: Plnění dílčích cílů diplomové práce (vlastní zpracování)

Závěrem lze říci, že práce naplnila vytyčené cíle a přispívá k rozvoji znalostí i praktických dovedností v oblasti využití generativní umělé inteligence pro správu metadat. Výsledky mohou být inspirací pro datové týmy a odborníky, kteří hledají cesty k efektivnější a odpovědnější správě datových aktiv v podnikovém prostředí.

# Použitá literatura

- Admetrics. (2025, květen 9). *AI Agents Explained: What they are, use cases and benefits for e-commerce*. <https://www.admetrics.io/en/post/ai-agents-in-e-commerce>
- Aprimo. (2025). Aprimo Launches AI Agents to Transform Content Operations with Scalable Automation. *Business Wire* (English). <https://research.ebsco.com/linkprocessor/plink?id=a56c576b-3144-38d0-8821-1e6676c3f587>
- Bannocks, C. (2019, červen). *Active Metadata Management Tools*. <https://www.informatica.com/products/informatica-platform/metadata-management.html>
- Blasingame, M. N., Koonce, T. Y., Williams, A. M., Giuse, D. A., Su, J., Krump, P. A., & Bettinsoli Giuse, N. (2025). Evaluating a large language model's ability to answer clinicians' requests for evidence summaries. *Journal of the Medical Library Association*, 113(1), 65–77. <https://doi.org/10.5195/jmla.2025.1985>
- Boone, M. (2024, červen 19). *IBM Knowledge Catalog 5.0, now with new visualization tools and available generative AI features to advance productivity* [Knowledge Catalog]. Data Governance. <https://community.ibm.com/community/user/dataops/blogs/marcus-boone/2024/06/19/ikc50>
- Borrison, R., Aleksy, M., & Dix, M. (2024). Building Metadata Normalization Using Generative AI. *2024 IEEE 19th Conference on Industrial Electronics and Applications (ICIEA)*, 1–6. <https://doi.org/10.1109/ICIEA61579.2024.10665241>
- Bourne, K. (2024, říjen 8). *Metadata Management & GenAI: Mutualistic Accelerators*. <https://guidehouse.com/insights/advanced-solutions/2024/metadata-management-and-genai>
- Bratková, E. (2012). *Metadata a jejich hlavní schémata*. [https://sites.ff.cuni.cz/uisk/wp-content/uploads/sites/62/2016/01/Metadata-a-jejich-hlavn%C3%AD-sch%C3%A9mata\\_Bratkov%C3%A1.pdf](https://sites.ff.cuni.cz/uisk/wp-content/uploads/sites/62/2016/01/Metadata-a-jejich-hlavn%C3%AD-sch%C3%A9mata_Bratkov%C3%A1.pdf)

- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., ... Amodei, D. (2020). *Language Models are Few-Shot Learners* (No. arXiv:2005.14165). arXiv. <https://doi.org/10.48550/arXiv.2005.14165>
- Colback, L. (2025, květen 7). AI agents: From co-pilot to autopilot. *Financial Times*. <https://www.ft.com/content/3e862e23-6e2c-4670-a68c-e204379fe01f>
- DAMA, I. (2017). *DAMA-DMBOK: Data Management Body of Knowledge*. (2. vyd.). Technics Publications.
- Danesh, M. H. (2020). *Summary: Artificial Intelligence—A Modern Approach*.
- Das, S. (2024, duben 1). *Ethics in Generative AI: Concerns, Examples, and Best Practices* - *ellow.io*. <https://ellow.io/ethics-in-generative-ai/>
- DeBrow, M. (2024, srpen 1). *The Power of Data-Driven Decision Making in Healthcare | Handle With Care—C8 Health Blog*. <https://c8health.com/a/blog/the-power-of-data-driven-decision-making-in-healthcare>
- Deloitte. (2024, září 12). *Deloitte: Generativní AI čelí výzvám v oblasti rizik a práce s daty, ukazuje nová studie Deloitte | Deloitte Česká republika* [Tisková zpráva]. Deloitte Czech Republic. <https://www2.deloitte.com/cz/cs/pages/press/articles/generativni-ai-celi-vyzvam-v-oblasti-rizik-a-prace-s-daty-ukazuje-nova-studie-deloitte.html>
- de Mello, B. H., Rigo, S. J., da Costa, C. A., da Rosa Righi, R., Donida, B., Bez, M. R., & Schunke, L. C. (2022). Semantic interoperability in health records standards: A systematic literature review. *Health and Technology*, 12(2), 255–272. <https://doi.org/10.1007/s12553-022-00639-w>
- Dolečková, L. (2016, červenec 25). Co je EXIF a proč vám může být užitečný? *Fotocesta*. <https://fotocesta.cz/blog/fototypy/co-je-exif-a-proc-vam-muze-byt-uzitecny>
- Egan, D., & Moreno, T. (2024, leden 11). *Document AI Custom Extractor, powered by generative AI, is now GA*. Google Cloud Blog. <https://cloud.google.com/blog/products/ai-machine-learning/document-ai-custom-extractor-powered-by-generative-ai-is-now-ga>

- Fabreau, G. E., Minty, E. P., Southern, D. A., Quan, H., & Ghali, W. A. (2021). A Meta-Data Manifesto: The Need for Global Health Meta-Data. *International Journal of Population Data Science*, 3(1), 436. <https://doi.org/10.23889/ijpds.v3i1.436>
- Farmer, D. (2024, říjen 11). *9 metadata management standards examples that guide success* | TechTarget. Search Data Management. <https://www.techtarget.com/searchdatamanagement/tip/Metadata-management-standards-examples-that-guide-success>
- Gartner. (2024). *Understand Data Governance Trends & Strategies*. Gartner. <https://www.gartner.com/en/data-analytics/topics/data-governance>
- Gaur, C. (2024, prosinec 2). *Metadata Management for Agentic AI Systems—Use Cases and Benefits*. <https://www.xenonstack.com/blog/metadata-management>
- Gonçalves, R. S., Kamdar, M. R., & Musen, M. A. (2019). *Aligning Biomedical Metadata with Ontologies Using Clustering and Embeddings* (Roč. 11503, s. 146–161). [https://doi.org/10.1007/978-3-030-21348-0\\_10](https://doi.org/10.1007/978-3-030-21348-0_10)
- Goodfellow, I., Bengio, Y., & Courville, A. (2016, listopad 18). *Deep Learning*. MIT Press. <https://mitpress.mit.edu/9780262035613/deep-learning/>
- Google Cloud. (2024). *Document AI*. Google Cloud. <https://cloud.google.com/document-ai>
- Gregor, P. (2021, květen 21). *Kdo personalizuje, ten jede*. Zboží a Prodej – zprávy z retailu. <https://www.zboziaprodej.cz/2021/05/21/kdo-personalizuje-ten-jede/>
- Gucer, V. (2020, září 8). Put AI to work in your business with metadata management. *IBM Blog*. <https://www.ibm.com/blog/put-ai-to-work-in-your-business-with-metadata-management/>
- Hagendorff, T. (2024). Mapping the Ethics of Generative AI: A Comprehensive Scoping Review. *Minds and Machines*, 34(4), 39. <https://doi.org/10.1007/s11023-024-09694-w>
- ChatGPT. (2025, červen). *ChatGPT*. <https://chatgpt.com/share/685a91c7-c8b4-800d-93e4-0e68b6c74d2f>
- Chen, Z., Liang, N., Zhang, H., Li, H., Yang, Y., Zong, X., Chen, Y., Wang, Y., & Shi, N. (2023). Harnessing the power of clinical decision support systems: Challenges and opportunities. *Open Heart*, 10(2), e002432. <https://doi.org/10.1136/openhrt-2023-002432>

- Chou, C. (2024). *The Impact of AI on Metadata: AI Study Group for Learning and Interdisciplinary Collaboration*. Proceedings of the International Conference on Dublin Core and Metadata Applications. Scopus. <https://doi.org/10.23106/dcmi.952409098>
- IBM. (2024, květen 16). *Governance and Catalog* | IBM. <https://www.ibm.com/products/knowledge-catalog>
- IMD. (2023, srpen 8). *Generative AI: What is it, and how can it impact business?* <https://www.imd.org/blog/digital-transformation/generative-ai/>
- Informatica. (2025). *Generative AI in MDM: Key Use Cases & Benefits*. Informatica. <https://www.informatica.com/resources/articles/informatica.com/resources/articles/gen-ai-mdm-use-cases>
- KNIME. (2017, 8). *Big Data Extensions* | KNIME. <https://www.knime.com/knime-big-data-extensions>
- LangChain. (2024). *State of AI Agents*. <https://www.langchain.com/stateofaiagents>
- Lindecrantz, E., Gi, M. T. P. G., & Zerbi, S. (2020, duben 28). *Personalized experience for customers: Driving differentiation in retail* | McKinsey. McKinsey. <https://www.mckinsey.com/industries/retail/our-insights/personalizing-the-customer-experience-driving-differentiation-in-retail>
- Lorica, B. (2023, červen 2). *Behind the Curtain: Unpacking GPT-4 and PaLM 2*. Gradient Flow. <https://gradientflow.com/behind-the-curtain-unpacking-gpt-4-and-palm-2/>
- LubaBelokon. (2018, duben 26). Open Source ETL: Apache NiFi vs Streamsets - DataScienceCentral.com. *Data Science Central*. <https://www.datasciencecentral.com/open-source-etl-apache-nifi-vs-streamsets/>
- Mahmood, M., Talburt, J. R., Syed, H., & Mehjabeen. (2023). Metadata: An Integral Component of the Modern Data Strategy—ProQuest. *The Institute of Electrical and Electronics Engineers, Inc. (IEEE) Conference Proceedings, 2023*. <https://doi.org/10.1109/CSCE60160.2023.00267>

- Marin, E. (2024). The transformative potential of Generative Artificial Intelligence (GenAI) in business: A text mining analysis on innovation data sources. *ESIC Market*, 55(2), Article 2. <https://doi.org/10.7200/esicm.55.333>
- Martorana, M., Kuhn, T., Stork, L., & Ossenbruggen, J. van. (2024). *Zero-Shot Topic Classification of Column Headers: Leveraging LLMs for Metadata Enrichment* (No. arXiv:2403.00884). arXiv. <https://doi.org/10.48550/arXiv.2403.00884>
- Matentzoglou, N., Balhoff, J. P., Bello, S. M., Bizon, C., Brush, M., Callahan, T. J., Chute, C. G., Duncan, W. D., Evelo, C. T., Gabriel, D., Graybeal, J., Gray, A., Gyori, B. M., Haendel, M., Harmse, H., Harris, N. L., Harrow, I., Hegde, H., Hoyt, A. L., ... Mungall, C. J. (2022). A Simple Standard for Sharing Ontological Mappings (SSSOM). *Database*, 2022, baac035. <https://doi.org/10.1093/database/baac035>
- McDowell, M. (2019, březn 12). *Stores get smart about AI*. Vogue Business. <https://www.voguebusiness.com/technology/artificial-intelligence-physical-stores-kering-nike-alibaba>
- Modernize Data Management to Drive Value*. (2025). Gartner. <https://www.gartner.com/en/data-analytics/topics/data-management>
- Mosha, N. F., & Ngulube, P. (2023). Metadata Standard for Continuous Preservation, Discovery, and Reuse of Research Data in Repositories by Higher Education Institutions: A Systematic Review. *Information*, 14(8), Article 8. <https://doi.org/10.3390/info14080427>
- Mulac, A., Mathiesen, L., Taxis, K., & Gerd Granås, A. (2021). Barcode medication administration technology use in hospital practice: A mixed-methods observational study of policy deviations. *BMJ Quality & Safety*, 30(12), 1021–1030. <https://doi.org/10.1136/bmjqs-2021-013223>
- MVČR. (2022, březn 23). *ISDOC 6.0.2—Národní standard pro elektronickou fakturaci*. <https://isdoc.cz/6.0.2/doc/isdoc.html>
- Naresh, V. (2024, říjen 7). *How to automate data mapping using AI*. <https://www.osmos.io/blog/automate-data-mapping-with-ai>



- Octopai. (2020, srpen 10). *Why Metadata Management Automation is Crucial to the Healthcare Industry*. Octopai. <https://www.octopai.com/why-metadata-management-automation-is-crucial-to-the-healthcare-industry/>
- OpenAI Help Center. (2025). *What are tokens and how to count them?* <https://help.openai.com/en/articles/4936856-what-are-tokens-and-how-to-count-them>
- OpenAI Platform, A. (2025). *Text generation and prompting*. <https://platform.openai.com>
- Oracle Cloud Infrastructure. (2025). *Generative AI Agents for Enterprise*. <https://www.oracle.com/artificial-intelligence/generative-ai/agents/>
- Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). *Generative Agents: Interactive Simulacra of Human Behavior* (No. arXiv:2304.03442). arXiv. <https://doi.org/10.48550/arXiv.2304.03442>
- Puli, I. D. (2024a, únor 6). Redefining Data Engineering: GenAI for Data Modernization and Innovation – RandomTrees. *RandomTrees – Blog*. <https://randomtrees.com/blog/data-engineering-genai/>
- Puli, I. D. (2024b, únor 19). REDEFINING DATA ENGINEERING: GENAI FOR DATA MODERNIZATION AND INNOVATION — RANDOMTREES. *Medium*. <https://randomtrees.medium.com/redefining-data-engineering-genai-for-data-modernization-and-innovation-randomtrees-6b3bd568cfad>
- Pulvermüller, F., Moseley, R. L., Egorova, N., Shebani, Z., & Boulenger, V. (2014). Motor cognition–motor semantics: Action perception theory of cognition and communication. *Neuropsychologia*, 55, 71–84. <https://doi.org/10.1016/j.neuropsychologia.2013.12.002>
- Ramachandran, K., Quarta, L., Schuurin, M., Kirschniak, C., Rehberg, B., & Gourévitch, A. (2024, únor 6). *The Solution to Data Management's GenAI Problem? More GenAI*. BCG Global. <https://www.bcg.com/publications/2024/the-solution-to-data-managements-genai-problem>
- Rosenbush, S. (2025, květen 17). AI Agents Face One Last, Big Obstacle. *Wall Street Journal*. <https://www.wsj.com/articles/ai-agents-face-one-last-big-obstacle-ef3ea7f5>
- Russell, S., & Norvig, P. (2022, srpen 22). *Artificial Intelligence: A Modern Approach, 4th US ed*. <https://aima.cs.berkeley.edu/>

- Saux, L. (2024, březen 4). What is metadata and why is it as important as the data itself? *Opendatasoft*. <https://www.opendatasoft.com/en/blog/what-is-metadata-and-why-is-it-important-data/>
- Shaikh, R. H. (2024, listopad 11). *Data Interoperability: Principles, Challenges, Best Practices*. <https://www.acceldata.io/blog/data-interoperability-key-principles-challenges-and-best-practices>
- Shapiro. (2024, listopad 15). AI Automation: A New Era in Business Efficiency and Innovation. *insideAI News*. <https://insideainews.com/2024/11/15/ai-automation-a-new-era-in-business-efficiency-and-innovation/>
- Shiller, R. J., & Larochelle, D. (2024). *Data Engineering Best Practices: Architect robust and cost-effective data solutions in the cloud era*. Packt Publishing.
- Shivaram, P. R. (2025, květen 8). *AI Agents: The Secret Behind Modern Data Ecosystems*. <https://www.acceldata.io/blog/how-ai-agents-are-redefining-data-management>
- Singh, M., Kumar, A., Donaparthi, S., & Karambelkar, G. (2025). *Leveraging Retrieval Augmented Generative LLMs For Automated Metadata Description Generation to Enhance Data Catalogs* (No. arXiv:2503.09003). arXiv. <https://doi.org/10.48550/arXiv.2503.09003>
- Singh, Y. (2023, duben 28). *Chcete nasazovat nejnovější technovýstřelky? Tady jsou rizika, na která můžete narazit*. CIOtrends. <https://www.ciotrends.cz/clanky/chcete-nasazovat-nejnovejsi-technovystrelky-tady-jsou-rizika-na-ktera-muzete-narazit>
- Stamp, E. (2024, říjen 17). *Data Governance in the Age of Generative AI: From Reactive to Self-Orchestrating* | *Deloitte* UK. <https://www.deloitte.com/uk/en/services/consulting/blogs/2024/data-governance-in-the-age-of-generative-ai.html>
- Storage, P. (2024a, únor 28). *7 Common Metadata Mistakes and How to Avoid Them*. Pure Storage Blog. <https://blog.purestorage.com/purely-educational/7-common-metadata-mistakes-and-how-to-avoid-them/>

- Storage, P. (2024b, únor 28). *7 Common Metadata Mistakes and How to Avoid Them*. Pure Storage Blog. <https://blog.purestorage.com/purely-educational/7-common-metadata-mistakes-and-how-to-avoid-them/>
- Sullivan, M. (2023, duben 13). *Auto-GPT and BabyAGI: How „autonomous agents“ are bringing generative AI to the masses*. Fast Company. <https://www.fastcompany.com/90880294/auto-gpt-and-babyagi-how-autonomous-agents-are-bringing-generative-ai-to-the-masses>
- Sundaram, S. S., & Musen, M. A. (2025). *Toward Total Recall: Enhancing FAIRness through AI-Driven Metadata Standardization* (No. arXiv:2504.05307). arXiv. <https://doi.org/10.48550/arXiv.2504.05307>
- Tallapragada, S. (2025, březn 3). From Zero to a Billion: Why Metadata Is Key to Building a Massive AI Agent Ecosystem. *Salesforce*. <https://www.salesforce.com/news/stories/scaling-metadata-agentic-ai/>
- Teradata. (2024). *What is Data Harmonization?* | Teradata. <https://www.teradata.com/insights/data-platform/what-is-data-harmonization>
- The Federal Register (DEPARTMENT OF COMMERCE), & Wise, O. (2024, duben 17). *AI and Open Government Data Assets Request for Information—ProQuest*. <https://www.proquest.com/docview/3039983820/1BE34D103C274F10PQ/1?accountid=17203&sourcetype=Reports>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. ukasz, & Polosukhin, I. (2017). Attention is All you Need. *Advances in Neural Information Processing Systems*, 30. [https://papers.nips.cc/paper\\_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html](https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html)
- Vogel, M. (2023, červen 7). *ChatGPT, Next Level: Meet 10 Autonomous AI Agents – Auto-GPT, BabyAGI, AgentGPT, Microsoft Jarvis, ChaosGPT & Friends – HIVE: Big Picture Blog*. <https://blog.big-picture.com/en/chatgpt-next-level-meet-10-autonomous-ai-agents-auto-gpt-babyagi-agentgpt-microsoft-jarvis-chaosgpt-friends/>

- Vora, G. (2025, květen 11). Not All AI Is the Same: A Deep Dive into Generative AI, AI Agents, and Agentic AI. *Medium*. <https://medium.com/@mr.vora212/not-all-ai-is-the-same-a-deep-dive-into-generative-ai-ai-agents-and-agentic-ai-dfcedfd70847>
- Wang, Y.-Y., Zhang, W.-W., Lu, Z., Sun, J., & Jing, M. (2024). Optimal resource allocation model for COVID-19: A systematic review and meta-analysis. *BMC Infectious Diseases*, 24, 200. <https://doi.org/10.1186/s12879-024-09007-7>
- Wong, H., & Saade, T. (2025, květen 29). The Rise of AI Agents: Anticipating Cybersecurity Opportunities, Risks, and the Next Frontier. *R Street Institute*. [https://www.rstreet.org/?post\\_type=research&p=87654](https://www.rstreet.org/?post_type=research&p=87654)
- Zavalin, V., & Zavalina, O. L. (2025). Are we there yet? Evaluation of AI-generated metadata for online information resources. *Information Research an International Electronic Journal*, 30(iConf), Article iConf. <https://doi.org/10.47989/ir30iConf47215>
- Zeng, M. L., & Qin, J. (2023). *Metadata, Third Edition*. ALAstore. <https://alastore.ala.org/metadata3>
- Zorz, M. (2025, červen 4). Agentic AI and the risks of unpredictable autonomy. *Help Net Security*. <https://www.helpnetsecurity.com/2025/06/04/thomas-squeo-thoughtworks-ai-systems-threat-modeling/>

# Přílohy

## Příloha A: Kód zdrojových souborů AI agenta

Zahrnuje celé znění souborů: README.md, agent\_core.py, metadata\_engine.py, quality\_checker.py, requirements.txt a streamlit\_app.py.

### README.md

Tento soubor slouží jako úvodní dokumentace k aplikaci AI Metadata Agent Smart. Obsahuje základní informace o projektu, jako je název, autor, verze a stručný popis funkcionality aplikace. V úvodu je definována struktura aplikace včetně tagů, které vystihují její zaměření např. metadata, data quality, streamlit, agent. Ve druhé části souboru je uveden podrobnější popis, podle kterého aplikace slouží k automatizované analýze metadat a validaci kvality dat u strukturovaných CSV souborů.

```
1 metadata:
2   title: AI Metadata Agent Smart
3   emoji: 🧠
4   colorFrom: '#133929'
5   colorTo: '#36C201'
6   sdk: streamlit
7   app_file: app.py
8   app_port: 8501
9   tags:
10    - data
11    - ai
12    - metadata
13    - streamlit
14    - agent
15   pinned: true
16   short_description: Interactive AI agent for automated metadata analysis and data quality
17   validation
18 # AI Metadata Agent Smart 🧠
19
20 Verze: 2.0.0
21 Autor: Bc. Magdalena Staňková
22
23 POPIS APLIKACE
24 AI Metadata Agent Smart je interaktivní Streamlit aplikace, která automatizuje analýzu
25 metadat a kontrolu kvality dat. Uživatel nahraje CSV soubor, AI agent zpracuje strukturu
26 tabulky, navrhne metadata, detekuje chybějící a neobvyklé hodnoty a umožní interaktivní chatovou
27 komunikaci k dalším otázkám.
```

## 26 FUNKCE

- 27 Automatická AI analýza: Generování návrhu metadat a identifikace možných chyb ve sloupcích.
- 28 Interaktivní chat: Klade dotazy přímo na konkrétní data a dostává odpovědi omezené na obsah datasetu.
- 29 Validace dat: Přehled prázdných hodnot, datových typů a detekce anomálií (extrémní nebo nestandardní hodnoty).
- 30 Historie konverzace: Ukládání a zobrazení předchozích uživatelských dotazů a odpovědí agenta.
- 31 Export AI výstupu: Stažení generovaného textového výstupu (TXT).
- 32 Export opravených dat a metadat: Možnost stažení očištěných dat a odpovídajících metadat ve formátu CSV.

## Agent\_core.py

Tento soubor obsahuje funkci `create_action_plan()`, která na základě výstupu z kontroly kvality dat sestaví návrh akčních kroků. Funkce očekává datový rámec s detekovanými problémy ve sloupcích a pro každou chybu automaticky navrhne odpovídající postup, jak daný problém řešit. Výstupem je nový datový rámec obsahující dva sloupce: *Sloupec* a *AI doporučená akce*.

Kód rozpoznává specifické typy problémů, jako jsou chybějící hodnoty, nestandardní texty, odlehle číselné hodnoty nebo smíšené datové typy a ke každému z nich přiřazuje konkrétní doporučení. Pokud je typ chyby neznámý, funkce doporučuje manuální kontrolu.

```
1 import pandas as pd
2
3 def create_action_plan(quality_report: pd.DataFrame) -> pd.DataFrame:
4     """
5     Na základě hlášení o chybách v datech vygeneruje doporučení AI agenta
6     s návrhem, co s tím dělat. Výstup obsahuje pouze sloupce: Sloupec, AI doporučená akce.
7     """
8
9     if quality_report.empty:
10         return pd.DataFrame(columns=["Sloupec", "AI doporučená akce"])
11
12     action_plan = []
13
14     for _, row in quality_report.iterrows():
15         col = row.get("Sloupec", "Neznámý")
16         issue = row.get("Typ chyby", "")
17
18         if issue == "Chybějící hodnota":
19             action = "Odstranit nebo doplnit chybějící hodnoty."
20         elif issue == "Nestandardní textová hodnota":
21             action = "Sjednotit textové hodnoty nebo nahradit NaN."
22         elif issue == "Podezřelá extrémní hodnota":
23             action = "Označit jako odlehlou hodnotu nebo použít škálování."
24         elif issue == "Smíšené typy hodnot":
25             action = "Sjednotit datový typ ve sloupci."
```

```

26     else:
27         action = "Zkontrolovat manuálně - neznámý typ problému."
28
29     action_plan.append({
30         "Sloupec": col,
31         "AI doporučená akce": action
32     })
33
34     return pd.DataFrame(action_plan)

```

## Metadata\_engine.py

Tento soubor obsahuje funkci `generate_metadata_table()`, která procházením jednotlivých sloupců datového rámce určuje jejich datový typ a zároveň odhaduje roli daného sloupce z pohledu metadat např. identifikátor, číselná veličina, textový popis. Výsledkem je tabulka s přehledem sloupců, jejich datových typů a přiřazené kategorie *Typ metadat*. Modul slouží jako základní nástroj pro strukturované pochopení obsahu dat.

```

1  import pandas as pd
2
3  def generate_metadata_table(df: pd.DataFrame) -> pd.DataFrame:
4      metadata = []
5      for col in df.columns:
6          dtype = str(df[col].dtype)
7
8          if pd.api.types.is_numeric_dtype(df[col]):
9              role = "Číselná veličina (technical)"
10         elif pd.api.types.is_datetime64_any_dtype(df[col]):
11             role = "Datum/čas (operational)"
12         elif col.lower() in ["id", "uuid", "identifier"]:
13             role = "Identifikátor (technical)"
14         elif col.lower() in ["name", "title", "description"]:
15             role = "Business název / text (business)"
16         else:
17             role = "Neurčeno (možná business/technical)"
18
19         metadata.append({
20             "Sloupec": col,
21             "Datový typ": dtype,
22             "Typ metadat": role,
23         })
24
25     return pd.DataFrame(metadata)

```

## Quality\_checker.py

Tento soubor obsahuje funkci `detect_data_quality_issues()`, která provádí základní detekci problémů v kvalitě dat. Prochází jednotlivé sloupce datového rámce a identifikuje čtyři typy chyb: chybějící hodnoty, nestandardní textové hodnoty, extrémní číselné hodnoty a smíšené datové typy. Ke každému nalezenému problému funkce přiřadí příklad a doporučení k nápravě. Výstupem je tabulka, která slouží jako vstup pro další rozhodování agenta.

```
1 import pandas as pd
2 import numpy as np
3
4 def detect_data_quality_issues(df: pd.DataFrame) -> pd.DataFrame:
5     """
6     Provede základní detekci problémů v kvalitě dat.
7     Vrací tabulku: Sloupec | Typ chyby | Příklad | Doporučení
8     """
9     issues = []
10
11     for col in df.columns:
12         series = df[col]
13
14         # 1. Chybějící hodnoty
15         if series.isnull().any():
16             issues.append({
17                 "Sloupec": col,
18                 "Typ chyby": "Chybějící hodnota",
19                 "Příklad": np.nan,
20                 "Doporučení": "Zvážit imputaci, odstranění nebo označení jako 'missing'"
21             })
22
23         # 2. Nestandardní textové hodnoty
24         if series.dtype == object:
25             bad_vals = series[series.astype(str).str.lower().isin(["nan", "null", "\\n",
26 "?"])]
27             if not bad_vals.empty:
28                 issues.append({
29                     "Sloupec": col,
30                     "Typ chyby": "Nestandardní textová hodnota",
31                     "Příklad": bad_vals.iloc[0],
32                     "Doporučení": "Nahradiť čistou hodnotou nebo NaN"
33                 })
```



```

34     # 3. Extrémní číselné hodnoty
35     if pd.api.types.is_numeric_dtype(series):
36         if series.std() > 0:
37             high_outliers = series[series > series.mean() + 3 * series.std()]
38             if not high_outliers.empty:
39                 issues.append({
40                     "Sloupec": col,
41                     "Typ chyby": "Podezřelá extrémní hodnota",
42                     "Příklad": high_outliers.iloc[0],
43                     "Doporučení": "Zvážit outlier detekci, ořezání nebo transformaci"
44                 })
45
46     # 4. Nekonzistence v typu (např. int + string mix)
47     if series.apply(lambda x: isinstance(x, str)).sum() > 0 and
pd.api.types.is_numeric_dtype(series):
48         issues.append({
49             "Sloupec": col,
50             "Typ chyby": "Smíšené typy hodnot",
51             "Příklad": series.astype(str).iloc[0],
52             "Doporučení": "Zkontrolovat formát a sjednotit typ"
53         })
54
55     return pd.DataFrame(issues)

```

## Requirements.txt

Soubor uvádí seznam všech knihoven, které jsou nezbytné pro spuštění aplikace AI Metadata Agent Smart. Obsahuje základní balíčky pro zpracování dat: **pandas** a **numpy**, vykreslování: **altair**, práci s rozhraním aplikace: **streamlit**, volání modelu GPT přes API: **openai** a formátování výstupů **tabulate**. Tento soubor je klíčový pro zajištění správného prostředí, protože umožňuje automatickou instalaci všech závislostí.

```

1  streamlit
2  pandas
3  numpy
4  altair
5  openai>=1.1.0,<2.0.0
6  tabulate

```

## Streamlit\_app.py

Tento soubor tvoří hlavní aplikační skript celé webové aplikace postavené na frameworku Streamlit. Zajišťuje veškerou interakci s uživatelem – od nahrání CSV souboru, přes jeho zobrazení a analýzu, až po komunikaci s jazykovým modelem prostřednictvím OpenAI API. Skript propojuje tři hlavní funkční moduly: `quality_checker.py`, `agent_core.py` a `metadata_engine.py` a orchestruje jejich využití v rámci aplikační logiky.

```
1 import os
2
3 # Streamlit config - bezpečné proměnné pro Hugging Face / Docker prostředí
4 os.environ["HOME"] = "/tmp"
5 os.environ["XDG_CONFIG_HOME"] = "/tmp"
6 os.environ["XDG_DATA_HOME"] = "/tmp"
7 os.environ["STREAMLIT_DISABLE_USAGE_STATS"] = "true"
8
9 import streamlit as st
10 import pandas as pd
11 import openai
12
13 from quality_checker import detect_data_quality_issues
14 from agent_core import create_action_plan
15 from metadata_engine import generate_metadata_table
16
17 st.set_page_config(page_title="🧠 AI Metadata Agent", layout="wide")
18 st.title("🧠 AI Metadata Agent")
19
20 # === Upload ===
21 uploaded_file = st.file_uploader("📁 Nahraj CSV soubor", type=["csv"])
22
23 if uploaded_file:
24     try:
25         df = pd.read_csv(uploaded_file)
26         st.success("✅ Soubor načten úspěšně.")
27
28         df_display = df.copy()
29         df_display.index = range(1, len(df_display) + 1)
30
31         st.subheader("📊 Náhled dat")
32         st.dataframe(df_display.head(10), use_container_width=True)
33
34         if "cached_metadata" not in st.session_state:
35             with st.spinner("AI analyzuje sloupce..."):
36                 metadata = generate_metadata_table(df)
37                 if not metadata.empty:
38                     metadata.index = range(1, len(metadata) + 1)
39
40
```

```

41         def format_metadata_type(value):
42             if "(" in value and ")" in value:
43                 start = value.index("(") + 1
44                 end = value.index(")")
45                 type_part = value[start:end].upper()
46                 return value[:start] + type_part + value[end:]
47             return value
48
49         metadata["Typ metadat"] = metadata["Typ
metadat"].apply(format_metadata_type)
50
51         openai.api_key = os.getenv("OPENAI_API_KEY")
52         descriptions = []
53         for column in metadata["Sloupec"]:
54             try:
55                 values_preview =
df[column].dropna().astype(str).unique()[:5].tolist()
56                 prompt = (
57                     f"Popiš velmi stručně a výstižně význam hodnot ve sloupci
'{column}' na základě těchto příkladů: {values_preview}. "
58                     f"Vrať jednu ucelenou krátkou větu do 125 znaků bez názvu
sloupce."
59                 )
60                 response = openai.chat.completions.create(
61                     model="gpt-3.5-turbo",
62                     messages=[
63                         {"role": "system", "content": "Jsi datový analytik, který
stručně a konzistentně vysvětluje význam hodnot ve sloupcích datového souboru."},
64                         {"role": "user", "content": prompt},
65                     ]
66                 )
67                 desc = response.choices[0].message.content.strip()
68             except Exception:
69                 desc = "Popis není dostupný."
70             descriptions.append(desc)
71         metadata["Popis"] = descriptions
72         st.session_state.cached_metadata = metadata
73     else:
74         st.warning("⚠ Metadata se nepodařilo vygenerovat.")
75
76     if "cached_metadata" in st.session_state:
77         st.subheader("📄 Generovaná metadata (AI)")
78         st.markdown(f"📄 Datová sada obsahuje **{df.shape[0]} řádků** a **{df.shape[1]}
sloupců**.")
79         st.table(st.session_state.cached_metadata)
80
81     st.subheader("🔍 Revize dat")
82     col1, col2 = st.columns(2)
83

```

```

84         with col1:
85             st.markdown("**Kvalita dat (AI kontrola)**")
86             with st.spinner("Kontroluji chyby..."):
87                 quality_report = detect_data_quality_issues(df)
88                 if not quality_report.empty:
89                     quality_report.index = range(1, len(quality_report) + 1)
90                     quality_report = quality_report.drop(columns=["Doporučení"],
errors="ignore")
91                     st.dataframe(quality_report.head(10), use_container_width=True)
92                 else:
93                     st.success("✅ Žádné problémy nenalezeny.")
94
95         with col2:
96             st.markdown("**Akční plán agenta**")
97             if not quality_report.empty:
98                 plan = create_action_plan(quality_report)
99                 plan.index = range(1, len(plan) + 1)
100                 plan = plan.drop(columns=["Typ chyby", "AI doporučení"], errors="ignore")
101                 plan = plan.rename(columns={"Možná akce": "AI doporučená akce"})
102                 st.dataframe(plan.head(10), use_container_width=True)
103             else:
104                 st.info("Data vypadají dobře - žádná akce není třeba.")
105
106         st.subheader("💬 Otázky na AI agenta")
107
108         if "chat_history" not in st.session_state:
109             st.session_state.chat_history = []
110
111         with st.form("chat_form", clear_on_submit=True):
112             col_input, col_button = st.columns([8, 1])
113             with col_input:
114                 user_input = st.text_input("Zeptej se na cokoli ohledně datasetu:",
key="chat_input", label_visibility="collapsed")
115             with col_button:
116                 submitted = st.form_submit_button("📤 Odeslat dotaz")
117
118             if submitted and user_input.strip():
119                 user_query = user_input.strip()
120                 openai.api_key = os.getenv("OPENAI_API_KEY")
121                 summary = df.describe(include='all').fillna("").astype(str).to_markdown()
122                 columns_info = "\n".join([
123                     f"- {col}: {df[col].dtype}, {df[col].nunique()} unikátních hodnot"
124                     for col in df.columns
125                 ])
126

```

```

127         prompt = (
128             f"Zde je přehled datasetu:\n"
129             f" Statistika:\n{summary}\n\n"
130             f" Sloupce:\n{columns_info}\n\n"
131             f"Dotaz: {user_query}"
132         )
133
134
135         with st.spinner("🧠 AI agent přemýšlí..."):
136             try:
137                 response = openai.chat.completions.create(
138                     model="gpt-3.5-turbo",
139                     messages=[
140                         {"role": "system", "content": "Odpovídej výhradně podle datového souboru. Nepřidávej domněnky mimo data."},
141                         {"role": "user", "content": prompt},
142                     ]
143                 )
144                 answer = response.choices[0].message.content.strip()
145                 st.session_state.chat_history.append((user_query, answer))
146             except Exception as e:
147                 st.session_state.chat_history.append((user_query, f"⚠️ Chyba: {e}"))
148
149         for q, a in reversed(st.session_state.chat_history[-5:]):
150             st.markdown(f"***? {q}***")
151             st.markdown(f"🧠 {a}")
152
153         st.subheader("🔧 Automatické opravy a export")
154
155         if st.button("🔧 Spustit opravy a nabídnout export"):
156             with st.spinner("🧠 AI analyzuje a opravuje dataset..."):
157                 df_cleaned = df.copy()
158                 opravy = []
159                 metadata_rows = []
160
161                 for col in df_cleaned.columns:
162                     original_dtype = df_cleaned[col].dtype
163                     col_data = df_cleaned[col]
164
165                     # Oprava chybějících hodnot
166                     if col_data.isnull().any():
167                         if pd.api.types.is_numeric_dtype(col_data):
168                             median_val = col_data.median()
169                             df_cleaned[col] = col_data.fillna(median_val)
170                             opravy.append(f"Sloupec **{col}**: doplněny chybějící hodnoty mediánem `{median_val}`.")

```

```

171         else:
172             df_cleaned[col] = col_data.fillna("Neznámo")
173             opravy.append(f"Sloupec **{col}**: doplněny chybějící hodnoty textem
174             ``Neznámo``.")
175
176         # Oprava textových hodnot
177         if pd.api.types.is_string_dtype(col_data):
178             df_cleaned[col] = col_data.astype(str).str.strip().str.replace("N/A",
179             "Neznámo", case=False).str.replace("?", "", regex=False)
180             opravy.append(f"Sloupec **{col}**: odstraněny nevalidní texty (např.
181             'N/A', '?').")
182
183         # Konverze typů - pokus o převod číselně vyhlížejících textů
184         if original_dtype == object and col_data.dropna().str.replace('.', '',
185         1).str.isnumeric().all():
186             try:
187                 df_cleaned[col] = pd.to_numeric(df_cleaned[col])
188                 opravy.append(f"Sloupec **{col}**: převeden na číselný typ.")
189             except:
190                 pass
191
192         # === Metadata pro export ===
193         unique_vals = df_cleaned[col].dropna().unique()
194         domain_preview = ", ".join(map(str, unique_vals[:5])) + ("..." if
195         len(unique_vals) > 5 else "")
196         value_range = f"{df_cleaned[col].min()}-{df_cleaned[col].max()}" if
197         pd.api.types.is_numeric_dtype(df_cleaned[col]) else "-"
198
199         if pd.api.types.is_numeric_dtype(df_cleaned[col]):
200             type_hint = "ČÍSELNÝ"
201         elif pd.api.types.is_datetime64_any_dtype(df_cleaned[col]):
202             type_hint = "DATUM"
203         elif "id" in col.lower():
204             type_hint = "IDENTIFIKÁTOR"
205         elif len(unique_vals) <= 10:
206             type_hint = "KATEGORIE"
207         else:
208             type_hint = "TEXT"
209
210         metadata_rows.append({
211             "Sloupec": col,
212             "Typ": type_hint,
213             "Počet unikátních hodnot": len(unique_vals),
214             "Ukázka hodnot": domain_preview,
215             "Rozsah (číselné)": value_range
216         })

```

```

212         # === Výstup ===
213         st.success("✅ Opravy i metadata byly vygenerovány.")
214         if opravy:
215             with st.expander("🔍 Provedené opravy", expanded=True):
216                 for fix in opravy:
217                     st.markdown(f"- {fix}")
218
219             st.markdown("**📄 Náhled opravených dat:**")
220             st.dataframe(df_cleaned.head(7).set_index(pd.Index(range(1, 8))),
221 use_container_width=True)
222
223             st.download_button(
224                 label="📄 Stáhnout opravený CSV",
225                 data=df_cleaned.to_csv(index=False).encode("utf-8"),
226                 file_name="opravena_data.csv",
227                 mime="text/csv"
228             )
229
230             # Metadata + export
231             metadata_df = pd.DataFrame(metadata_rows)
232
233             st.markdown("**📄 Generovaná metadata:**")
234             st.dataframe(metadata_df.set_index(pd.Index(range(1, len(metadata_df)+1))),
235 use_container_width=True)
236
237             # Exportní tlačítko
238             st.download_button(
239                 label="📄 Stáhnout metadata CSV",
240                 data=metadata_df.to_csv(index=False).encode("utf-8"),
241                 file_name="metadata.csv",
242                 mime="text/csv"
243             )
244
245         except Exception as e:
246             st.error(f"❌ Chyba při zpracování souboru: {e}")
247         else:
248             st.info("📄 Nahraj CSV soubor pro spuštění analýzy.")

```